

7SNV€ [AD“S®]ZAPE680' COOT:ATKIL

벤 밀든할, 프라툴 P. 스리니바산, 매튜 텐치, 조나단 T. 배런, 라비 라마무르티, 렌 네.

UC 버클리 *구글 연구소 °UC 샌디에이고

초록 본 논문에서는 복잡한 장면의 새로운 시점을 생성하기 위해, 입력 시점의 희소 집합을 사용하여 기반의 연속적인 볼륨 장면 함수를 최적화하는 방법을 제시합니다. 제안하는 알고리즘은 완전 연결(비 컨볼루션) 심층 신경망을 사용하여 장면을 표현하며, 이 신경망의 입력은 단일의 연속적인 5차원 좌표 (공간 위치 (x, y, z) 및 시야 방향 $(@)$)이며, 출력은 해당 공간 위치에서의 볼륨 밀도 및 시야 의존적인 방출 광도입니다. 제안하는 방법은 카메라 광선을 따라 5차원 좌표를 쿼리하고, 고전적인 볼륨 렌더링 기법을 사용하여 출력된 색상과 밀도를 이미지로 투영합니다. 볼륨 렌더링은 본질적으로 미분 가능하므로, 제안하는 표현을 최적화하는 데 필요한 입력은 알려진 카메라 자세를 가진 이미지 집합입니다. 본 논문에서는 복잡한 기하학적 구조와 외관을 가진 장면의 사실적인 새로운 시점을 렌더링하기 위해 신경 라디언스 필드를 효과적으로 최적화하는 방법을 설명하고, 신경 렌더링 및 시점 합성 분야의 기존 연구보다 우수한 결과를 보여줍니다. 시점 합성 결과는 비디오 형태로 시청하는 것이 가장 효과적이므로, 독자 여러분께서는 비교 분석을 위해 첨부된 비디오를 시청해 주시기를 권장합니다.

키워드: 장면 표현, 뷰 합성, 이미지 기반 렌더링, 볼륨 렌더링, 3D 딥러닝.

1. 서론

본 연구에서는, 획득된 이미지들의 렌더링 오류를 최소화하기 위해 연속적인 5차원 장면 표현의 파라미터를 직접 최적화하는 새로운 방법론을 통해, 오랫동안 제기되어 온 뷰 합성 문제를 다룹니다.

다음은 입력 텍스트의 번역입니다. 우리는 정적인 장면을 공간상의 각 지점 (x, y, z) 에서 각 방향 $(@, \phi)$ 으로 방출되는 복사량과, (x, y, z) 를 통과하는 광선에 의해 얼마나 많은 복사량이 축적되는지를 제어하는 미분 투과도 역할을 하는 밀도를 나타내는 연속적인 5차원 함수로 표현합니다. 우리의 방법은 이 함수를 표현하기 위해, 단일 5차원 좌표 $(x, y, z, 0,)$ 로부터 단일 부피 밀도와 뷰에 의존적인 RGB 색상을 회귀시키는 심층 완전 연결 신경망을 최적화합니다 (이는 종종 다층 퍼셉트론 또는 MLP라고 불립니다). 이러한 신경망 복사 필드(NeRF)를 렌더링하기 위해서는...

"본 연구에 모든 저자가 동등하게 기여했습니다."




그림 1: 본 논문에서는 입력 이미지 집합으로부터 특정 장면의 연속적인 5차원 신경 라디언스 필드 표현(임의의 연속적인 위치에서의 볼륨 밀도 및 시점 의존적인 색상)을 최적화하는 방법을 제시합니다. 우리는 볼륨 렌더링 기술을 사용하여 이 장면 표현의 샘플을 광선(rays)을 따라 누적하여, 임의의 시점에서 장면을 렌더링합니다. 여기서, 우리는 합성된 Drums 장면에서 무작위로 획득된 100개의 입력 시점을 시각화하고, 최적화된 NeRF 표현으로부터 렌더링된 두 가지 새로운 시점을 보여줍니다.

특정 관점에서, 우리는 다음과 같은 과정을 수행합니다: 1) 씬을 통과하는 카메라 광선을 추적하여 3차원 점들의 샘플 집합을 생성하고, 2) 이러한 점들과 그에 상응하는 2차원 시야 방향을 신경망의 입력으로 사용하여 색상과 밀도의 출력 집합을 생성하며, 3) 기존의 볼륨 렌더링 기법을 사용하여 이러한 색상과 밀도를 2차원 이미지로 누적합니다. 이 과정은 본질적으로 미분 가능하므로, 관측된 각 이미지와 우리의 표현으로부터 렌더링된 해당 시야 간의 오차를 최소화하여 그래디언트 하강법을 사용하여 이 모델을 최적화할 수 있습니다. 여러 시야에 대한 이 오차를 최소화하는 것은 신경망이 실제 씬의 내용을 포함하는 위치에 높은 볼륨 밀도와 정확한 색상을 할당함으로써 일관된 씬 모델을 예측하도록 장려합니다. 그림 [2]는 이러한 전체 파이프라인을 시각적으로 보여줍니다.

복잡한 장면을 위한 신경 라디언스 필드 표현을 최적화하는 기본적인 구현 방식은 충분히 높은 해상도의 표현으로 수렴하지 않으며, 카메라 광선 당 필요한 샘플 수 측면에서 비효율적이라는 것을 확인했습니다. 이러한 문제점을 해결하기 위해, 입력 5차원 좌표를 위치 인코딩을 통해 변환하여 MLP가 더 높은 주파수의 함수를 표현할 수 있도록 하고, 이 고주파 장면 표현을 적절하게 샘플링하기 위해 필요한 쿼리 수를 줄이는 계층적 샘플링 절차를 제안합니다.

다음은 영어 학술 논문 텍스트의 한국어 번역입니다. ****우리의 접근 방식**** 저희의 접근 방식은 볼륨 기반 표현 방식의 장점을 계승합니다. 이는 복잡한 현실 세계의 기하학적 구조와 외관을 모두 표현할 수 있으며, 투영된 이미지 기반 최적화에 적합합니다. 특히, 저희의 방법은 고해상도로 복잡한 장면을 모델링할 때 발생하는 이산화된 3차원 격자(voxel grid)의 높은 저장 비용 문제를 해결합니다. 요약하자면, 저희의 주요 기술적 기여는 다음과 같습니다.

— 복잡한 기하 구조와 재질을 갖는 연속적인 장면을 5차원 뉴럴 방사선 필드(Neural Radiance Fields)로 표현하는 방법론. 이 방법론은 기본적인 다층 퍼셉트론(MLP) 네트워크로 파라미터화됩니다.

- 기존 볼륨 렌더링 기술을 기반으로 하는 미분 가능한 렌더링 절차를 사용하며, 이를 통해 표준 RGB 이미지로부터 이러한 표현을 최적화합니다. 여기에는 MLP의 용량을 시각적으로 중요한 장면 영역에 할당하기 위한 계층적 샘플링 전략이 포함됩니다.

— 각 입력 *oD* 좌표를 고차원 공간으로 매핑하는 위치 인코딩 방식을 사용하여, 신경망 방사선 필드를 성공적으로 최적화하여 고주파 장면 콘텐츠를 표현할 수 있습니다.

저희는 제안하는 신경 라디언스 필드 방법이 기존의 최첨단 뷰 합성 방법들을 정량적, 정성적으로 능가함을 보여줍니다. 이는 신경망을 사용하여 3차원 장면을 표현하는 방법뿐만 아니라, 심층 컨볼루션 신경망을 훈련하여 샘플링된 볼륨 표현을 예측하는 방법까지 포함합니다. 현재까지 알려진 바로는, 본 논문은 자연 환경에서 촬영된 RGB 이미지를 기반으로 실제 객체 및 장면의 고해상도, 사실적인 새로운 뷰를 렌더링할 수 있는 최초의 연속적인 신경 장면 표현을 제시합니다.

2. 관련 연구

최근 컴퓨터 비전 분야에서 유망한 연구 방향 중 하나는 객체와 장면을 다층 퍼셉트론(MLP)의 가중치에 인코딩하는 것입니다. 이 방법은 3차원 공간 위치를 장면의 모양에 대한 암시적 표현, 예를 들어 해당 위치에서의 부호 거리 [6]로 직접 매핑합니다. 그러나 현재까지 이러한 방법은 삼각형 메시 또는 복셀 그리드와 같은 이산적인 표현을 사용하여 장면을 표현하는 기술만큼 복잡한 기하 구조를 가진 현실적인 장면을 동일한 수준의 정확도로 재현하는 데 어려움을 겪고 있습니다. 본 절에서는 이러한 두 가지 연구 방향을 검토하고, 우리의 접근 방식과 비교하여 복잡하고 현실적인 장면 렌더링에 있어 최첨단 결과를 제공하는 신경망 기반 장면 표현의 기능을 향상시키는 방법을 설명합니다.

다음과 같은 유사한 접근 방식이 사용되었습니다. 다층 퍼셉트론(MLP)을 사용하여 저차원 좌표를 색상으로 매핑하는 방법은 이미지 [44], 텍스처 처리된 재료 [12, 31, 136, 137] 및 간접 조명 값 [38]과 같은 다른 그래픽 함수를 표현하는 데에도 활용되었습니다.

신경망 기반 3차원 형상 표현 최근 연구에서는 심층 신경망을 활용하여 xyz 좌표를 부호 거리 함수 [15, 32] 또는 점유 필드 [11, 27]에 매핑함으로써 연속적인 3차원 형상을 암시적으로 표현하는 방식을 연구해 왔습니다. 그러나 이러한 모델은 일반적으로 ShapeNet [3]과 같은 합성 3차원 형상 데이터셋에서 얻은 실제 3차원 형상 정보에 의존하는 제약이 있습니다. 이후 연구에서는 미분 가능한 렌더링 함수를 사용하여 신경망 기반 암시적 형상 표현을 2차원 이미지만을 사용하여 최적화함으로써 이러한 제약을 완화하려는 시도가 있었습니다. Niemeyer et al. [29]는 표면을 3차원 점유 필드로 표현하고, 각 광선에 대해 수치적 방법을 사용하여 표면 교차점을 찾은 후, 암시적 미분법을 사용하여 정확한 미분을 계산합니다. 각 광선 교차점의 위치는 신경망 기반 3차원 텍스처 필드에 입력으로 제공되며, 해당 지점에 대한 확산 색상을 예측합니다. Sitzmann et al.은 덜 직접적인 신경망 기반 3차원 표현을 사용하며, 각 연속적인 3차원 좌표에서 특징 벡터와 RGB 색상을 출력합니다. 또한, 각 광선을 따라 이동하며 표면의 위치를 결정하는 순환 신경망으로 구성된 미분 가능한 렌더링 함수를 제안합니다.

"이러한 기술들은 잠재적으로 복잡하고 고해상도의 기하학적 구조를 표현할 수 있지만, 현재까지는 단순한 형태와 낮은 기하학적 복잡성을 가진 객체에만 적용되어 왔으며, 이로 인해 과도하게 부드러운 렌더링 결과가 나타납니다. 본 연구에서는 5차원 방사 휘도 필드(3차원 볼륨)를 인코딩하기 위해 네트워크를 최적화하는 대체 전략을 제시합니다."

2차원 시점 의존적인 외관 정보를 활용하여 더 높은 해상도의 기하학적 구조와 외관을 표현함으로써, 복잡한 장면의 사실적인 새로운 시점을 렌더링할 수 있습니다.

뷰 합성 및 이미지 기반 렌더링 밀집된 뷰 샘플링을 통해, 간단한 광학 필드 샘플 보간 기법을 사용하여 사실적인 새로운 뷰를 재구성할 수 있습니다 [21, 5, 7]. 희소한 뷰 샘플링을 사용한 새로운 뷰 합성에 있어서, 컴퓨터 비전 및 그래픽 분야는 관찰된 이미지로부터 전통적인 기하학적 구조 및 외관 특징을 예측함으로써 상당한 발전을 이루었습니다. 널리 사용되는 접근 방식 중 하나는 장면의 메시 기반 표현을 사용하는 것으로, 이는 확산 [48] 또는 뷰 의존적 [2, 8, 22, 30, 49] 외관을 가집니다. 미분 가능한 래스터라이저 또는 패스트레이서는 메시 표현을 직접 최적화하여 그래디언트 하강을 통해 주어진 입력 이미지 세트를 재현할 수 있습니다. 그러나 이미지 재투영을 기반으로 한 그래디언트 기반 메시 최적화는 종종 어려움을 겪는데, 이는 아마도 지역 최소값 또는 손실 함수의 불량한 조건 때문일 것입니다. 또한, 이 전략은 최적화 전에 제공되어야 하는 고정된 토폴로지를 가진 템플릿 메시가 필요하며, 이는 일반적으로 제약 없는 실제 장면에서는 사용할 수 없습니다.

다음은 입력 텍스트의 번역입니다. 또 다른 방법론은 입력 RGB 이미지 집합으로부터 고품질의 사실적인 뷰 합성을 수행하기 위해 볼륨 표현을 활용합니다. 볼륨 기반 접근 방식은 복잡한 형태와 재질을 현실적으로 표현할 수 있으며, 그래디언트 기반 최적화에 적합하며, 메시 기반 방법보다 시각적으로 산만하게 느껴지는 아티팩트를 덜 생성하는 경향이 있습니다. 초기 볼륨 기반 접근 방식은 관찰된 이미지를 사용하여 직접적으로 복셀 그리드를 색상 매기기 [1940/45]를 수행했습니다. 최근에는 여러 방법이 대규모의 다중 장면 데이터셋을 사용하여, 입력 이미지 집합으로부터 샘플링된 볼륨 표현을 예측하는 심층 신경망을 학습시키고, 테스트 시에 알파 블렌딩 또는 학습된 블렌딩을 사용하여 새로운 뷰를 렌더링합니다. 다른 연구에서는 컨볼루션 신경망(CNN)과 샘플링된 복셀 그리드를 각 특정 장면별로 결합하여 최적화하는 방법을 제시했습니다. 이를 통해 CNN은 저해상도 복셀 그리드에서 발생하는 이산화 아티팩트를 보정하거나, 예측된 복셀 그리드가 입력 시간 또는 애니메이션 제어에 따라 달라지도록 하는 것을 목표로 합니다 [24]. 이러한 볼륨 기반 기술은 새로운 뷰 합성에 있어 인상적인 결과를 보여주었지만, 더 높은 해상도의 이미지로 확장하는 능력은 3차원 공간의 이산적인 샘플링으로 인해 시간 및 공간 복잡성이 낮아 발생하는 근본적인 한계를 가지고 있습니다. 우리는 이 문제를 해결하기 위해, 심층 완전 연결 신경망의 파라미터 내에 연속적인 볼륨을 인코딩합니다. 이는 기존의 볼륨 기반 접근 방식보다 훨씬 높은 품질의 렌더링을 생성할 뿐만 아니라, 샘플링된 볼륨 표현에 비해 훨씬 적은 저장 공간을 필요로 합니다.

3. 신경 라디언스 필드 장면 표현

다음은 영어 학술 논문 텍스트를 한국어로 번역한 결과입니다. **연속적인 장면의 표현** 본 연구에서는 연속적인 장면을 다음과 같이 표현합니다. * $\mathbf{oD}$ 벡터 값을 갖는 함수로, 입력은 3차원 위치 $\mathbf{x} = (a, y, z)$ 및 2차원 시야 방향 (θ, ϕ) 이며, 출력은 방출되는 색상 $\mathbf{c} = (r, g, b)$ 및 부피 밀도 σ 입니다. * 실제로는 다음과 같이 표현합니다.




그림 2: 우리의 신경망 기반 방사선 필드 장면 표현 방식 및 미분 가능한 렌더링 과정에 대한 개요. 우리는 카메라 광선을 따라 5차원 좌표 (위치 및 시야 방향)를 샘플링하여 이미지를 생성합니다 (a). 이러한 위치 정보를 다층 퍼셉트론 (MLP)에 입력하여 색상 및 부피 밀도를 생성합니다 (b). 그런 다음, 부피 렌더링 기법을 사용하여 이러한 값을 이미지로 합성합니다 (c). 이 렌더링 함수는 미분 가능하므로, 생성된 이미지와 실제 관측 이미지 간의 잔차를 최소화하여 장면 표현을 최적화할 수 있습니다 (d).

방향을 3차원 데카르트 좌표 단위 벡터 d 로 표현합니다. 이러한 연속적인 5차원 장면 표현을 MLP(Multi-Layer Perceptron) 네트워크 $F_{\theta}: (x, d) \rightarrow (c, \sigma)$ 로 근사하고, 각 입력 5차원 좌표를 해당 부피 밀도와 방향성 방출 색상으로 매핑하도록 네트워크의 가중치 θ 를 최적화합니다.

다음은 영어 학술 논문 텍스트의 한국어 번역입니다. 본 연구에서는 모델이 다중 시점 일관성을 갖도록 유도하기 위해, 네트워크가 입력 위치 x 에 대한 부피 밀도 σ 를 예측하도록 제한하는 동시에, RGB 색상 c 는 위치와 시야 방향 모두에 대한 함수로 예측하도록 설계했습니다. 이를 위해, MLP (Multi-Layer Perceptron) F_{θ} 는 먼저 입력 3차원 좌표 x 를 8개의 완전 연결 계층(ReLU 활성화 함수 사용, 각 계층당 256 채널)을 통해 처리하고, 부피 밀도 σ 와 256차원 특징 벡터를 출력합니다. 이 특징 벡터는 이후 카메라 광선의 시야 방향과 연결(concatenation)되어, 추가적인 완전 연결 계층(ReLU 활성화 함수 사용, 128 채널)으로 전달되며, 이 계층은 시점 의존적인 RGB 색상을 출력합니다.

(그림)을 참조하면, 저희 방법이 시야 방향 정보를 활용하여 램베르트 반사 특성이 아닌 현상을 표현하는 방식을 확인할 수 있습니다. 그림 4에서 볼 수 있듯이, 시야 의존성 없이 학습된 모델(입력으로 x 만 사용)은 반사광을 표현하는 데 어려움을 겪습니다.

4. 방사 필드를 이용한 볼륨 렌더링

저희의 oD 뉴럴 레디언스 필드는 씬을 공간상의 모든 지점에서 부피 밀도와 방향성 방출 복사량으로 표현합니다. 고전적인 볼륨 렌더링 원리를 사용하여 씬을 통과하는 모든 광선의 색상을 렌더링합니다. 부피 밀도 $\sigma(x)$ 는 위치 x 에서 무한소 입자에서 광선이 종료될 확률의 미분으로 해석될 수 있습니다. 근거리 경계 t_n 와 원거리 경계 t_f 를 갖는 카메라 광선 $r(t) = o + td$ 의 예상 색상 $C(r)$ 은 다음과 같습니다.

$$C(r) = \int_{t_n}^{t_f} T(t) \sigma(r(t)) c(r(t), d) dt, \text{ where } T(t) = \exp\left(-\int_{t_n}^t \sigma(r(s)) ds\right). \quad (1)$$




그림 3: 시점 의존적인 방사광의 시각화. 우리의 신경망 기반 방사광 필드 표현은 공간 위치 x 와 시야 방향 d 에 대한 5차원 함수로서 RGB 색상을 출력합니다. 여기서는, 우리의 신경망 표현으로 구성된 배(Ship) 장면에서 두 개의 공간 위치에 대한 시점 방향별 색상 분포의 예시를 시각화합니다. (a)와 (b)에서는, 배의 측면(주황색 삽입)과 물 표면(파란색 삽입)에 위치한 두 개의 고정된 3차원 지점의 모습을 서로 다른 카메라 위치에서 관찰한 결과를 보여줍니다. 우리의 방법은 이러한 두 개의 3차원 지점의 시점 변화에 따른 외관 변화를 예측하며, (c)에서는 이러한 현상이 시야 방향의 전체 반구에 걸쳐 어떻게 연속적으로 일반화되는지를 보여줍니다.

함수 $J'(t)$ 는 t_n 에서 t_f 까지의 광선 경로를 따라 누적 투과율을 나타냅니다. 즉, 광선이 t 에서 t_f 까지 다른 입자와 충돌하지 않고 이동할 확률입니다. 우리의 연속적인 뉴럴 라디언스 필드에서 원하는 가상 카메라의 각 픽셀을 통과하는 카메라 광선에 대해, 이 적분 $C(r)$ 을 추정하여 뷰를 렌더링해야 합니다.

다음은 영어 학술 논문 텍스트의 번역입니다. (컴퓨터 과학/AI 분야) * **수치적 적분 추정** 연속적인 적분을 수치적 방법(구적법)을 사용하여 추정합니다. 일반적으로 이산화된 복셀 그리드를 렌더링하는 데 사용되는 결정론적 구적법은 MLP가 고정된 이산적인 위치 집합에서만 쿼리되도록 하여, 저희의 표현 방식의 해상도를 효과적으로 제한합니다. 대신, 저희는 계층화된 샘플링 접근 방식을 사용합니다. 여기서 $[t_n, t_f]$ 구간을 N 개의 균등하게 간격을 둔 구간으로 나누고, 각 구간 내에서 하나의 샘플을 균등하게 무작위로 추출합니다.

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)\right]. \quad (2)$$

비록 적분 값을 추정하기 위해 이산적인 샘플 집합을 사용하지만, 계층화 표본 추출(stratified sampling)은 최적화 과정에서 다층 퍼셉트론(MLP)이 연속적인 위치에서 평가되도록 함으로써 연속적인 장면 표현을 가능하게 합니다. 우리는 이러한 샘플들을 사용하여, Max가 작성한 볼륨 렌더링 관련 논문 [26]에서 논의된 사분법 규칙을 통해 $C(r)$ 을 추정합니다.

$$\hat{C}(r) = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) c_i, \text{ where } T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right), \quad (3)$$

다음은 주어진 텍스트의 번역입니다. 여기서 $\delta_i = t_{i+1} - t_i$ 는 인접한 샘플 간의 거리를 나타냅니다. $C(r)$ 를 (c_i, δ_i) 값들의 집합으로부터 계산하는 이 함수는 사소하게 미분 가능하며, alpha 값 $\alpha_i = 1 - \exp(-\sigma_i \delta_i)$ 인 전통적인 알파 합성으로 단순화될 수 있습니다.




그림 4: 본 연구에서 제안하는 전체 모델이 시점 의존적인 방사휘도를 표현하고, 입력 좌표를 고주파 위치 인코딩을 통해 전달함으로써 얻는 이점을 시각적으로 보여줍니다. 시점 의존성을 제거하면 모델이 불도저 트랙에서 발생하는 정반사를 재현하는 능력이 저하됩니다. 위치 인코딩을 제거하면 모델의 고주파 기하학적 구조 및 텍스처를 표현하는 능력이 크게 감소하여, 결과적으로 과도하게 부드러운(oversmoothed) 외관을 나타냅니다.

9. 신경 라디언스 필드 최적화

이전 섹션에서는 장면을 신경망 방사선 필드로 모델링하고 이 표현으로부터 새로운 뷰를 렌더링하는 데 필요한 핵심 구성 요소를 설명했습니다. 그러나 6.4절에서 보여진 바와 같이, 이러한 구성 요소만으로는 최첨단 수준의 품질을 달성하기에 충분하지 않습니다. 따라서 고해상도의 복잡한 장면을 표현할 수 있도록 두 가지 개선 사항을 도입합니다. 첫 번째는 입력 좌표의 위치 인코딩으로, 이는 MLP가 고주파 함수를 표현하는 데 도움을 줍니다. 두 번째는 계층적 샘플링 절차로, 이를 통해 고주파 표현을 효율적으로 샘플링할 수 있습니다.

5.1 위치 인코딩

비록 신경망이 범용 함수 근사기(universal function approximator)라는 사실이 알려져 있음에도 불구하고, {14} 본 연구에서는 네트워크 F_θ 가 $xyz0 \in \mathbb{R}^4$ 입력 좌표에 직접 작용할 경우, 색상 및 기하학적 형태의 고주파 변화를 표현하는 데 성능이 저하되는 현상이 나타났습니다. 이는 Rahaman et al. [35]의 최근 연구 결과와 일관성을 보입니다. 해당 연구에서는 심층 신경망이 낮은 주파수의 함수를 학습하는 경향이 있다는 것을 보여줍니다. 또한, 입력 데이터를 네트워크에 전달하기 전에 고주파 함수를 사용하여 더 높은 차원의 공간으로 매핑하면, 고주파 변동을 포함하는 데이터에 대한 더 나은 fitting이 가능함을 보여줍니다.

다음은 번역된 텍스트입니다. 저희는 이러한 연구 결과를 신경망 기반 장면 표현의 맥락에서 활용하며, F_θ 를 두 개의 함수, 즉 학습 가능한 함수 F_θ 와 학습 불가능한 함수 γ 의 조합으로 재정의함으로써 성능이 크게 향상됨을 보여줍니다 (그림 및 표 2 참조). 여기서 γ 는 $\mathbb{R}^4$ 을 더 높은 차원의 공간 $\mathbb{R}^L$ 으로 매핑하는 함수이며, F_θ 는 여전히 일반적인 다층 퍼셉트론(MLP)입니다. 구체적으로, 저희가 사용하는 인코딩 함수는 다음과 같습니다.

$$\gamma(p) = (\sin(2^0 \pi p), \cos(2^0 \pi p), \dots, \sin(2^{L-1} \pi p), \cos(2^{L-1} \pi p)). \quad (4)$$

다음 함수 $\gamma(\cdot)$ 은 x 좌표의 세 가지 값 (각 값은 $[-1, 1]$ 범위로 정규화됨)과 세 가지 구성 요소에 각각 적용됩니다.

데카르트 좌표계에서 시야 방향 단위 벡터 d (이는 정의에 따라 $[-1, 1]$ 범위 내에 있음). 우리의 실험에서는 $y(x)$ 에 대해 $L = 10$, 그리고 $y(d)$ 에 대해 $L = 4$ 로 설정했습니다.

다음은 입력 텍스트의 번역입니다. 유사한 매핑 방식은 널리 사용되는 Transformer 아키텍처(참조 [47])에서도 사용되며, 이는 "위치 인코딩"이라고 불립니다. 그러나 Transformer는 이를 시퀀스 내 토큰의 개별적인 위치 정보를 아키텍처에 입력하는 데 사용합니다. 아키텍처 자체가 순서 정보를 포함하지 않는 경우에 해당됩니다. 반면, 본 연구에서는 이러한 함수들을 사용하여 연속적인 입력 좌표를 더 높은 차원의 공간으로 매핑함으로써, 다층 퍼셉트론(MLP)이 더 높은 주파수의 함수를 더 쉽게 근사화할 수 있도록 합니다. 관련 연구 분야인 투영 데이터를 기반으로 3차원 단백질 구조를 모델링하는 연구에서도 유사한 입력 좌표 매핑 방식을 사용합니다.

0. 2 계층적 볼륨 샘플링

저희의 렌더링 전략은 각 카메라 광선에 따라 N 개의 쿼리 지점에서 신경 라디언스 필드 네트워크를 밀집적으로 평가하는 방식으로, 비효율적입니다. 렌더링된 이미지에 기여하지 않는 빈 공간 및 가려진 영역이 여전히 반복적으로 샘플링됩니다. 저희는 볼륨 렌더링 분야의 초기 연구 [20]에서 영감을 받아, 최종 렌더링에 미치는 예상 효과에 비례하여 샘플을 할당하는 계층적 표현 방식을 제안합니다.

다음은 입력 텍스트의 번역입니다. 장면을 단일 네트워크로 표현하는 대신, 우리는 두 개의 네트워크를 동시에 최적화합니다. 하나는 "거친(coarse)" 네트워크이고, 다른 하나는 "세밀한(fine)" 네트워크입니다. 먼저, 계층화된 샘플링을 사용하여 N 개의 위치를 샘플링하고, 설명된 방정식(Eqns. and B)에 따라 이 "거친" 네트워크를 해당 위치에서 평가합니다. 이 "거친" 네트워크의 출력을 바탕으로, 각 광선(ray)을 따라 샘플링할 점들을 더욱 정교하게 선택합니다. 이때, 샘플은 볼륨의 관련 부분에 더 집중되도록 편향됩니다. 이를 위해, 먼저 "거친" 네트워크에서 얻은 알파 합성 색상 $C(r)$ 을 방정식 [3]에서 다음과 같이 표현합니다. 이는 광선 상의 모든 샘플링된 색상 c_i 의 가중 합으로 나타낼 수 있습니다.

$$\hat{C}_c(\mathbf{r}) = \sum_{i=1}^{N_c} w_i c_i, \quad w_i = T_i(1 - \exp(-\sigma_i \delta_i)). \tag{5}$$

다음 가중치를 $Ww_i = 1/30 \times w_i$ 로 정규화하면, 광선(ray)을 따라 일정한 구간으로 나뉘는 확률 밀도 함수(PDF)가 생성됩니다. 이 분포로부터 역변환 샘플링(inverse transform sampling)을 사용하여 두 번째 샘플 집합인 N_y 위치를 추출하고, 첫 번째와 두 번째 샘플 집합의 합집합에 대해 "세밀한(fine)" 네트워크를 평가합니다. 그리고 방정식 [3]을 사용하여 광선의 최종 렌더링 색상 $C(x)$ 를 계산하지만, N 개의 샘플과 N_y 개의 샘플을 모두 사용합니다. 이 절차는 시각적으로 보이는 콘텐츠를 포함할 것으로 예상되는 영역에 더 많은 샘플을 할당합니다. 이는 중요 샘플링(importance sampling)과 유사한 목표를 달성하지만, 각 샘플을 전체 적분의 독립적인 확률적 추정값으로 취급하는 대신, 샘플링된 값을 전체 적분 영역의 불균일한 이산화(discretization)로 사용합니다.

0.d 구현 세부 사항

각 장면별로 독립적인 신경망 기반의 연속적인 볼륨 표현 네트워크를 최적화합니다. 이는 장면의 캡처된 RGB 이미지 데이터 세트만 필요로 합니다.

해당 카메라의 자세 및 내부 파라미터, 그리고 장면 경계 (합성 데이터의 경우, 실제 카메라 자세, 내부 파라미터 및 경계를 사용하며, 실제 데이터의 경우 COLMAP 구조-운동 패키지를 사용하여 이러한 파라미터를 추정합니다). 각 최적화 반복 시, 데이터셋의 모든 픽셀에서 무작위로 선택된 일괄 데이터를 샘플링하고, 섹션.0에서 설명된 계층적 샘플링 방법을 따릅니다. 조잡한 네트워크에서 N_V 개의 샘플을, 그리고 정밀한 네트워크에서 $N + N_y$ 개의 샘플을 추출합니다. 그런 다음, 섹션.4에서 설명된 볼륨 렌더링 절차를 사용하여, 추출된 두 세트의 샘플로부터 각 광선의 색상을 렌더링합니다. 우리의 손실 함수는 조잡한 렌더링과 정밀한 렌더링 모두에서 렌더링된 픽셀 색상과 실제 픽셀 색상 간의 제곱 오차의 총합입니다.

$$\mathcal{L} = \sum_{\mathbf{r} \in \mathcal{R}} \left[\left\| \hat{C}_c(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 + \left\| \hat{C}_f(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 \right] \quad (6)$$

여기서 $\mathcal{R}$ 은 각 배치 내의 광선 집합을 나타내며, $C(\mathbf{r})$, $\hat{C}_c(\mathbf{r})$, 그리고 $\hat{C}_f(\mathbf{r})$ 는 각각 광선 $\mathbf{r}$ 에 대한 정답, 대략적인 볼륨 예측 값, 그리고 정밀한 볼륨 예측 값을 나타내는 RGB 색상을 의미합니다. 최종 렌더링 결과는 $\hat{C}_f(\mathbf{r})$ 에서 나오지만, 대략적인 네트워크에서 생성된 가중치 분포를 사용하여 정밀한 네트워크에서 샘플을 할당할 수 있도록 $\hat{C}_c(\mathbf{r})$ 에 대한 손실도 최소화합니다.

저희의 실험에서는 배치 크기를 4096개의 광선으로 설정했으며, 각 광선은 조잡한 볼륨에서 $N_V = 64$ 개의 좌표, 그리고 정밀한 볼륨에서 $N_y = 128$ 개의 추가 좌표에서 샘플링되었습니다. 최적화 과정에서는 학습률을 5×10^{-4} 에서 시작하여 지수적으로 5×10^{-5} 로 감소시키는 Adam 옵티마이저를 사용했습니다 (다른 Adam 하이퍼파라미터는 기본값인 $\beta_1 = 0.9$, $\beta_2 = 0.999$, 그리고 $\epsilon = 10^{-7}$ 로 설정). 단일 장면의 최적화는 일반적으로 NVIDIA V100 GPU 한 대에서 약 100,000 ~ 300,000 iteration 동안 진행되며, 약 1~2일이 소요됩니다.

6. 결과

다음은 영어 학술 논문 텍스트의 번역입니다. 컨텍스트: 이 부분은 컴퓨터 과학/AI 분야의 연구 논문에 포함되어 있습니다. 지침: 1. 전문적이고 학문적인 어조를 유지합니다 (예: '습니다/합니다' 또는 간결한 어미 '습니다/입니다'를 적절하게 사용). 2. 글머리 기호(*), 숫자(1.), 또는 수학 변수와 같이 원래 형식을 유지합니다 (해당하는 경우). 3. 설명을 추가하지 마십시오. 번역된 텍스트만 출력하십시오. 입력 텍스트: 저희는 저희 방법이 기존 연구보다 우수한 성능을 정량적(Labels II) 및 정성적(tis..I9)으로 보여주며, 설계 선택 사항을 검증하기 위한 다양한 분석 연구를 수행했습니다 (표). 독자분들께서는 저희 방법이 새로운 시점에서 부드러운 경로를 렌더링할 때 기존 방법보다 얼마나 큰 성능 향상을 보이는지 더 잘 이해하기 위해, 저희의 추가 비디오를 시청해 주시기를 권장합니다.

6. 1. 데이터셋

합성 렌더링 객체에 대한 실험 결과 본 연구에서는 합성 렌더링 객체 데이터셋인 "Diffuse Synthetic 360°" 및 "Realistic Synthetic 360°"에 대한 실험 결과를 제시합니다. DeepVoxels [41] 데이터셋은 간단한 기하학적 구조를 가진 네 개의 램베르트 표면 객체를 포함합니다. 각 객체는 상반구에서 샘플링된 시점에서 512×512 픽셀로 렌더링됩니다 (479개의 시점을 입력으로 사용하고, 테스트에는 1000개의 시점을 사용). 또한, 복잡한 기하학적 구조와 사실적인 비-램베르트 재질을 가진 8개의 객체에 대한 패스트레이싱 이미지를 포함하는 자체 데이터셋을 생성했습니다. 이 데이터셋에서 6개의 객체는 상반구에서 샘플링된 시점에서 렌더링되고, 2개의 객체는 전체 구에서 샘플링된 시점에서 렌더링됩니다. 각 장면에서 100개의 시점을 입력으로 사용하고, 200개의 시점을 테스트에 사용하며, 모든 이미지는 800×800 픽셀로 렌더링됩니다.

Method	Diffuse Synthetic 360° [41]			Realistic Synthetic 360°			Real Forward-Facing [28]		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
SRN [42]	33.20	0.963	0.073	22.26	0.846	0.170	22.84	0.668	0.378
NV [24]	29.62	0.929	0.099	26.05	0.893	0.160	-	-	-
LLFF [28]	34.38	0.985	0.048	24.88	0.911	0.114	24.13	0.798	0.212
Ours	40.15	0.991	0.023	31.01	0.947	0.081	26.50	0.811	0.250

표 1: 본 연구의 방법은 합성 이미지 및 실제 이미지 데이터셋 모두에서 기존 연구보다 정량적으로 우수한 성능을 보입니다. PSNR/SSIM (높을수록 좋음) 및 LPIPS [50] (낮을수록 좋음) 값을 보고합니다. DeepVoxels [41] 데이터셋은 단순한 기하학적 구조를 가진 4개의 확산 객체로 구성됩니다. 본 연구에서 제작한 사실적인 합성 데이터셋은 복잡한 비-램베르티안 재질을 가진 8개의 복잡한 기하학적 구조의 객체에 대한 경로 추적 렌더링으로 구성됩니다. 실제 데이터셋은 8개의 실제 장면을 촬영한 것으로, 핸드헬드 방식으로 촬영되었습니다 (NV는 이 데이터에 대해 평가할 수 없는데, 이는 경계 내부에 있는 객체만 재구성하기 때문입니다). LLFF가 약간 더 나은 LPIPS 값을 달성하지만, 독자들은 본 연구 방법이 다른 기준 모델보다 더 나은 다중 뷰 일관성을 제공하고 더 적은 아티팩트를 생성하는 것을 보여주는 보충 영상을 시청하시기를 권장합니다.

복잡한 장면의 실제 이미지. 우리는 대략 전방을 향한 이미지를 촬영한 복잡한 실제 환경의 결과를 제시합니다 (표 1, "실제 전방 촬영"). 이 데이터 세트는 휴대폰으로 촬영된 8개의 장면으로 구성되어 있으며 (LLFF 논문에서 가져온 5개와 우리가 직접 촬영한 3개), 각 장면은 20~62개의 이미지로 구성되어 있으며, 이 중 1/s는 테스트 세트용으로 사용되었습니다. 모든 이미지의 해상도는 1008 x 756 픽셀입니다.

6.2 비교 분석

"모델의 성능을 평가하기 위해, 현재 최고 성능을 보이는 뷰 합성 기술들과 비교 분석을 진행했으며, 상세 내용은 아래와 같습니다. 모든 방법은 동일한 입력 뷰 세트를 사용하여 각 장면별로 별도의 네트워크를 학습합니다. 단, Local Light Field Fusion [28]은 대규모 데이터셋에 대해 단일 3D 컨볼루션 네트워크를 학습한 후, 학습된 네트워크를 사용하여 테스트 단계에서 새로운 장면의 입력 이미지를 처리합니다."

Neural Volumes (NV)는 특정 배경 앞에 완전히 위치한 객체의 새로운 시점을 합성합니다 (이때, 관심 객체는 별도로 캡처되어야 하며, 배경은 별도로 획득되어야 합니다). 이 방법은 심층 3D 컨볼루션 네트워크를 최적화하여 128° 간격으로 분산된 RGBa 픽셀 그리드와 32° 간격으로 분산된 3D 워프 그리드를 예측합니다. 알고리즘은 워프된 픽셀 그리드를 통과하는 카메라 광선을 사용하여 새로운 시점을 렌더링합니다.

Scene Representation Networks (SRN)는 연속적인 장면을 불투명한 표면으로 표현하며, 각 (x, y, z) 좌표를 특징 벡터로 매핑하는 MLP에 의해 암묵적으로 정의됩니다. SRN은 재귀 신경망을 사용하여 장면 표현을 따라 특정 3D 좌표에서의 특징 벡터를 활용하여, 해당 광선 상의 다음 단계 크기를 예측합니다. 최종 단계에서 얻은 특징 벡터는 해당 표면상의 점에 대한 단일 색상으로 디코딩됩니다. 참고로, SRN은 동일한 저자들이 개발한 DeepVoxels [41]의 성능을 개선한 후속 연구이며, 따라서 DeepVoxels과의 비교는 포함하지 않습니다.



그림 5: 물리 기반 렌더러를 사용하여 생성된 새로운 합성 데이터셋에서 추출한 장면의 테스트 데이터셋 뷰에 대한 비교. 제안하는 방법은 기하학적 특징과 외관 모두에서 미세한 디테일을 복원할 수 있습니다. 예를 들어, 선박의 장비, 레고의 기어 및 트랙, 마이크의 광택이 나는 받침대 및 메시 그릴, 그리고 재료의 비-램베르티안 반사율 등이 있습니다. LLFF는 마이크 받침대와 재료 객체의 가장자리에 밴딩 현상을, 그리고 선박의 돛대 내부 및 레고 객체 내부에는 그림자 현상을 나타냅니다. SRN은 모든 경우에 흐릿하고 왜곡된 렌더링 결과를 생성합니다. Neural Volumes는 마이크 그릴 또는 레고 기어의 디테일을 복원하지 못하며, 선박 장비의 기하학적 구조를 완전히 복원하는 데 실패합니다.




그림 6: 실제 장면의 테스트 데이터셋 뷰에 대한 비교. LLFF는 특히 이러한 용도로 설계되었습니다 (실제 장면의 전방 촬영). 제안하는 방법은 LLFF보다 렌더링된 뷰 전반에 걸쳐 미세한 기하학적 구조를 보다 일관성 있게 표현할 수 있습니다. 예를 들어, Fern 이미지의 잎, T-rex의 뼈대 갈비뼈 및 난간에서 이를 확인할 수 있습니다. 또한, 제안하는 방법은 LLFF가 깨끗하게 렌더링하기 어려운 부분적으로 가려진 영역을 정확하게 재구성합니다. 예를 들어, Fern 이미지 하단 부분의 잎 뒤에 있는 노란색 선반과 Orchid 이미지 하단 부분의 배경에 있는 녹색 잎을 들 수 있습니다. 또한, LLFF는 여러 렌더링을 결합하는 과정에서 반복되는 경계선을 생성할 수 있습니다 (Orchid 이미지 상단 부분에서 확인할 수 있음). SRN은 각 장면의 저주파 기하학적 구조 및 색상 변화를 캡처하지만, 어떠한 미세한 디테일도 재현할 수 없습니다.

로컬 라이트 필드 퓨전 (LLEF) {25/ LLFF는 잘 샘플링된 전방 장면에서 사실적인 새로운 뷰를 생성하기 위해 설계되었습니다. 이는 학습된 3D 컨볼루션 네트워크를 사용하여 각 입력 뷰에 대해 이산화된 프러스텀 샘플링된 RGBa 그리드 (멀티플레인 이미지 또는 MPI [52])를 직접 예측하고, 이후 알파 컴포지팅 및 인접한 MPI들을 새로운 뷰 포인트에 블렌딩하여 새로운 뷰를 렌더링합니다.

6.3 토론

다음은 입력 텍스트의 번역입니다. 저희는 모든 시나리오에서, 장면별로 별도의 네트워크를 최적화하는 기존 방법(NV 및 SRN)보다 훨씬 뛰어난 성능을 보입니다. 또한, 저희는 LLFF보다 질적 및 양적으로 우수한 렌더링 결과를 생성하며, 이를 위해 LLFF의 입력 이미지만을 전체 학습 데이터로 사용했습니다 (모든 지표에서, 단 하나의 지표를 제외하고).

'SRN 방법은 과도하게 부드러운 기하 구조와 텍스처를 생성하며, 뷰 합성 측면에서 표현 능력은 카메라 레이스당 단일 깊이 값과 색상 값을 선택한다는 제한으로 인해 제한됩니다. NV 기준은 비교적 상세한 볼륨 기하 구조와 외관을 캡처할 수 있지만, 128°의 명시적인 픽셀 그리드를 사용하기 때문에 고해상도에서 미세한 디테일을 표현하는 데 어려움이 있습니다. LLFF는 입력 뷰 간의 시차를 64 픽셀을 초과하지 않도록 "샘플링 지침"을 제공하며, 따라서 뷰 간의 시차가 최대 400-500 픽셀에 달하는 합성 데이터셋에서 정확한 기하 구조를 추정하는 데 자주 실패합니다. 또한, LLFF는 다양한 뷰를 렌더링하기 위해 다양한 장면 표현 방식을 혼합하여 사용하며, 이는 보조 영상에서 볼 수 있듯이 시각적으로 산만하게 느껴지는 불일치를 야기합니다.'

'이 방법들 간의 가장 큰 실용적인trade-off는 시간과 공간 복잡도 간의 관계입니다. 비교된 모든 단일 장면(single scene) 방법은 각 장면당 최소 12시간 이상의 훈련 시간이 필요합니다. 반면, LLFF는 작은 입력 데이터셋을 10분 이내에 처리할 수 있습니다. 그러나 LLFF는 각 입력 이미지에 대해 매우 큰 3D 볼륨 그리드를 생성하며, 이는 막대한 저장 공간을 요구합니다 (단일 "현실적인 합성" 장면의 경우 15GB 이상). 저희 방법은 네트워크 가중치에 5MB만 필요하며 (LLFF에 비해 3000배의 압축률), 이는 저희 데이터셋의 어떤 단일 장면의 입력 이미지 자체보다 적은 메모리 용량입니다.

6.4 제거 실험 (Ablation studies)

다음은 영어 학술 논문 텍스트의 한국어 번역입니다. **알고리즘 설계 선택 및 파라미터 검증 (표 [2])** 본 연구에서는 "현실적인 합성 360°" 장면 데이터를 사용하여 알고리즘의 설계 선택과 파라미터를 검증했습니다. 표 2는 실험 결과를 보여줍니다. * 9행은 전체 모델을 기준으로 제시합니다. * 1행은 위치 인코딩(PE), 뷰 의존성(VD), 또는 계층적 샘플링(H)을 포함하지 않은 최소한의 모델 버전을 보여줍니다. * 2-4행에서는 전체 모델에서 세 가지 구성 요소(위치 인코딩, 뷰 의존성, 계층적 샘플링)를 각각 제거하면서 성능 변화를 관찰했습니다. 결과적으로 위치 인코딩(2행)과 뷰 의존성(3행)이 가장 큰 성능 향상을 제공하며, 그 다음으로 계층적 샘플링(4행)이 성능 향상에 기여하는 것을 확인했습니다. * 5-6행은 입력 이미지 수를 줄일 때 알고리즘의 성능이 어떻게 감소하는지를 보여줍니다. 참고로, 본 연구 방법은 입력 이미지가 25개일 때에도, NV, SRN, LLFF 모델이 100개의 이미지를 사용할 때의 성능을 모두 능가하는 것을 보입니다 (자세한 내용은 추가 자료를 참조). * 7-8행에서는 최대 주파수 선택에 대한 검증 결과를 제시합니다.

	Input	#Im.	L	(N_c, N_f)	PSNR↑	SSIM↑	LPIPS↓
1) No PE, VD, H	xyz	100	-	(256, -)	26.67	0.906	0.136
2) No Pos. Encoding	$xyz\theta\phi$	100	-	(64, 128)	28.77	0.924	0.108
3) No View Dependence	xyz	100	10	(64, 128)	27.66	0.925	0.117
4) No Hierarchical	$xyz\theta\phi$	100	10	(256, -)	30.06	0.938	0.109
5) Far Fewer Images	$xyz\theta\phi$	25	10	(64, 128)	27.78	0.925	0.107
6) Fewer Images	$xyz\theta\phi$	50	10	(64, 128)	29.79	0.940	0.096
7) Fewer Frequencies	$xyz\theta\phi$	100	5	(64, 128)	30.59	0.944	0.088
8) More Frequencies	$xyz\theta\phi$	100	15	(64, 128)	30.81	0.946	0.096
9) Complete Model	$xyz\theta\phi$	100	10	(64, 128)	31.01	0.947	0.081

표 2: 본 모델의 성능 분석. 제시된 지표는 실제 합성 데이터셋의 8개 장면에서 얻은 결과를 평균화한 값입니다. 자세한 설명은 6.4절을 참조하십시오.

4. 위치 인코딩에 사용된 값 (최대 주파수, $d=1$ 인 경우에 비례하여 스케일링). 5개의 주파수만 사용하는 경우 성능이 저하되지만, 주파수 개수를 10에서 15로 늘리는 것은 성능 향상에 기여하지 않습니다. L 을 증가시키는 효과는 샘플링된 입력 이미지에 존재하는 최대 주파수(우리 데이터에서는 대략 1024)를 초과할 경우 제한적이라고 판단됩니다.

7. 결론

다음은 입력 텍스트의 번역입니다. 저희 연구는 객체와 장면을 연속 함수로 표현하는 데 사용되는 기존 연구의 한계를 직접적으로 해결합니다. 저희는 장면을 5차원 신경 방사휘도장(3차원 위치와 2차원 시야 방향에 따라 부피 밀도와 시야에 따라 달라지는 방사휘도를 출력하는 다층 퍼셉트론)으로 표현하는 것이, 심층 컨볼루션 신경망을 훈련하여 이산적인 복셀 표현을 출력하는 기존의 주된 방법보다 더 나은 렌더링 결과를 얻는다는 것을 보여줍니다.

다음은 영어 학술 논문 텍스트의 한국어 번역입니다. **계층적 샘플링 전략을 제안하여 렌더링 효율성을 높였습니다 (학습 및 테스트 모두에 해당). 하지만 신경 라디언스 필드를 효율적으로 최적화하고 렌더링하는 기술에 대한 연구는 아직 더 많은 발전이 필요합니다. 향후 연구 방향의 또 다른 측면은 해석 가능성입니다. 3차원 격자 및 메시와 같은 샘플링된 표현은 렌더링된 뷰의 예상 품질 및 오류 모드에 대한 추론을 가능하게 하지만, 딥 신경망의 가중치에 장면을 인코딩할 때 이러한 문제를 어떻게 분석할 수 있을지는 불분명합니다. 본 연구는 실제 이미지를 기반으로 하는 그래픽 파이프라인 개발에 기여하며, 복잡한 장면은 실제 객체 및 장면의 이미지에서 최적화된 신경 라디언스 필드로 구성될 수 있을 것입니다.**

감사의 말씀 본 연구에는 케빈 카오(Kevin Cao), 구웨이 프랭크 양(Guowei Frank Yang), 니틴 라가반(Nithin Raghavan) 님께서 귀중한 의견과 논의를 제공해 주셨습니다. RR은 ONR의 N000141712687 및 N000142012529 연구비 지원 및 로널드 L. 그레이엄 교수 자리를 통해 연구를 수행했습니다. BM은 허츠 재단(Hertz Foundation)의 연구 지원금을 받았으며, MT는 NSF 대학원 연구 지원금을 받았습니다. 구글은 BAIR Commons 프로그램을 통해 상당한 양의 클라우드 컴퓨팅 크레딧을 기부했습니다. 다음 분들께도 감사의 말씀을 드립니다.

블렌드 스왑 사용자에게 저희의 사실적인 합성 데이터셋에 사용된 모델 제작자를 안내합니다: gregzaal (선박), 1DInc (의자), bryanajones (드럼), Herberhold (피쿠스), erickfree (핫도그), Heinzelnisse (레고), elbrujodelatribu (재료), 그리고 up3d.de (마이크).

참고 문헌

1. Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G.S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., Zheng, X.: TensorFlow: 이기종 시스템에서의 대규모 머신러닝 (2015)
2. Buehler, C., Bosse, M., McMillan, L., Gortler, S., Cohen, M.: 구조화되지 않은 루미 그래프 렌더링. In: SIGGRAPH (2001).
3. Chang, A.X., Funkhouser, T., Guibas, L., Hanrahan, P., Huang, Q., Li, Z., Savarese, S., Savva, M., Song, S., Su, H., 외. "Shapenet: An information-rich 3d model repository." arXiv:1512.03012 (2015).
4. Chen, W., Gao, J., Ling, H., Smith, E.J., Lehtinen, J., Jacobson, A., Fidler, S.: 보간 기반 미분 렌더러를 이용한 3D 객체 예측 방법. In: NeurIPS (2019)
5. Cohen, M., Gortler, S.J., Szeliski, R., Grzeszczuk, R., Szeliski, R.: The lumigraph. In: SIGGRAPH (1996).
6. Curless, B., Levoy, M.: 복잡한 모델을 범위 이미지로부터 구축하는 볼륨 기반 방법. In: SIGGRAPH (1996)
7. Davis, A., Levoy, M., Durand, F.: Unstructured light fields. In: Eurographics (2002)
8. Debevec, P., Taylor, C.J., Malik, J.: 사진을 이용한 건축물 모델링 및 렌더링: 하이브리드 기하학 및 이미지 기반 접근 방식. In: SIGGRAPH (1996).
9. Flynn, J., Broxton, M., Debevec, P., DuVall, M., Fyffe, G., Overbeck, R., Snavely, N., Tucker, R.: DeepView: 학습 기반 경사 하강법을 이용한 뷰 합성. In: CVPR (2019)
10. Genova, K., Cole, F., Maschinot, A., Sarna, A., Vlasic, D., Freeman, W.T.: 비지도 학습을 이용한 3D 형태 변환 모델 회귀. In: CVPR (2018)
11. Genova, K., Cole, F., Sud, A., Sarna, A., Funkhouser, T.: Local deep implicit functions for 3d shape. In: CVPR (2020).
12. Henzler, P., Mitra, N.J., Ritschel, T.: 2D 예시로부터 신경망 기반 3D 텍스처 공간 학습. In: CVPR (2020)
13. Henzler, P., Rasche, V., Ropinski, T., Ritschel, T.: 단일 이미지 토모그래피: 2차원 두개골 X-선 이미지로부터 3차원 부피 데이터 생성. In: Eurographics (2018).
14. Hornik, K., Stinchcombe, M., White, H.: 다층 피드포워드 신경망은 범용 근사기로 작용한다. *Neural Networks* (1989).
15. Jiang, C., Sud, A., Makadia, A., Huang, J., NieSner, M., Funkhouser, T.: 로컬 임플리시트 그리드 표현을 이용한 3D 장면 모델링. In: CVPR (2020).
16. Kajiya, J.T., Herzen, B.P.V.: Ray tracing volume densities. Computer Graphics (SIGGRAPH) (1984).
17. Kar, A., Hane, C., Malik, J.: 다중 시점 입체 기계 학습. NeurIPS (2017) 발표 논문.
18. Kingma, D.P., Ba, J.: Adam: A method for stochastic optimization. In: ICLR (2015).

16. B. Mildenhall, P. P. Srinivasan, M. Tancik 외.

19. Kutulakos, K.N., Seitz, S.M.: A theory of shape by space carving. International Journal of Computer Vision (2000).

20. Levoy, M.: 볼륨 데이터의 효율적인 레이 트레이싱. ACM Transactions on Graphics (1990).

21. Levoy, M., Hanrahan, P.: Light field rendering. In: SIGGRAPH (1996).

22. Li, T.M., Aittala, M., Durand, F., Lehtinen, J.: 엣지 샘플링을 통한 미분 가능한 몬테 카를로 레이 트레이싱. ACM Transactions on Graphics (SIGGRAPH Asia) (2018).

23. Liu, S., Li, T., Chen, W., Li, H.: Soft rasterizer: A differentiable renderer for image-based 3D reasoning. In: ICCV (2019).

24. Lombardi, S., Simon, T., Saragih, J., Schwartz, G., Lehrmann, A., Sheikh, Y.: Neural volumes: Learning dynamic renderable volumes from images. ACM Transactions on Graphics (SIGGRAPH) (2019).

25. Loper, M.M., Black, M.J.: OpenDR: 근사 미분 렌더러. In: ECCV (2014)

26. Max, N.: 광학 모델을 이용한 직접 볼륨 렌더링. IEEE Transactions on Visualization and Computer Graphics (1995).

27. Mescheder, L., Oechsle, M., Niemeyer, M., Nowozin, S., Geiger, A.: Occupancy networks: Learning 3D reconstruction in function space. In: CVPR (2019).

28. Mildenhall, B., Srinivasan, P.P., Ortiz-Cayon, R., Kalantari, N.K., Ramamoorthi, R., Ng, R., Kar, A.: Local light field fusion: Practical view synthesis with prescriptive sampling guidelines. ACM Transactions on Graphics (SIGGRAPH) (2019).

29. Niemeyer, M., Mescheder, L., Oechsle, M., Geiger, A.: Differentiable volumetric rendering: Learning implicit 3D representations without 3D supervision. In: CVPR (2019).

30. Nimier-David, M., Vicini, D., Zeltner, T., Jakob, W.: Mitsuba 2: A retargetable forward and inverse renderer. ACM Transactions on Graphics (SIGGRAPH Asia) (2019)

31. Oechsle, M., Mescheder, L., Niemeyer, M., Strauss, T., Geiger, A.: Texture fields: Learning texture representations in function space. In: ICCV (2019).

32. Park, J.J., Florence, P., Straub, J., Newcombe, R., Lovegrove, S.: DeepSDF: 연속적인 부호 거리 함수 학습을 통한 형상 표현. In: CVPR (2019).

33. Penner, E., Zhang, L.: Soft 3D reconstruction for view synthesis. ACM Transactions on Graphics (SIGGRAPH Asia) (2017).

34. Porter, T., Duff, T.: Compositing digital images. Computer Graphics (SIGGRAPH) (1984).

35. Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F.A., Bengio, Y., Courville, A.C.: 신경망의 스펙트럴 편향에 대하여. ICML (2018) 발표 논문.

36. Rainer, G., Ghosh, A., Jakob, W., Weyrich, T.: 통합 신경 인코딩을 이용한 BTF 표현. Computer Graphics Forum (Eurographics) (2020).

37. Rainer, G., Jakob, W., Ghosh, A., Weyrich, T.: 신경망 기반 BTF 압축 및 보간. Computer Graphics Forum (Eurographics) (2019).

38. Ren, P., Wang, J., Gong, M., Lin, S., Tong, X., Guo, B.: 전역 조명에 대한 방사선 회귀 함수 활용. *ACM Transactions on Graphics* (2013).

39. Schénberger, J.L., Frahm, J.

40. Seitz, S.M., Dyer, C.R.: 복셀 색상화를 이용한 사실적인 장면 복원. International Journal of Computer Vision (1999).

41. Sitzmann, V., Thies, J., Heide, F., Nießner, M., Wetzstein, G., Zollhöfer, M.: Deep-voxels: 학습 가능한 지속적인 3차원 특징 임베딩. In: CVPR (2019)

42. Sitzmann, V., Zollhoefer, M., Wetzstein, G.: Scene representation networks: 연속적인 3차원 구조 인지 신경망 기반 장면 표현. In: NeurIPS (2019)

43. Srinivasan, P.P., Tucker, R., Barron, J.T., Ramamoorthi, R., Ng, R., Snavely, N.: 다중 평면 이미지를 이용한 시야 확장 기술의 한계 극복. In: CVPR (2019).
44. Stanley, K.O.: 구성적 패턴 생성 네트워크: 발달의 새로운 추상화. 유전 프로그래밍 및 진화 가능한 기계 (2007).
45. Szeliski, R., Golland, P.: 입체 매칭 알고리즘: 투명도 및 매칭 적용. In: ICCV (1998)
46. Tulsiani, S., Zhou, T., Efros, A.A., Malik, J.: 다중 시점 감독을 이용한 단일 시점 재구성: 미분 가능한 광선 일관성. In: CVPR (2017)
47. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: Attention is all you need. In: NeurIPS (2017)
48. Waechter, M., Moehle, N., Goesele, M.: Let there be color!. 3차원 재구성의 대규모 텍스처링. In: ECCV (2014).
49. Wood, D.N., Azuma, D.I., Aldinger, K., Curless, B., Duchamp, T., Salesin, D.H., Stuetzle, W.: Surface light fields for 3D photography. In: SIGGRAPH (2000).
50. Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: 심층 특징이 시각적 측정 기준으로 얼마나 효과적인가. In: CVPR (2018)
51. Zhong, E.D., Bepler, T., Davis, J.H., Berger, B.: Cryo-EM 이미지를 기반으로 3차원 단백질 구조의 연속적인 분포를 재구성하는 연구. In: ICLR (2020)
52. Zhou, T., Tucker, R., Flynn, J., Fyffe, G., Snavely, N.: Stereo magnification: 다중 평면 이미지를 이용한 뷰 합성 학습. ACM Transactions on Graphics (SIGGRAPH) (2018).

“ A. 추가 구현 세부 사항 ”

Network 아키텍처 (그림 7)는 저희가 제안하는 간단한 완전 연결(fully-connected) 구조에 대한 상세 내용을 보여줍니다. .

볼륨 경계 (Volume Bounds) 본 방법은 카메라 광선에 따른 연속적인 5차원 좌표에서 뉴럴 방사 성분 필드(neural radiance field) 표현을 쿼리하여 뷰를 렌더링합니다. 합성 이미지 실험에서는 장면의 크기를 조정하여 원점을 중심으로 하는 2의 변 길이의 정육면체 안에 포함되도록 하고, 이 경계 볼륨 내에서만 표현을 쿼리합니다. 실제 이미지 데이터셋은 가장 가까운 지점부터 무한대까지 어디에든 존재할 수 있는 내용을 포함하므로, 정규화된 장치 좌표를 사용하여 이러한 지점의 깊이 범위를 $[1, 1]$ 범위로 매핑합니다. 이를 통해 모든 광선 기원이 장면의 가장 가까운 평면으로 이동되고, 카메라의 원근 광선이 변환된 볼륨에서 평행 광선으로 매핑되며, 거리(inverse depth)가 거리 대신 사용되므로, 모든 좌표가 이제 경계 내에 포함됩니다.

훈련 세부 사항 실제 장면 데이터의 경우, 최적화 과정에서 출력 값 0에 평균이 0이고 분산이 1인 임의의 가우시안 노이즈를 추가하여 네트워크를 정규화합니다. 이를 통해 새로운 뷰를 렌더링하는 데 있어 시각적 성능이 약간 향상되는 것을 확인했습니다. 저희 모델은 Tensorflow를 사용하여 구현되었습니다.

렌더링 상세 정보: 테스트 시 새로운 뷰를 렌더링하기 위해, 우리는 coarse 네트워크를 통해 1개의 광선당 64개의 점을, 그리고 fine 네트워크를 통해 1개의 광선당 $64 + 128 = 192$ 개의 점을 샘플링합니다. 이는 1개의 광선당 총 256번의 네트워크 쿼리를 수행하는 것을 의미합니다. 우리의 사실적인 합성 데이터...




그림 7: 우리의 완전 연결 네트워크 아키텍처 시각화. 입력 벡터는 녹색으로, 중간 은닉층은 파란색으로, 출력 벡터는 빨간색으로 표시됩니다. 각 블록 내의 숫자는 벡터의 차원을 나타냅니다. 모든 층은 표준 완전 연결 층이며, 검은색 화살표는 ReLU 활성화 함수를 사용하는 층을, 주황색 화살표는 활성화 함수가 없는 층을, 점선 검은색 화살표는 시그모이드 활성화 함수를 사용하는 층을 나타냅니다. "+" 기호는 벡터 연결을 의미합니다. 입력 위치($y(\mathbf{x})$)의 위치 인코딩은 8개의 완전 연결 ReLU 층을 거치며, 각 층은 256개의 채널을 가집니다. 우리는 DeepSDF [32] 아키텍처를 따르며, 이 입력 값을 다섯 번째 층의 활성화 값과 연결하는 스킵 연결을 포함합니다. 추가적인 층은 부피 밀도 σ (ReLU를 사용하여 0이 아닌 양수로 만드는)와 256차원 특징 벡터를 출력합니다. 이 특징 벡터는 입력 시야 방향($\gamma(\mathbf{d})$)의 위치 인코딩과 연결되고, 추가적인 완전 연결 ReLU 층 (128개 채널)을 거칩니다. 마지막 층 (시그모이드 활성화 함수 사용)은 방향 $\mathbf{d}$ 를 가진 광선에 의해 관찰되는 위치 $\mathbf{x}$ 에서의 방출되는 RGB 광도를 출력합니다.

데이터셋은 이미지당 64만 개의 광선을 필요로 하며, 실제 장면은 이미지당 76만 2천 개의 광선을 필요로 하여, 렌더링된 이미지당 1억 5천만 개에서 2억 개의 네트워크 쿼리가 발생합니다. NVIDIA V100 GPU를 사용했을 때, 이는 프레임당 약 30초의 시간이 소요됩니다.

B. 추가적인 기준 방법 상세 설명

Neural Volumes (NV) 저희는 저자들이 공개적으로 배포한 NV 코드를 사용합니다 (<https://github.com/facebookresearch/neuralvolumes>). 또한, 시간 의존성을 고려하지 않고 단일 장면에서 학습하는 과정을 따릅니다.

장면 표현 네트워크 (SRN) 본 연구에서는 저자들이 공개한 SRN 코드를 사용합니다 (<https://github.com/vsitzmann/scene-representation-n>). 또한, 단일 장면 데이터셋에 대한 학습 과정은 저자들의 방법을 따릅니다.

로컬 라이트 필드 퓨전 (LLFF) [25]: 본 연구에서는 저자들이 <https://github.com/Fyusion/LLFF> 에서 공개한 사전 훈련된 LLFF 모델을 사용합니다.

양적 비교 SRN 구현은 저자들이 발표한 내용에 따르면 상당한 양의 GPU 메모리를 요구하며, 4개의 NVIDIA V100 GPU를 활용한 병렬 처리 시에도 이미지 해상도가 512 x 512 픽셀로 제한됩니다. 본 연구에서는 합성 데이터셋에 대해 SRN의 성능을 512 x 512 픽셀에서, 실제 데이터셋에 대해 504 x 376 픽셀에서 평가했습니다. 이는 다른 방법들이 지원하는 더 높은 해상도인 800 x 800 및 1008 x 752와 비교한 결과입니다.

C NDC (Coordinate Normalization Device) 레이 스페이스 도출

다음은 입력 텍스트의 번역입니다. 삼각형 래스터화 파이프라인에서 일반적으로 사용되는 정규화된 장치 좌표(NDC) 공간에서 "전방향" 캡처를 사용하여 실제 장면을 재구성합니다. 이 공간은 z축(카메라 축)을 시차에 대해 선형적으로 변환하는 동시에 평행선을 유지하므로 편리합니다.

다음에서, 카메라 공간에서 NDC 공간으로 광선을 매핑하기 위해 적용되는 변환을 유도합니다. 균일 좌표를 사용하는 표준적인 3차원 투영 행렬은 다음과 같습니다.

$$M = \begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \quad (7)$$

여기서 n 과 f 는 각각 근거리 및 원거리 클리핑 평면을 나타내고, r 과 t 는 근거리 클리핑 평면에서의 장면의 오른쪽 및 위쪽 경계를 나타냅니다. (참고: 여기서는 카메라가 $-z$ 방향을 향하는 관습을 사용합니다.) 동차 좌표를 갖는 점 $(x, y, z, 1)$ 을 투영하기 위해서는, M 행렬을 왼쪽에서 곱한 후 네 번째 좌표로 나눕니다.

$$\begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{n}{r}x \\ \frac{n}{t}y \\ \frac{-(f+n)}{f-n}z - \frac{2fn}{f-n} \\ -z \end{pmatrix} \quad (8)$$

$$\text{project} \rightarrow \begin{pmatrix} \frac{n}{r} \frac{x}{-z} \\ \frac{n}{t} \frac{y}{-z} \\ \frac{(f+n)}{f-n} - \frac{2fn}{f-n} \frac{1}{-z} \end{pmatrix} \quad (9)$$

투영된 점은 현재 정규화된 장치 좌표(NDC) 공간에 위치하며, 여기서 원래의 뷰 프러스텀은 $[-1, 1] \times$ 큐브로 매핑되었습니다.

우리의 목표는 주어진 광선 $o+td$ 를 받아, NDC 공간에서 광선 기점 o' 와 방향 d' 를 계산하는 것입니다. 이를 통해, 모든 t 에 대해, $\gamma(o + td) = o' + t'd'$ (여기서 γ 은 위에서 언급된 행렬을 사용한 투영)을 만족하는 새로운 t' 가 존재하도록 합니다. 다시 말해, 원래 광선의 투영과 NDC 공간에서의 광선 추적은 동일한 점들을 나타내지만 (반드시 동일한 비율로 표현되는 것은 아님).

다음과 같이 Eqn.pjas (QzX/Z, Ay Y/2, az+0z/2) 형태의 투영 점을 재정의하겠습니다. 새로운 원점 $\mathbf{o}'$ 와 방향 벡터 $\mathbf{d}'$ 의 구성 요소는 다음 조건을 만족해야 합니다.

$$\begin{pmatrix} a_x \frac{o_x + td_x}{o_z + td_z} \\ a_y \frac{o_y + td_y}{o_z + td_z} \\ a_z + \frac{b_z}{o_z + td_z} \end{pmatrix} = \begin{pmatrix} o'_x + t' d'_x \\ o'_y + t' d'_y \\ o'_z + t' d'_z \end{pmatrix}. \quad (10)$$

Lo, 자유도를 줄이기 위해, 우리는 $t' = 0$ 과 $\phi = 0$ 이 동일한 지점으로 매핑되도록 결정했습니다. $t = 0$ 과 $t' = 0$ 을 방정식 [10]에 대입하면, NDC 공간의 원점 $\mathbf{o}$ 를 직접적으로 얻을 수 있습니다.

$$\mathbf{o}' = \begin{pmatrix} o'_x \\ o'_y \\ o'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x}{o_z} \\ a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z} \end{pmatrix} = \pi(\mathbf{o}). \quad (11)$$

다음은 원래 광선의 시작점의 투영 7(o)입니다. 이 값을 방정식 10에 대입하여 임의의 t 값에 대해 t' 와 $\mathbf{d}'$ 의 값을 결정할 수 있습니다.

$$\begin{pmatrix} t' d'_x \\ t' d'_y \\ t' d'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x + td_x}{o_z + td_z} - a_x \frac{o_x}{o_z} \\ a_y \frac{o_y + td_y}{o_z + td_z} - a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z + td_z} - a_z - \frac{b_z}{o_z} \end{pmatrix} \quad (12)$$

$$= \begin{pmatrix} a_x \frac{o_z(o_x + td_x) - o_x(o_z + td_z)}{(o_z + td_z)o_z} \\ a_y \frac{o_z(o_y + td_y) - o_y(o_z + td_z)}{(o_z + td_z)o_z} \\ b_z \frac{o_z - (o_z + td_z)}{(o_z + td_z)o_z} \end{pmatrix} \quad (13)$$

$$= \begin{pmatrix} a_x \frac{td_z}{o_z + td_z} \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \frac{td_z}{o_z + td_z} \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{td_z}{o_z + td_z} \frac{1}{o_z} \end{pmatrix} \quad (14)$$

다음과 같은 공통 표현식을 분리하면, 이는 오직 ϕ 에만 의존하는 식을 의미합니다.

$$t' = \frac{td_z}{o_z + td_z} = 1 - \frac{o_z}{o_z + td_z} \quad (15)$$

$$\mathbf{d}' = \begin{pmatrix} a_x \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{1}{o_z} \end{pmatrix}. \quad (16)$$

참고로, 원하는 경우, $\phi = 0$ 일 때 $t' = 0$ 이 됩니다. 또한, t 가 무한대로 증가함에 따라 t' 는 1보다 커지는 것을 확인할 수 있습니다. 원래 투영 행렬로 돌아가면, 우리의 상수 값은 다음과 같습니다.

$$a_x = -\frac{n}{r} \quad (17)$$

$$a_y = -\frac{n}{t} \quad (18)$$

$$a_z = \frac{f + n}{f - n} \quad (19)$$

$$b_z = \frac{2fn}{f - n} \quad (20)$$

표준 핀홀 카메라 모델을 활용하여, 다음과 같이 a 를 재정의할 수 있습니다.

$$a_x = -\frac{f_{cam}}{W/2} \quad (21)$$

$$a_y = -\frac{f_{cam}}{H/2} \quad (22)$$

다음과 같이 번역합니다. 여기서 W 와 H 는 이미지의 폭과 높이를 픽셀 단위로 나타내며, f_{cam} 은 카메라의 초점 거리를 나타냅니다.

다음은 입력 텍스트의 번역입니다. 실제 전방 촬영 데이터에서, 우리는 원거리 장면의 경계가 무한대라고 가정합니다 (이는 NDC가 z 차원을 사용하여 역 깊이, 즉 시차를 표현하기 때문에 큰 부담이 되지 않습니다). 이러한 조건에서, z 상수 값은 다음과 같이 단순화됩니다:

$$a_z = 1 \quad (23)$$

$$b_z = 2n. \quad (24)$$

다음 내용을 종합하여:

$$\mathbf{o}' = \begin{pmatrix} -\frac{f_{cam}}{W/2} \frac{o_x}{o_z} \\ -\frac{f_{cam}}{H/2} \frac{o_y}{o_z} \\ 1 + \frac{2n}{o_z} \end{pmatrix} \quad (25)$$

$$\mathbf{d}' = \begin{pmatrix} -\frac{f_{cam}}{W/2} \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ -\frac{f_{cam}}{H/2} \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -2n \frac{1}{o_z} \end{pmatrix}. \quad (26)$$

다음은 구현 과정에서 고려해야 할 마지막 세부 사항입니다. 우리는 광선의 근단면($z = -n$)과의 교차점에서 o 값을 tnd 를 더한 값($0 = 0 + tnd$)으로 이동시킵니다. 여기서 $t = -(n + 0)/d$ 입니다. 이렇게 NDC 광선으로 변환한 후, 우리는 t' 값을 0부터 1까지 선형적으로 샘플링하여, 원래 공간에서 n 부터 무한대까지의 불일치(disparity)를 선형적으로 샘플링할 수 있습니다.




그림 8: Deep Voxels 합성 데이터셋의 장면들에 대한 테스트 데이터셋 뷰 비교. 이 데이터셋의 객체들은 단순한 기하학적 구조와 완벽하게 확산되는 반사 특성을 가집니다. 입력 이미지의 수가 많고 (479개의 뷰) 렌더링된 객체의 단순성으로 인해, 저희 방법과 LLFF [28] 모두 이 데이터에 대해 거의 완벽한 성능을 보입니다. LLFF는 여전히 3D 볼륨 간의 보간 과정에서 가끔씩 아티팩트를 나타냅니다 (각 객체에 대한 상단 삽입 그림 참조). SRN과 NV는 미세한 디테일을 렌더링할 수 있는 표현력을 가지고 있지 않습니다.

추가 결과

장면별 분석: 'Labels|3}/4}{5} 및 |6j는 본 논문에서 제시된 전체적인 정량적 결과들을 각 장면별 지표로 세분화한 것입니다. 장면별 분석 결과는 본 논문에서 제시된 전체적인 정량적 지표와 일관성을 유지하며, 저희 방법이 모든 기준 모델보다 정량적으로 우수한 성능을 보입니다. LLFF가 LPIPS 지표에서 약간 더 나은 결과를 보이는 반면, 독자 여러분께서는 저희 방법이 기준 모델보다 더 나은 다중 뷰 일관성을 제공하며, 더 적은 아티팩트를 생성하는 것을 보여주는 보충 영상 자료를 시청해 주시기 바랍니다.

	PSNR↑				SSIM↑				LPIPS↓			
	Chair	Pedestal	Cube	Vase	Chair	Pedestal	Cube	Vase	Chair	Pedestal	Cube	Vase
DeepVoxels [41]	33.45	32.35	28.42	27.99	0.99	0.97	0.97	0.96	—	—	—	—
SRN [42]	36.67	35.91	28.74	31.46	0.982	0.957	0.944	0.969	0.093	0.081	0.074	0.044
NV [24]	35.15	36.47	26.48	20.39	0.980	0.963	0.916	0.857	0.096	0.069	0.113	0.117
LLFF [28]	36.11	35.87	32.58	32.97	0.992	0.983	0.983	0.983	0.051	0.039	0.064	0.039
Ours	42.65	41.44	39.19	37.32	0.991	0.986	0.996	0.992	0.047	0.024	0.006	0.017

표 3: DeepVoxels [41] 데이터셋의 장면별 정량적 결과. 이 데이터셋의 "장면"은 모두 단순한 기하학적 구조를 가진 확산 객체이며, 3D 스캐너로 캡처된 텍스처 매핑 메시로부터 렌더링되었습니다. DeepVoxels 방법의 측정 지표는 해당 논문에서 직접 가져왔으며, LPIPS는 보고하지 않고 SSIM은 소수점 이하 두 자리까지 보고합니다.

	PSNR↑							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	26.96	17.18	20.73	26.81	20.85	18.09	26.85	20.60
NV [24]	28.33	22.58	24.79	30.71	26.08	24.22	27.78	23.93
LLFF [28]	28.72	21.13	21.79	31.41	24.54	20.72	27.48	23.22
Ours	33.00	25.01	30.13	36.18	32.54	29.62	32.91	28.65

	SSIM↑							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	0.910	0.766	0.849	0.923	0.809	0.808	0.947	0.757
NV [24]	0.916	0.873	0.910	0.944	0.880	0.888	0.946	0.784
LLFF [28]	0.948	0.890	0.896	0.965	0.911	0.890	0.964	0.823
Ours	0.967	0.925	0.964	0.974	0.961	0.949	0.980	0.856

	LPIPS↓							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	0.106	0.267	0.149	0.100	0.200	0.174	0.063	0.299
NV [24]	0.109	0.214	0.162	0.109	0.175	0.130	0.107	0.276
LLFF [28]	0.064	0.126	0.130	0.061	0.110	0.117	0.084	0.218
Ours	0.046	0.091	0.044	0.121	0.050	0.063	0.028	0.206

표 4: 실제와 유사한 합성 데이터셋에 대한 장면별 정량적 결과. 이 데이터셋의 "장면"은 보다 복잡한 기하학 구조와 비-람베르트 재질을 가진 객체들로 구성되어 있으며, Blender의 Cycles 레이 트레이싱 렌더링을 통해 생성되었습니다.

PSNR↑								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	27.29	21.37	18.24	26.63	17.37	24.63	22.87	24.33
LLFF [28]	28.42	22.85	19.52	29.40	18.52	25.46	24.15	24.70
Ours	32.70	25.17	20.92	31.16	20.36	27.40	26.80	27.45

SSIM↑								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	0.883	0.611	0.520	0.641	0.449	0.738	0.761	0.742
LLFF [28]	0.932	0.753	0.697	0.872	0.588	0.844	0.857	0.840
Ours	0.948	0.792	0.690	0.881	0.641	0.827	0.880	0.828

LPIPS↓								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	0.240	0.459	0.440	0.453	0.467	0.288	0.298	0.376
LLFF [28]	0.155	0.247	0.216	0.173	0.313	0.174	0.222	0.193
Ours	0.178	0.280	0.316	0.171	0.321	0.219	0.249	0.268

표 95: 실제 이미지 데이터셋에서 추출한 장면별 정량적 결과. 이 데이터셋에 포함된 장면들은 모두 전면 카메라를 장착한 휴대폰으로 촬영되었습니다.

		PSNR↑							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	28.44	23.11	25.17	32.24	26.38	24.69	28.16	25.12
2)	No Pos. Encoding	30.33	24.54	29.32	33.16	27.75	27.79	30.76	26.55
3)	No View Dependence	30.06	23.41	25.91	32.65	29.93	24.96	28.62	25.72
4)	No Hierarchical	31.32	24.55	29.25	35.24	31.42	29.22	31.74	27.73
5)	Far Fewer Images	30.92	22.62	24.39	32.77	27.97	26.55	30.47	26.57
6)	Fewer Images	32.19	23.70	27.45	34.91	31.53	28.54	32.33	27.67
7)	Fewer Frequencies	32.19	25.29	30.73	36.06	30.77	29.77	31.66	28.26
8)	More Frequencies	32.87	24.65	29.92	35.78	32.50	29.54	32.86	28.34
9)	Complete Model	33.00	25.01	30.13	36.18	32.54	29.62	32.91	28.65

		SSIM↑							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	0.919	0.896	0.926	0.955	0.882	0.905	0.955	0.810
2)	No Pos. Encoding	0.938	0.918	0.953	0.956	0.903	0.933	0.968	0.824
3)	No View Dependence	0.948	0.906	0.938	0.961	0.947	0.912	0.962	0.828
4)	No Hierarchical	0.951	0.914	0.956	0.969	0.951	0.944	0.973	0.844
5)	Far Fewer Images	0.956	0.895	0.922	0.966	0.930	0.925	0.972	0.832
6)	Fewer Images	0.963	0.911	0.948	0.971	0.957	0.941	0.979	0.847
7)	Fewer Frequencies	0.959	0.928	0.965	0.972	0.947	0.952	0.973	0.853
8)	More Frequencies	0.967	0.921	0.962	0.973	0.961	0.948	0.980	0.853
9)	Complete Model	0.967	0.925	0.964	0.974	0.961	0.949	0.980	0.856

		LPIPS↓							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	0.095	0.168	0.084	0.104	0.178	0.111	0.084	0.261
2)	No Pos. Encoding	0.076	0.104	0.050	0.124	0.128	0.079	0.041	0.261
3)	No View Dependence	0.075	0.148	0.113	0.112	0.088	0.102	0.073	0.220
4)	No Hierarchical	0.065	0.177	0.056	0.130	0.072	0.080	0.039	0.249
5)	Far Fewer Images	0.058	0.173	0.082	0.123	0.081	0.079	0.035	0.229
6)	Fewer Images	0.051	0.166	0.057	0.121	0.055	0.068	0.029	0.223
7)	Fewer Frequencies	0.055	0.143	0.038	0.087	0.071	0.060	0.029	0.219
8)	More Frequencies	0.047	0.158	0.045	0.116	0.050	0.064	0.027	0.261
9)	Complete Model	0.046	0.091	0.044	0.121	0.050	0.063	0.028	0.206

표 6: 본 연구의 분석(ablations)을 통해 얻은 장면별 정량적 결과. 여기에서 사용된 장면은 표 [4]에 제시된 장면과 동일합니다.