

070
7
SNV
€ [
AD'
S®]
ZAP
E68
0' C
OOT
:AT
KIL

NeRF: 장면을 신경망 방사 휘도장(Neural Radiance Fields)으로 표현하여 시점
합성 기술 구현.

벤 밀덴할, 프라툴 P. 스리니바산, 매튜 탄칙, 조나단 T. 배런, 라비
라마무르티, 렌 네.

UC 버클리 * 구글 연구소 * UC 샌디에이고

초록: 본 논문에서는 복잡한 장면의 새로운 시점을 합성하는 데 있어 최첨단 성능을 달성하는 방법을 제시합니다. 이 방법은 희소한 입력 시점 집합을 사용하여, 기본이 되는 연속적인 3차원 장면 함수를 최적화합니다. 제안하는 알고리즘은 완전 연결(컨볼루션 기반이 아닌) 심층 신경망을 사용하여 장면을 표현합니다. 이 신경망의 입력은 단일 연속적인 5차원 좌표(공간 위치 (x, y, z) 및 시야 방향 (θ))이며, 출력은 해당 공간 위치에서의 부피 밀도와 시야에 따라 달라지는 방사 휘도입니다. 우리는 카메라 광선을 따라 5차원 좌표를 쿼리하고, 고전적인 부피 렌더링 기법을 사용하여 출력된 색상과 밀도를 이미지로 투영하여 새로운 시점을 합성합니다. 부피 렌더링은 본질적으로 미분 가능하므로, 우리의 표현 방식을 최적화하는 데 필요한 입력은 알려진 카메라 자세를 가진 이미지 집합뿐입니다. 우리는 복잡한 기하학적 구조와 외관을 가진 장면의 사실적인 새로운 시점을 렌더링하기 위해 신경망 방사 휘도 필드를 효과적으로 최적화하는 방법을 설명하고, 신경망 렌더링 및 시점 합성 분야의 기존 연구보다 뛰어난 결과를 보여줍니다. 시점 합성 결과는 동영상으로 시청하는 것이 가장 효과적이므로, 독자 여러분께서는 설득력 있는 비교를 위해 저희가 제공하는 추가 동영상을 시청해 주시기 바랍니다.

키워드: 장면 표현, 뷰 합성, 이미지 기반 렌더링, 볼륨 렌더링, 3D 딥러닝.

1. 서론

본 연구에서는 기존의 뷰 합성 문제를 새롭게 접근하여, 캡처된 이미지들을 렌더링할 때 발생하는 오류를 최소화하기 위해 연속적인 5차원 장면 표현의 파라미터를 직접 최적화하는 방법을 제시합니다.

저희는 정적인 장면을, 공간상의 각 지점 (x, y, z) 에서 각 방향 (θ, ϕ) 으로 방출되는 복사량을 나타내는 연속적인 5차원 함수로 표현합니다. 또한, 각 지점에서 복사량이 얼마나 쌓이는지를 조절하는 미분 투과율 역할을 하는 밀도를 정의합니다. 저희의 방법은 이 함수를 표현하기 위해, 컨볼루션 레이어가 없는 심층 완전 연결 신경망(Multilayer Perceptron 또는 MLP라고도 함)을 최적화합니다. 이 신경망은 단일 5차원 좌표 (x, y, z, θ) 를 입력으로 받아 단일 부피 밀도와 시점(view)에 따라 달라지는 RGB 색상을 출력합니다. 이러한 신경망 기반 복사 필드(Neural Radiance Field, NeRF)를 사용하여 렌더링을 수행합니다.




그림 1: 우리는 입력 이미지 세트로부터 3차원 장면을 나타내는 연속적인 5차원 신경망 방사휘도 필드(연속적인 위치에서의 부피 밀도 및 시점 의존 색상)를 최적화하는 방법을 제시합니다. 우리는 이 장면 표현의 샘플을 광선(rays)을 따라 누적하여, 어떤 시점에서도 장면을 렌더링하기 위해 볼륨 렌더링 기술을 사용합니다. 여기서는, 합성된 드럼 장면의 주변 반구에서 무작위로 촬영된 100개의 입력 시점을 시각화하고, 우리의 최적화된 NeRF 표현을 사용하여 렌더링된 두 가지 새로운 시점을 보여줍니다.

특정 관점에서 보면, 우리는 다음과 같은 과정을 거칩니다. 1) 장면 내에서 카메라 광선을 따라 이동하며 3차원 점들의 집합을 생성하고, 2) 이러한 점들과 해당 2차원 시야 방향을 신경망의 입력으로 사용하여 색상과 밀도의 집합을 생성하며, 3) 기존의 볼륨 렌더링 기술을 사용하여 이러한 색상과 밀도를 2차원 이미지로 합성합니다. 이 과정은 자연스럽게 미분 가능하므로, 각 관찰된 이미지와 우리가 생성한 표현으로부터 얻은 해당 이미지 간의 오차를 최소화하여 그래디언트 하강법을 사용하여 이 모델을 최적화할 수 있습니다. 여러 시점에서 이 오차를 최소화하는 것은 신경망이 장면의 일관성 있는 모델을 예측하도록 유도하며, 이를 위해 실제 장면 내용을 포함하는 위치에 높은 볼륨 밀도와 정확한 색상을 할당하도록 합니다. 그림 [2]는 이러한 전체적인 과정을 시각적으로 보여줍니다.

복잡한 장면을 표현하는 신경망 방사휘도 필드(Neural Radiance Field)를 최적화하는 기본적인 구현 방식은 충분히 높은 해상도의 표현으로 수렴하지 않으며, 카메라 광선 당 필요한 샘플 수 측면에서 비효율적이라는 것을 확인했습니다. 이러한 문제점을 해결하기 위해, 입력 5차원 좌표를 위치 인코딩을 통해 변환하여 다층 퍼셉트론(MLP)이 더 높은 주파수의 함수를 표현할 수 있도록 하고, 이 고주파 장면 표현을 적절하게 샘플링하기 위해 필요한 쿼리 수를 줄이는 계층적 샘플링 방식을 제안합니다.

저희의 접근 방식은 볼륨 기반 표현 방식의 장점을 활용합니다. 이 방식은 복잡한 현실 세계의 기하 구조와 외관을 표현하는 데 적합하며, 투영된 이미지를 이용한 경사 기반 최적화에도 잘 어울립니다. 특히, 저희의 방법은 고해상도로 복잡한 장면을 모델링할 때 발생하는, 이산화된 복셀 그리드의 저장 비용 문제를 해결합니다. 요약하자면, 저희의 주요 기술적 기여는 다음과 같습니다.

- 복잡한 기하 구조와 재질을 가진 연속적인 장면을 5차원 뉴럴 방사 휘도장(neural radiance fields)으로 표현하는 방법. 이 방법은 기본적인 다층 퍼셉트론(MLP) 네트워크를 기반으로 합니다.
- 기존 볼륨 렌더링 기술을 기반으로 하는 미분 가능 렌더링 방식을 사용하며, 이를 통해 표준 RGB 이미지에서 얻은 데이터를 최적화하여 표현합니다. 특히, 이 방식은 신경망(MLP)의 성능을 효율적으로 활용하기 위해, 시야에 보이는 장면의 영역에 집중적으로 자원을 할당하는 계층적 샘플링 전략을 포함합니다.

- 각 입력 데이터의 좌표를 고차원 공간에 매핑하는 위치 인코딩 방식을 사용하여, 신경망 방사선 필드를 성공적으로 최적화하여 고주파 장면 정보를 표현할 수 있습니다.

저희는 개발한 신경망 기반 광선 필드 방법이 최첨단 뷰 합성 방법들을 능가하며, 특히 자연 환경에서 촬영된 RGB 이미지를 기반으로 실제 객체와 장면의 고해상도, 사실적인 새로운 시점을 생성하는 데 탁월한 성능을 보인다는 것을 입증했습니다. 현재까지 알려진 바로는, 본 논문은 자연 환경에서 촬영된 RGB 이미지를 이용하여 실제 객체와 장면의 고해상도, 사실적인 새로운 시점을 렌더링할 수 있는 최초의 연속적인 신경망 기반 장면 표현 방식을 제시합니다. 또한, 신경망 기반 3D 표현을 장면 데이터에 적용하거나, 심층 컨볼루션 신경망을 훈련하여 샘플링된 볼륨 데이터 표현을 예측하는 기존 연구들보다 우수한 성능을 보입니다.

2. 관련 연구

최근 컴퓨터 비전 분야에서 주목받는 연구 방향 중 하나는 객체와 장면을 다층 퍼셉트론(MLP)의 가중치에 저장하는 것입니다. 이 방법은 3차원 공간 좌표를 받아 해당 위치의 형상을 나타내는 간접적인 표현, 예를 들어 부호 거리 [6]를 직접 매핑합니다. 그러나 이러한 방법은 현재까지 복잡한 기하 구조를 가진 현실적인 장면을 삼각형 메시나 복셀 격자와 같은 이산적인 표현 방식을 사용하는 기술과 동일한 수준의 정확도로 재현하는 데 어려움을 겪고 있습니다. 본 섹션에서는 이러한 두 가지 연구 방향을 살펴보고, 저희가 제안하는 접근 방식과 비교하여 복잡하고 현실적인 장면을 렌더링하는 데 있어 최첨단 결과를 얻을 수 있도록 신경망 기반 장면 표현의 기능을 향상시키는 방법을 설명하겠습니다.

저차원 좌표를 색상으로 변환하는 데 다층 퍼셉트론(MLP)을 사용하는 유사한 방식은 이미지[44], 질감 있는 재료[12, 31, 136, 137] 및 간접 조명 값[38]과 같은 다른 그래픽 기능을 표현하는 데에도 활용되었습니다.

최근 연구에서는 심층 신경망을 활용하여 xyz 좌표를 부호 거리 함수[15, 32] 또는 점유 필드[11, 32]에 매핑함으로써, 연속적인 3차원 형상을 암묵적으로 표현하는 방법을 연구해 왔습니다. 하지만 이러한 모델은 일반적으로 ShapeNet과 같은 합성 3차원 형상 데이터셋에서 얻은 실제 3차원 형상 정보가 필요하다는 제약이 있습니다. 이후 연구에서는 이러한 제약을 완화하기 위해, 신경망을 활용한 암묵적인 3차원 형상 표현을 2차원 이미지만을 사용하여 최적화할 수 있도록 미분 가능한 렌더링 함수를 제안했습니다. Niemeyer et al.은 표면을 3차원 점유 필드로 표현하고, 각 광선에 대해 수치적 방법을 사용하여 표면과의 교점을 찾은 후, 암묵적인 미분법을 사용하여 정확한 미분값을 계산합니다. 각 교점의 위치는 신경망 기반의 3차원 텍스처 필드에 입력으로 제공되며, 해당 지점의 확산색을 예측합니다. Sitzmann et al.은 좀 더 간접적인 신경망 기반의 3차원 표현 방식을 사용하며, 각 연속적인 3차원 좌표에서 특징 벡터와 RGB 색상을 출력합니다. 또한, 각 광선을 따라 이동하면서 표면의 위치를 결정하는 순환 신경망으로 구성된 미분 가능한 렌더링 함수를 제안합니다.

"이러한 기술들은 복잡하고 고해상도의 형상을 표현할 잠재력을 가지고 있지만, 현재까지는 단순한 형태와 낮은 기하학적 복잡성을 가진 객체에만 적용되어 왔으며, 결과적으로 과도하게 부드러운 렌더링 결과를 초래합니다. 본 연구에서는 5차원 방사 휘도 필드(3차원 볼륨)를 인코딩하기 위해 네트워크를 최적화하는 대체 전략을 제시합니다."

(2차원 시점 의존적인 외형을 가진) 이 기술은 더 높은 해상도의 기하 구조와 외형을 표현하여 복잡한 장면의 사실적인 이미지를 생성할 수 있습니다.

뷰 합성 및 이미지 기반 렌더링: 다수의 뷰 정보를 활용하여, 간단한 광학 필드 샘플 보간 기술을 통해 사실적인 새로운 뷰를 재구성할 수 있습니다 [21, 5, 7]. 뷰 정보가 상대적으로 적은 환경에서의 새로운 뷰 합성을 위해, 컴퓨터 비전 및 그래픽 분야에서는 관찰된 이미지로부터 기존의 기하학적 구조 및 외관 특징을 예측하는 기술이 상당한 발전을 이루었습니다. 널리 사용되는 방법 중 하나는 장면을 메시 기반으로 표현하며, 이 때 메시의 외관은 확산 특성을 가지거나 [48] 시점에 따라 달라지는 특성을 가질 수 있습니다 [2, 18, 49]. 미분 가능한 래스터화 또는 경로 추적 기술 [22, 30]을 사용하여, 그래디언트 하강법을 통해 메시 표현을 직접 최적화하여 입력 이미지 집합을 재현할 수 있습니다. 그러나 이미지 재투영 기반의 메시 최적화는 종종 어려움을 겪는데, 이는 손실 함수의 지역 최소값 또는 불량한 조건 때문에 발생할 가능성이 높습니다. 또한, 이러한 전략은 최적화 전에 고정된 토폴로지를 가진 템플릿 메시를 초기값으로 제공해야 하지만, 이는 제약 없는 실제 환경에서는 일반적으로 사용할 수 없습니다.

또 다른 방법론은 입력된 RGB 이미지 집합으로부터 고품질의 사실적인 뷰 합성을 수행하기 위해 볼륨 표현 방식을 사용합니다. 볼륨 기반 접근 방식은 복잡한 형태와 재질을 사실적으로 표현할 수 있으며, 그래디언트 기반 최적화에 적합하고, 메시 기반 방법보다 시각적으로 방해되는 현상을 덜 발생시키는 경향이 있습니다. 초기 볼륨 기반 접근 방식은 관찰된 이미지를 사용하여 3차원 픽셀 격자를 직접 색칠했습니다 [1940/45]. 최근에는 여러 연구에서 대규모 데이터셋을 사용하여 딥 네트워크를 훈련시켜 입력 이미지 집합으로부터 샘플링된 볼륨 표현을 예측하고, 테스트 시에 알파 블렌딩 또는 학습된 블렌딩 방식을 사용하여 새로운 뷰를 생성합니다. 다른 연구에서는 합성곱 신경망(CNN)과 샘플링된 3차원 픽셀 격자를 특정 장면마다 조합하여 최적화하며, 이를 통해 CNN이 저해상도 픽셀 격자에서 발생하는 이산화 현상을 보완하거나, 예측된 픽셀 격자가 입력 시간 또는 애니메이션 제어에 따라 변하도록 합니다 [24]. 이러한 볼륨 기반 기술은 새로운 뷰 합성에 있어 뛰어난 결과를 보여주었지만, 더 높은 해상도의 이미지로 확장하는 데는 근본적인 한계가 있습니다. 이는 이산적인 샘플링 방식 때문에 시간 및 공간 복잡도가 낮기 때문이며, 더 높은 해상도의 이미지를 생성하려면 3차원 공간을 더 세밀하게 샘플링해야 합니다. 우리는 이 문제를 해결하기 위해 딥 완전 연결 신경망의 파라미터 내에 연속적인 볼륨을 포함시키는 방식을 사용했습니다. 이 방식은 기존의 볼륨 기반 접근 방식보다 훨씬 높은 품질의 렌더링 결과를 제공할 뿐만 아니라, 샘플링된 볼륨 표현 방식에 비해 훨씬 적은 저장 공간을 필요로 합니다.

신경 방사 필드(Neural Radiance Field)를 이용한 장면 표현 방식.

저희는 연속적인 장면을 다음과 같이 표현합니다. 입력값은 3차원 위치 $x = (a, y, z)$ 와 2차원 시야 방향 (θ, ϕ) 이며, 출력값은 방출되는 색상 $c = (r, g, b)$ 와 부피 밀도 ρ_c 로 표현되는 벡터 함수로 나타냅니다. 실제로는 다음과 같이 표현합니다.




그림 2: 저희가 개발한 뉴럴 방사형 필드(Neural Radiance Field)를 이용한 장면 표현 방식과 미분 가능한 렌더링 절차에 대한 개요입니다. 저희는 카메라 광선을 따라 5차원 좌표(위치 및 시야 방향)를 샘플링하여 이미지를 생성합니다 (a). 이러한 위치 정보를 다층 퍼셉트론(MLP)에 입력하여 색상과 볼륨 밀도를 생성합니다 (b). 그런 다음, 볼륨 렌더링 기술을 사용하여 이러한 값을 결합하여 이미지를 생성합니다 (c). 이 렌더링 함수는 미분 가능하므로, 생성된 이미지와 실제 관측된 이미지 간의 잔차를 최소화하여 장면 표현 방식을 최적화할 수 있습니다 (d).

방향을 3차원 데카르트 좌표계의 단위 벡터 d 로 표현합니다. 이 연속적인 5차원 장면 표현을 MLP(Multi-Layer Perceptron) 신경망 $F_\Theta: (x, d) \rightarrow (c, \sigma)$ 를 사용하여 근사하고, 각 입력 5차원 좌표를 해당 부피 밀도와 방향으로 방출되는 색상으로 매핑하도록 신경망의 가중치 Θ 를 최적화합니다.

저희는 네트워크가 부피 밀도 ' σ '를 위치 ' x '에만 의존하는 함수로 예측하도록 제한하면서, RGB 색상 ' c '는 위치와 시야 방향 모두에 의존하는 함수로 예측할 수 있도록 하여, 다중 시점에서 일관성을 유지하는 표현을 장려합니다. 이를 위해, MLP (Multilayer Perceptron)는 먼저 입력된 3차원 좌표 ' x '를 8개의 완전 연결 계층(ReLU 활성화 함수 사용, 각 계층당 256 채널)을 통해 처리하고, ' σ '와 256차원 특징 벡터를 출력합니다. 이 특징 벡터는 카메라 광선의 시야 방향과 연결되어, 추가적인 완전 연결 계층(ReLU 활성화 함수 사용, 128 채널)으로 전달되며, 이를 통해 시야에 따라 달라지는 RGB 색상이 출력됩니다.

(그림 [5]을 참조하시면) 저희 방법이 시야 방향을 활용하여 램베르트 법칙을 따르지 않는 현상을 표현하는 예시를 확인할 수 있습니다. 그림 4에서 볼 수 있듯이, 시야 의존성 없이 (x 값만 입력으로 사용하여) 학습된 모델은 반사광 표현에 어려움을 겪습니다.

4. 방사 필드를 이용한 4차원 렌더링 기술

저희의 oD 신경망 기반 광선 필드는 공간상의 모든 지점을 부피 밀도와 해당 지점에서 방출되는 광선으로 표현합니다. 우리는 고전적인 부피 렌더링 원리를 사용하여 장면을 통과하는 모든 광선의 색상을 렌더링합니다. 부피 밀도 $\sigma(x)$ 는 위치 x 에서 매우 작은 입자에서 광선이 끝날 확률을 나타낼 수 있습니다. 카메라 광선 $r(t) = o + td$ (여기서 t 는 근거리 및 원거리 경계를 나타냄)의 예상 색상 $C(r)$ 은 다음과 같습니다.

$$C(r) = \int_{t_n}^{t_f} T(t) \sigma(r(t)) c(r(t), d) dt, \text{ where } T(t) = \exp\left(-\int_{t_n}^t \sigma(r(s)) ds\right). \quad (1)$$




그림 3: 시야에 따라 달라지는 방사광의 시각화. 저희의 신경망 기반 방사광 필드 표현 방식은 공간 위치 x 와 시야 방향 d 를 5차원 함수로 표현하여 RGB 색상을 출력합니다. 여기서는 저희의 신경망 표현 방식에 따른 배(Ship) 장면의 두 가지 공간 위치에 대한 시야 방향별 색상 분포를 시각화했습니다. (a)와 (b)에서는 배의 측면(주황색 삽입 부분)과 물 표면(파란색 삽입 부분)에 위치한 두 개의 고정된 3차원 지점의 모습을 서로 다른 카메라 위치에서 촬영한 모습을 보여줍니다. 저희의 방법은 이러한 두 개의 3차원 지점의 시각적인 변화를 예측하며, (c)에서는 이러한 변화가 시야 방향의 전체 반구에 걸쳐 어떻게 연속적으로 나타나는지 보여줍니다.

함수 $J'(t)$ 는 t_n 에서 t 까지의 광선 경로를 따라 누적된 투과율을 나타냅니다. 즉, 광선이 t 에서 t 까지 다른 입자와 충돌하지 않고 이동할 확률을 의미합니다. 우리의 연속적인 신경망 방사휘도 필드에서 뷰를 생성하려면, 원하는 가상 카메라의 각 픽셀을 통과하는 광선에 대한 이 적분 $C(r)$ 을 추정해야 합니다.


우리는 이 연속적인 적분을 수치적으로 근사하기 위해 수치 적분법을 사용합니다. 일반적으로 이산화된 복셀 그리드를 렌더링하는 데 사용되는 결정론적 수치 적분법은 MLP가 고정된 이산적인 위치에서만 값을 계산하도록 하여, 우리의 표현 방식의 해상도를 제한할 수 있습니다. 대신, 우리는 계층화된 샘플링 방식을 사용합니다. 이 방식에서는 구간 $[t_1, t_2]$ 를 N 개의 균등하게 분할된 구간으로 나누고, 각 구간 내에서 무작위로 하나의 샘플을 추출합니다.

$$t_i \sim \mathcal{U}\left[t_n + \frac{i-1}{N}(t_f - t_n), t_n + \frac{i}{N}(t_f - t_n)\right]. \quad (2)$$

우리는 적분 값을 추정하기 위해 일정한 샘플 집합을 사용하지만, 계층화된 샘플링 방식은 최적화 과정에서 MLP(Multi-Layer Perceptron)가 연속적인 위치에서 평가되도록 하여 연속적인 장면 표현을 가능하게 합니다. 우리는 이 샘플들을 사용하여 맥스(Max)가 작성한 볼륨 렌더링 관련 논문에서 언급된 사분법 규칙에 따라 $C(r)$ 값을 추정합니다.

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^N T_i(1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i, \text{ where } T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right), \quad (3)$$

여기서 δ_i 는 $t_{i+1} - t_i$ 이며, 이는 인접한 샘플 간의 거리를 나타냅니다. $C(r)$ 을 계산하는 이 함수는 미분하기 쉬우며, 알파 값 $\alpha_i = 1 - \exp(-\sigma_i \delta_i)$ 을 사용하는 전통적인 알파 합성 방식으로 단순화될 수 있습니다.



진실의 근원.

Complete Model

뷰 의존성 없음, 위치 인코딩 없음.

그림 4: 여기서는 저희의 전체 모델이 시점 의존적인 방출 광도를 표현하고, 입력 좌표를 고주파 위치 인코딩을 통해 처리함으로써 어떤 이점을 얻는지 시각적으로 보여줍니다. 시점 의존성을 제거하면 모델이 불도저 트랙의 반사광을 재현하는 것을 방지할 수 있습니다. 반면, 위치 인코딩을 제거하면 모델의 고주파 기하학적 구조와 질감을 표현하는 능력이 크게 저하되어, 결과적으로 표면이 지나치게 매끄럽게 보이는 현상이 발생합니다.

9. 신경 방사 필드 최적화.

이전 섹션에서는 신경망 방사휘도 필드(neural radiance field)로 장면을 모델링하고, 이 표현 방식을 사용하여 새로운 시점을 렌더링하는 데 필요한 핵심 구성 요소를 설명했습니다. 그러나 6.4절에서 보여준 것처럼, 이러한 구성 요소만으로는 최첨단 수준의 품질을 달성하기에 충분하지 않다는 것을 확인했습니다. 따라서 고해상도 복잡한 장면을 표현할 수 있도록 두 가지 개선 방안을 제시합니다. 첫 번째는 입력 좌표의 위치 인코딩으로, 이는 다층 퍼셉트론(MLP)이 고주파 함수를 표현하는 데 도움을 줍니다. 두 번째는 계층적 샘플링 절차로, 이를 통해 이 고주파 표현을 효율적으로 샘플링할 수 있습니다.

5.1 위치 인코딩

신경망은 범용 함수 근사기(universal function approximator)라는 사실에도 불구하고, 저희는 네트워크가 $xyz \in \mathbb{R}^3$ 입력 좌표에 직접 작용할 때, 색상과 형상의 고주파 변화를 정확하게 표현하는 데 어려움이 있다는 것을 발견했습니다. 이는 Rahaman 등[35]의 최근 연구 결과와 일치하는데, 해당 연구에서는 심층 신경망이 낮은 주파수의 함수를 학습하는 경향이 있다는 것을 보여줍니다. 또한, 입력값을 네트워크에 전달하기 전에 고주파 함수를 사용하여 더 높은 차원의 공간으로 매핑하면, 고주파 변화를 포함하는 데이터에 대한 더 나은 적합성을 얻을 수 있다는 것을 보여줍니다.

우리는 이러한 연구 결과를 신경망 기반의 장면 표현 방식에 적용하여, Fo 함수를 두 개의 함수, 즉 학습 가능한 함수와 학습 불가능한 함수로 분해하여 표현하는 방식이 성능을 크게 향상시킨다는 것을 보여줍니다 (그림 및 표 2 참조). 여기서 γ 는 $\mathbb{R}$ 공간에서 더 높은 차원의 공간 $\mathbb{R}^L$ 으로의 매핑 함수이며, F_6 는 여전히 일반적인 다층 퍼셉트론(MLP)입니다. 보다 구체적으로, 저희가 사용하는 인코딩 함수는 다음과 같습니다.

$$\gamma(p) = (\sin(2^0 \pi p), \cos(2^0 \pi p), \dots, \sin(2^{L-1} \pi p), \cos(2^{L-1} \pi p)). \quad (4)$$

이 함수 $\gamma(\cdot)$ 은 x 축의 세 가지 좌표 값(각 값은 $[-1, 1]$ 범위로 정규화됨)과 세 가지 구성 요소에 각각 적용됩니다.

데카르트 좌표계에서 시야 방향을 나타내는 단위 벡터 d (이는 $[-1, 1]$ 범위 내에 있습니다). 저희 실험에서는 $y(x)$ 에 대해 $L = 10$, 그리고 $y(d)$ 에 대해 $L = 4$ 로 설정했습니다.

유사한 매핑 방식은 인기 있는 트랜스포머(Transformer) 아키텍처(참조: [47])에서도 사용되며, 이 경우 "위치 인코딩(positional encoding)"이라고 불립니다. 하지만 트랜스포머는 이 방식을 사용하여 시퀀스 내 토큰의 개별적인 위치 정보를 아키텍처에 입력으로 제공하며, 이 아키텍처는 순서에 대한 개념을 포함하지 않습니다. 반면, 우리는 이러한 함수들을 사용하여 연속적인 입력 좌표를 더 높은 차원의 공간으로 매핑함으로써, 우리의 다층 퍼셉트론(MLP)이 더 쉽게 높은 주파수의 함수를 근사화할 수 있도록 합니다. 관련 연구에서는 3차원 단백질 구조를 투영 데이터로부터 모델링하는 문제에서도 유사한 입력 좌표 매핑 방식을 사용합니다.

0.2 계층적 볼륨 샘플링.

저희가 사용하는 렌더링 방식은 각 카메라 광선에 따라 N 개의 샘플 지점에서 신경망 기반 방사선 필드를 평가하는 방식으로, 비효율적입니다. 렌더링된 이미지에 영향을 미치지 않는 빈 공간이나 가려진 영역도 계속해서 샘플링되기 때문입니다. 우리는 초기 볼륨 렌더링 연구 [20]에서 영감을 받아, 최종 렌더링 결과에 미치는 예상 효과에 비례하여 샘플 수를 할당하는 계층적 표현 방식을 제안합니다. 이를 통해 렌더링 효율성을 높일 수 있습니다.

장면을 단일 네트워크로만 표현하는 대신, 우리는 두 개의 네트워크, 즉 "거친(coarse)" 네트워크와 "정밀(fine)" 네트워크를 동시에 최적화합니다. 먼저, 계층화된 샘플링을 사용하여 N 개의 위치를 선택하고, 식 (A) 및 (B)에 설명된 대로 이 위치에서 "거친" 네트워크를 평가합니다. 이렇게 평가된 "거친" 네트워크의 결과를 바탕으로, 각 광선(ray)을 따라 샘플링할 지점을 더욱 정확하게 선택합니다. 이때, 샘플링은 해당 볼륨의 관련 부분에 더 집중되도록 설계됩니다. 이를 위해, 먼저 "거친" 네트워크에서 얻은 알파 블렌딩된 색상을 식 (3)에 제시된 대로, 광선을 따라 샘플링된 모든 색상 c_i 의 가중 합으로 다시 표현합니다.

$$\hat{C}_c(\mathbf{r}) = \sum_{i=1}^{N_c} w_i c_i, \quad w_i = T_i(1 - \exp(-\sigma_i \delta_i)). \tag{5}$$

이러한 가중치를 $Ww_i = 1/30 \times w_i$ 로 정규화하면, 광선(ray)을 따라 일정한 값을 갖는 확률 밀도 함수(PDF)가 생성됩니다. 이 분포로부터 두 번째 샘플 집합을 추출하기 위해 역변환 샘플링을 사용하고, 첫 번째와 두 번째 샘플 집합의 합집합에 대해 "세밀한" 네트워크를 평가한 후, 식 [3]을 사용하여 광선 $C(x)$ 의 최종 렌더링 색상을 계산합니다. 이때 모든 $N + N_y$ 개의 샘플을 사용합니다. 이 절차는 시각적으로 보이는 내용이 포함될 것으로 예상되는 영역에 더 많은 샘플을 할당합니다. 이는 중요 샘플링과 유사한 목표를 가지지만, 각 샘플을 전체 적분의 독립적인 확률 추정치로 취급하는 대신, 추출된 값을 전체 적분 영역의 불균일한 이산화로 활용합니다.

0.d 구현 세부 사항

각 장면마다 별도의 신경망 기반의 연속적인 볼륨 표현 네트워크를 최적화합니다. 이 과정에는 장면의 RGB 이미지를 촬영한 데이터 세트만 필요합니다.

해당 카메라의 자세, 내부 파라미터, 그리고 장면 경계 정보를 사용합니다 (합성 데이터의 경우, 실제 데이터의 경우 COLMAP 구조-운동 패키지를 사용하여 이러한 파라미터를 추정합니다). 각 최적화 반복 과정에서, 데이터셋의 모든 픽셀에서 무작위로 샘플링된 일괄 데이터를 선택하고, 섹션에서 설명된 계층적 샘플링 방식을 따릅니다. 우리는 조잡한 네트워크에서 N_V 개의 샘플과 정밀 네트워크에서 $N + N_f$ 개의 샘플을 가져옵니다. 그런 다음, 섹션 4에서 설명된 볼륨 렌더링 절차를 사용하여, 두 가지 샘플 집합으로부터 각 광선의 색상을 렌더링합니다. 우리의 손실 함수는 조잡한 렌더링과 정밀 렌더링 모두에서 렌더링된 픽셀 색상과 실제 픽셀 색상 간의 제곱 오차의 총합입니다.

$$\mathcal{L} = \sum_{\mathbf{r} \in \mathcal{R}} \left[\left\| \hat{C}_c(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 + \left\| \hat{C}_f(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 \right] \quad (6)$$

여기서 $\mathcal{R}$ 은 각 배치에 속하는 광선들의 집합이며, $C(\mathbf{r})$, $\hat{C}_c(\mathbf{r})$, 그리고 $\hat{C}_f(\mathbf{r})$ 는 각각 광선 $\mathbf{r}$ 에 대한 실제 색상, 대략적인 부피 예측 색상, 그리고 정밀한 부피 예측 색상을 나타냅니다. 최종 렌더링 결과는 $\hat{C}_f(\mathbf{r})$ 에서 나오지만, 대략적인 부피 예측 색상 $\hat{C}_c(\mathbf{r})$ 의 손실을 최소화하여, 대략적인 네트워크에서 얻은 가중치 분포를 정밀한 네트워크에서 샘플 할당에 활용할 수 있도록 합니다.

저희 실험에서는 4096개의 광선을 사용하며, 각 광선은 조잡한 볼륨에서 64개의 좌표, 그리고 정밀한 볼륨에서 128개의 추가 좌표에서 샘플링됩니다. 최적화 과정에서는 Adam 옵티마이저를 사용하며, 학습률은 5×10^{-4} 에서 시작하여 최적화 과정 동안 지수적으로 5×10^{-5} 로 감소합니다 (다른 Adam 하이퍼파라미터는 기본값인 $\beta_1 = 0.9$, $\beta_2 = 0.999$, 그리고 $\epsilon = 10^{-7}$ 으로 설정). 단일 장면의 최적화는 일반적으로 NVIDIA V100 GPU 한 대에서 약 100만에서 300만 번의 반복을 거쳐 수렴하며, 이는 약 1~2일 정도 소요됩니다.

6. 결과

저희는 정량적(레이블 II) 및 정성적(qualitative) 측면에서 6) 저희 방법이 기존 연구보다 우수함을 보여드리며, 설계 결정의 타당성을 검증하기 위한 다양한 분석 결과를 제시합니다(표). 독자 여러분께서는 저희 방법이 기존 방식에 비해 새로운 시점을 부드럽게 표현하는 데 얼마나 큰 개선을 가져왔는지 더 잘 이해하기 위해, 저희가 제공하는 추가 영상 자료를 시청해 주시기 바랍니다.

6.1 데이터셋

인공적으로 생성된 객체 이미지에 대한 실험 결과를 먼저 보여드리겠습니다. "디퓨즈 합성 360도(Diffuse Synthetic 360°)" 및 "현실적인 합성 360도(Realistic Synthetic 360°)"라는 두 가지 데이터셋을 사용했습니다. DeepVoxels [41] 데이터셋은 단순한 기하학 구조를 가진 네 개의 램베르트 표면 객체를 포함하고 있습니다. 각 객체는 상반구에서 무작위로 선택된 시점에서 512×512 픽셀로 렌더링됩니다 (입력 데이터는 479개, 테스트 데이터는 1000개). 또한, 저희는 복잡한 기하학 구조와 현실적인 비-램베르트 재질을 가진 여덟 개의 객체에 대한 패스트레이싱 이미지를 포함하는 자체 데이터셋을 생성했습니다. 이 중 여섯 개는 상반구에서 무작위로 선택된 시점에서 렌더링되었고, 두 개는 전체 구에서 무작위로 선택된 시점에서 렌더링되었습니다. 각 장면에서 100개의 시점을 입력 데이터로 사용하고, 200개의 시점을 테스트 데이터로 사용했으며, 모든 이미지는 800×800 픽셀로 렌더링되었습니다.

Method	Diffuse Synthetic 360° [41]			Realistic Synthetic 360°			Real Forward-Facing [28]		
	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓	PSNR↑	SSIM↑	LPIPS↓
SRN [42]	33.20	0.963	0.073	22.26	0.846	0.170	22.84	0.668	0.378
NV [24]	29.62	0.929	0.099	26.05	0.893	0.160	-	-	-
LLFF [28]	34.38	0.985	0.048	24.88	0.911	0.114	24.13	0.798	0.212
Ours	40.15	0.991	0.023	31.01	0.947	0.081	26.50	0.811	0.250

표 1: 저희 방법은 합성 이미지와 실제 이미지 데이터셋 모두에서 기존 연구보다 수치적으로 우수한 성능을 보입니다. 저희는 PSNR/SSIM (값이 높을수록 좋음)과 LPIPS [50] (값이 낮을수록 좋음) 값을 보고합니다. DeepVoxels [41] 데이터셋은 단순한 기하학적 구조를 가진 4개의 객체로 구성되어 있습니다. 저희가 만든 사실적인 합성 데이터셋은 복잡한 비-램베르티안 재질을 가진 8개의 복잡한 기하학적 구조의 객체에 대한 경로 추적 렌더링으로 구성되어 있습니다. 실제 데이터셋은 8개의 실제 장면을 촬영한 것으로, 손으로 들고 촬영한 전방향 이미지입니다 (NV는 이 데이터에 대해 평가할 수 없습니다. 왜냐하면 NV는 특정 영역 내의 객체만 재구성하기 때문입니다). LLFF가 약간 더 나은 LPIPS 값을 달성하지만, 독자들은 저희 방법이 다른 방법들보다 더 나은 다중 뷰 일관성을 제공하고 더 적은 아티팩트를 생성하는 것을 보여주는 추가 비디오를 시청해 주시기 바랍니다.

복잡한 장면 재구성: 저희는 실제 환경에서 촬영된 복잡한 장면들을 보여드리며, 이 장면들은 주로 정면으로 촬영된 이미지들로 구성되어 있습니다 (표 1, "실제 정면 촬영"). 이 데이터셋은 휴대폰으로 촬영된 8개의 장면으로 구성되어 있으며, 각 장면은 20~62개의 이미지로 이루어져 있습니다 (LLFF 논문에서 가져온 5개 장면과 저희가 직접 촬영한 3개 장면). 테스트 데이터셋은 전체 이미지의 1/3을 사용합니다. 모든 이미지의 해상도는 1008 x 756 픽셀입니다.

6.2 비교 분석

"저희 모델의 성능을 평가하기 위해, 현재 최고 수준의 뷰 합성 기술들과 비교 분석을 진행했습니다. 자세한 내용은 아래에 설명되어 있습니다. 모든 방법은 동일한 입력 뷰 데이터를 사용하여 각 장면마다 별도의 네트워크를 학습합니다. 단, Local Light Field Fusion [28]은 대규모 데이터셋을 사용하여 하나의 3D 컨볼루션 네트워크를 학습한 후, 학습된 네트워크를 사용하여 테스트 단계에서 새로운 장면의 입력 이미지를 처리합니다."

Neural Volumes (NV)는 특정 배경 앞에 완전히 위치한 객체의 새로운 시점을 생성하는 기술입니다. 이 기술은 관심 대상 객체를 제외한 배경을 별도로 촬영한 후, 128° 간격으로 샘플링된 RGBa 3차원 보폭 격자 및 32° 간격으로 샘플링된 3차원 변형 격자를 예측하기 위해 심층 3차원 컨볼루션 신경망을 최적화합니다. 알고리즘은 변형된 보폭 격자를 통해 카메라 광선을 투사하여 새로운 시점을 생성합니다.

신경망 기반 장면 표현(Scene Representation Networks, SRN)은 연속적인 장면을 불투명한 표면으로 표현하며, 각 (x, y, z) 좌표를 특징 벡터로 매핑하는 다층 퍼셉트론(MLP)에 의해 암묵적으로 정의됩니다. SRN은 순환 신경망을 사용하여 장면 표현을 따라 특정 3차원 좌표에서의 특징 벡터를 기반으로 광선(ray)을 따라 다음 단계의 크기를 예측합니다. 최종 단계에서 얻은 특징 벡터는 해당 표면상의 지점에 대한 단일 색상으로 변환됩니다. 참고로, SRN은 동일한 연구진이 개발한 DeepVoxels [41]의 개선된 버전이며, DeepVoxels와의 비교는 생략했습니다.



그림 5: 저희가 물리 기반 렌더러를 사용하여 생성한 새로운 합성 데이터셋의 장면들을 테스트 데이터셋에서 확인한 결과 비교. 저희 방법은 선박의 돛대, 레고 장치의 기어와 트랙, 마이크의 반짝이는 받침대 및 메시 그릴, 그리고 재료의 램베르트 반사율이 아닌 반사 특성 등, 기하학적 구조와 외관 모두에서 미세한 디테일을 복원할 수 있습니다. LLFF는 마이크 받침대와 재료 물체의 가장자리에서 줄무늬 현상을, 선박의 돛대 및 레고 물체 내부에서 그림자 현상을 보입니다. SRN은 모든 경우에 흐릿하고 왜곡된 렌더링 결과를 생성합니다. Neural Volumes는 마이크 그릴 또는 레고 기어의 디테일을 포착하지 못하며, 선박 돛대의 기하학적 구조를 복원하는 데 완전히 실패합니다.



그림 6: 실제 장면의 테스트 데이터셋에서 얻은 다양한 시점 비교. LLFF는 특히 이러한 용도(실제 장면의 전방 촬영)를 위해 설계되었습니다. 제 방법은 LLFF보다 렌더링된 다양한 시점에서 더 일관성 있게 미세한 형상을 표현할 수 있습니다. 그림에서 보이는 "페른" 잎의 세부 묘사, "티-렉스"의 뼈대 갈비뼈 및 난간 등이 그 예입니다. 또한, 저희 방법은 LLFF가 제대로 렌더링하기 어려운 부분적으로 가려진 영역도 정확하게 재구성합니다. 예를 들어, "페른" 이미지 하단부에 있는 노란색 선반이나 "오키드" 이미지 하단부의 배경에 있는 녹색 잎 등이 있습니다. 다양한 렌더링 결과를 결합하는 과정에서 LLFF는 반복적인 가장자리를 생성할 수 있습니다. 이는 "오키드" 이미지 상단부에서 볼 수 있습니다. SRN은 각 장면에서 나타나는 저주파의 형상 및 색상 변화를 포착하지만, 미세한 디테일을 재현하는 데는 한계가 있습니다.

로컬 라이트 필드 퓨전(Local Light Field Fusion, LLFF) 기술은 잘 촬영된 전방 시야의 장면에서 사실적인 새로운 시점을 생성하도록 설계되었습니다. 이 기술은 훈련된 3차원 컨볼루션 신경망을 사용하여 각 입력 시점에 대해 이산화된 원근 사각 프리즘으로 샘플링된 RGBa 그리드(멀티플레인 이미지 또는 MPI)를 직접 예측합니다. 그런 다음, 알파 블렌딩을 통해 주변 MPI들을 결합하여 새로운 시점을 렌더링합니다.

6.3 토론

저희 연구 결과는 각 장면마다 별도의 네트워크를 사용하는 기존 방식(NV 및 SRN)보다 모든 시나리오에서 압도적으로 우수한 성능을 보입니다. 또한, 저희는 LLFF 방식과 비교했을 때, 거의 모든 성능 지표에서 더 뛰어난 결과물을 생성하며, 동시에 LLFF에서 사용된 입력 이미지만을 저희의 전체 학습 데이터로 사용했습니다.

"SRN 방법은 매우 부드러운 기하 구조와 질감을 생성하지만, 뷰 합성 능력이 카메라 광선당 하나의 깊이와 색상 정보만 사용한다는 제한 때문에 제한적입니다. NV 기본 방법은 비교적 상세한 입체 기하 구조와 외관을 표현할 수 있지만, 128°의 명시적인 3차원 격자 구조를 사용하기 때문에 고해상도에서 미세한 디테일을 표현하는 데 어려움이 있습니다. LLFF는 입력 뷰 간의 시차(disparity)가 64 픽셀을 초과하지 않도록 "샘플링 지침"을 제공합니다. 따라서 뷰 간의 시차가 최대 400-500 픽셀에 달하는 합성 데이터셋에서 정확한 기하 구조를 추정하는 데 자주 실패합니다. 또한, LLFF는 다양한 뷰를 렌더링하기 위해 서로 다른 장면 표현 방식을 혼합하여 사용하는데, 이는 시각적으로 혼란을 야기하는 일관성 없는 결과를 초래하며, 이는 저희의 추가 영상에서 확인할 수 있습니다."

이러한 방법들 간의 가장 큰 실용적인 차이점은 시간과 공간 복잡도입니다. 비교된 모든 단일 장면 기반 방법은 장면당 최소 12시간의 훈련 시간이 필요합니다. 반면, LLFF는 상대적으로 작은 입력 데이터 세트를 10분 이내에 처리할 수 있습니다. 그러나 LLFF는 모든 입력 이미지에 대해 매우 큰 3차원 복셀 그리드를 생성하므로, 엄청난 저장 공간이 필요합니다 (단일 "현실적인 합성" 장면의 경우 15GB 이상). 저희 방법은 네트워크 가중치에 5MB 밖에 필요하지 않습니다 (LLFF에 비해 3000배 더 압축 효율적), 이는 저희 데이터 세트의 어떤 장면에서도 입력 이미지 자체보다 훨씬 적은 메모리 용량입니다.

6.4 제거 실험 연구

표 [2]에서 저희 알고리즘의 설계 선택 사항 및 파라미터들을 광범위한 분석을 통해 검증했습니다. 저희는 "현실적인 합성 360°" 장면에서의 결과를 제시합니다. 9번째 행은 저희 모델의 전체적인 모습을 참조용으로 보여줍니다. 1번째 행은 위치 인코딩(PE), 시점 의존성(VD), 또는 계층적 샘플링(H)이 없는 저희 모델의 최소화된 버전을 보여줍니다. 2~4번째 행에서는 전체 모델에서 이 세 가지 구성 요소를 하나씩 제거하면서, 위치 인코딩(2번째 행)과 시점 의존성(3번째 행)이 가장 큰 성능 향상을 가져다주는 것을 확인했으며, 그 다음이 계층적 샘플링(4번째 행)입니다. 5~6번째 행은 입력 이미지의 수가 감소함에 따라 성능이 어떻게 저하되는지를 보여줍니다. 참고로, 저희 방법은 입력 이미지가 25개로 제한되는 경우에도 다른 방법(NV, SRN, LLFF)보다 모든 지표에서 더 나은 성능을 보입니다. (이는 100개의 이미지를 사용하는 경우를 기준으로 합니다. 자세한 내용은 추가 자료를 참조하십시오.) 7~8번째 행에서는 최대 주파수 선택에 대한 검증 결과를 보여줍니다.

	Input	#Im.	L	(N_c, N_f)	PSNR↑	SSIM↑	LPIPS↓
1) No PE, VD, H	xyz	100	-	(256, -)	26.67	0.906	0.136
2) No Pos. Encoding	$xyz\theta\phi$	100	-	(64, 128)	28.77	0.924	0.108
3) No View Dependence	xyz	100	10	(64, 128)	27.66	0.925	0.117
4) No Hierarchical	$xyz\theta\phi$	100	10	(256, -)	30.06	0.938	0.109
5) Far Fewer Images	$xyz\theta\phi$	25	10	(64, 128)	27.78	0.925	0.107
6) Fewer Images	$xyz\theta\phi$	50	10	(64, 128)	29.79	0.940	0.096
7) Fewer Frequencies	$xyz\theta\phi$	100	5	(64, 128)	30.59	0.944	0.088
8) More Frequencies	$xyz\theta\phi$	100	15	(64, 128)	30.81	0.946	0.096
9) Complete Model	$xyz\theta\phi$	100	10	(64, 128)	31.01	0.947	0.081

표 2: 우리 모델에 대한 성능 분석. 제시된 지표들은 실제와 유사한 합성 데이터셋의 8개 장면에서 얻은 결과를 평균화한 것입니다. 자세한 설명은 6.4절을 참조하십시오.

포지셔널 인코딩에 사용되는 값은 x 이며, 이는 d 값에 비례하여 스케일링됩니다 (여기서 x 는 사용되는 최대 주파수를 나타냅니다). 5개의 주파수만 사용하는 경우 성능이 저하되지만, 주파수 개수를 10에서 15로 늘려도 성능 향상은 없습니다. L 값을 늘리는 효과는 샘플링된 입력 이미지에 존재하는 최대 주파수(우리 데이터에서는 대략 1024)를 초과하게 되면 제한된다고 생각합니다.

7. 결론

저희의 연구는 객체와 장면을 연속 함수로 표현하는 데 사용되는 기존 머신러닝 모델의 한계를 직접적으로 해결합니다. 저희는 장면을 5차원 뉴럴 방사휘도 필드(3차원 위치와 2차원 시야 방향에 따라 부피 밀도와 시야에 따른 방사휘도를 출력하는 머신러닝 모델)로 표현하는 것이, 기존의 딥 컨볼루션 신경망을 사용하여 이산적인 복셀 표현을 생성하는 방식보다 더 나은 렌더링 결과를 얻을 수 있음을 보여줍니다.

저희는 렌더링 효율성을 높이기 위해 계층적 샘플링 전략을 제안했지만, 신경 라디언스 필드를 효율적으로 최적화하고 렌더링하는 기술에 대한 연구는 아직 더 많은 발전이 필요합니다. 미래 연구의 또 다른 방향은 해석 가능성입니다. 픽셀 그리드나 메시와 같은 샘플링된 표현은 렌더링 결과의 품질과 오류 발생 가능성에 대한 추론을 가능하게 하지만, 딥 신경망의 가중치에 장면 정보를 인코딩할 때 이러한 문제를 어떻게 분석할 수 있을지는 불분명합니다. 저희는 이 연구가 실제 이미지 기반의 그래픽 파이프라인 개발에 기여할 것이라고 생각합니다. 여기서 복잡한 장면은 실제 객체와 장면의 이미지에서 최적화된 신경 라디언스 필드로 구성될 수 있습니다.

감사의 말씀: 케빈 카오, 구웨이 프랭크 양, 그리고 니틴 라가반에게 귀중한 의견과 논의에 대한 감사를 드립니다. RR은 ONR의 N000141712687 및 N000142012529 연구 지원금과 로널드 L. 그레이엄 교수 자리를 통해 지원받았습니다. BM은 허츠 재단의 연구 지원금을, MT는 NSF 대학원 연구 지원금을 받았습니다. 구글은 BAIR Commons 프로그램을 통해 상당한 양의 클라우드 컴퓨팅 크레딧을 기부했습니다. 다음 분들에게도 감사의 말씀을 드립니다.

저희의 사실적인 합성 데이터셋에 사용된 모델을 Blend Swap 사용자들에게 제공합니다: gregzaal (선박), 1DInc (의자), bryanajones (드럼), Herberhold (피쿠스 나무), erickfree (핫도그), Heinzelnisse (레고), elbrujodelatribu (재료), 그리고 up3d.de (마이크).

참고 문헌

1. Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G.S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., Zheng, X.: TensorFlow: 다양한 시스템에서의 대규모 머신러닝 (2015)
2. Buehler, C., Bosse, M., McMillan, L., Gortler, S., Cohen, M.: 구조화되지 않은 루미 그래프 렌더링. SIGGRAPH (2001) 발표 논문.
3. Chang, A.X., Funkhouser, T., Guibas, L., Hanrahan, P., Huang, Q., Li, Z., Savarese, S., Savva, M., Song, S., Su, H. 외: Shapenet: 풍부한 정보를 담은 3D 모델 저장소. arXiv:1512.03012 (2015)
4. Chen, W., Gao, J., Ling, H., Smith, E.J., Lehtinen, J., Jacobson, A., Fidler, S.: 보간 기반 미분 렌더러를 이용한 3차원 객체 예측 방법. NeurIPS (2019) 발표 논문.
5. Cohen, M., Gortler, S.J., Szeliski, R., Grzeszczuk, R., Szeliski, R.: "The lumigraph." SIGGRAPH (1996) 발표 논문.
6. Curless, B., Levoy, M.: 3차원 이미지로부터 복잡한 모델을 구축하는 볼륨 기반 방법. SIGGRAPH (1996) 발표 논문.
7. Davis, A., Levoy, M., Durand, F.: 구조화되지 않은 광학 필드. 유럽 그래픽스 학회 (Eurographics) (2012)
8. Debevec, P., Taylor, C.J., Malik, J.: 사진을 이용한 건축 모델링 및 렌더링: 하이브리드 기하학 및 이미지 기반 접근 방식. SIGGRAPH (1996) 발표 논문.
9. Flynn, J., Broxton, M., Debevec, P., DuVall, M., Fyffe, G., Overbeck, R., Snavely, N., Tucker, R.: DeepView: 학습 기반 경사 하강법을 이용한 뷰 합성. In: CVPR (2019)
10. Genova, K., Cole, F., Maschinot, A., Sarna, A., Vlasic, D., Freeman, W.T.: 비지도 학습을 이용한 3D 변형 모델 회귀. CVPR (2018) 학회 발표.
11. Genova, K., Cole, F., Sud, A., Sarna, A., Funkhouser, T.: 3차원 형상 표현을 위한 지역적 심층 잠재 함수. CVPR (2020) 학회 발표 논문.
12. Henzler, P., Mitra, N.J., Ritschel, T.: 2차원 예제 데이터를 기반으로 신경망을 활용한 3차원 텍스처 공간 학습. CVPR (2020) 학회 발표 논문.
13. Henzler, P., Rasche, V., Ropinski, T., Ritschel, T.: 단일 이미지 토모그래피: 2차원 두개골 X선 이미지로부터 3차원 부피 데이터 생성. In: Eurographics (2018)
14. Hornik, K., Stinchcombe, M., White, H.: 다층 피드포워드 신경망은 범용 근사기입니다. 신경망 (1989).
15. Jiang, C., Sud, A., Makadia, A., Huang, J., NieSner, M., Funkhouser, T.: 3차원 장면을 위한 로컬 임플리시트 그리드 표현. CVPR (2020) 학회 발표.
16. Kajiya, J.T., Herzen, B.P.V.: 광선 추적 기반의 부피 밀도 계산. 컴퓨터 그래픽 (SIGGRAPH) (1984)
17. Kar, A., Hane, C., Malik, J.: 다중 시점 입체 기계 학습. NeurIPS (2017) 학회 발표.
18. Kingma, D.P., Ba, J.: Adam: 확률적 최적화 방법. ICLR (2015) 학회 발표.

16. B. Mildenhall, P. P. Srinivasan, M. Tancik 외.

19. Kutulakos, K.N., Seitz, S.M.: 공간 조각을 통한 형태 이론. International Journal of Computer Vision (2000).

20. Levoy, M.: 볼륨 데이터의 효율적인 광선 추적. ACM Transactions on Graphics (1990)

21. Levoy, M., Hanrahan, P.: 광학적 정보 렌더링. SIGGRAPH (1996)에 게재.

22. Li, T.M., Aittala, M., Durand, F., Lehtinen, J.: "엣지 샘플링을 통한 미분 가능한 몬테카를로 레이 트레이싱." ACM Transactions on Graphics (SIGGRAPH Asia), (2018).

23. Liu, S., Li, T., Chen, W., Li, H.: 소프트 래스터라이저: 이미지 기반 3차원 추론을 위한 미분 가능 렌더러. ICCV (2019) 학회 논문.

24. Lombardi, S., Simon, T., Saragih, J., Schwartz, G., Lehrmann, A., Sheikh, Y.: 신경망 기반 볼륨 렌더링: 이미지로부터 동적인 렌더링 가능한 볼륨 학습. ACM Transactions on Graphics (SIGGRAPH) (2019)

25. Loper, M.M., Black, M.J.: OpenDR: 근사 미분 렌더러. ECCV (2014)에 게재.

26. Max, N.: 직접 볼륨 렌더링을 위한 광학 모델. IEEE Visualization and Computer Graphics 논문 (1995).

27. Mescheder, L., Oechsle, M., Niemeyer, M., Nowozin, S., Geiger, A.: Occupancy networks: 기능 공간에서의 3차원 재구성 학습. In: CVPR (2019)

28. Mildenhall, B., Srinivasan, P.P., Ortiz-Cayon, R., Kalantari, N.K., Ramamoorthi, R., Ng, R., Kar, A.: 로컬 라이트 필드 융합: 예측적 샘플링 지침을 활용한 실용적인 뷰 합성. ACM Transactions on Graphics (SIGGRAPH) (2019)

29. Niemeyer, M., Mescheder, L., Oechsle, M., Geiger, A.: 미분 가능한 볼륨 렌더링: 3D 지도 없이 암묵적인 3D 표현 학습. In: CVPR (2019)

30. Nimier-David, M., Vicini, D., Zeltner, T., Jakob, W.: Mitsuba 2: 재사용 가능한 순방향 및 역 렌더링 시스템. ACM Transactions on Graphics (SIGGRAPH Asia) (2019)

31. Oechsle, M., Mescheder, L., Niemeyer, M., Strauss, T., Geiger, A.: 텍스처 필드: 함수 공간에서 텍스처 표현 학습. ICCV (2019) 학회 발표 논문.

32. Park, J.J., Florence, P., Straub, J., Newcombe, R., Lovegrove, S.: DeepSDF: 형상 표현을 위한 연속적인 부호 거리 함수 학습. CVPR (2019) 학회 발표.

33. Penner, E., Zhang, L.: 뷰 합성(view synthesis)을 위한 소프트 3D 재구성. ACM Transactions on Graphics (SIGGRAPH Asia) (2017)

34. Porter, T., Duff, T.: 디지털 이미지 합성. 컴퓨터 그래픽 (SIGGRAPH) (1984)

35. Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F.A., Bengio, Y., Courville, A.C.: 신경망의 스펙트럼 편향에 대한 연구. ICML (2018) 발표 논문.

36. Rainer, G., Ghosh, A., Jakob, W., Weyrich, T.: BTF(Bidirectional Reflectance Function, 양방향 반사 함수)의 통합 신경망 인코딩. Computer Graphics Forum (Eurographics) (2020).

37. Rainer, G., Jakob, W., Ghosh, A., Weyrich, T.: 신경망 기반 BTF 압축 및 보간. Computer Graphics Forum (Eurographics) (2019)

38. Ren, P., Wang, J., Gong, M., Lin, S., Tong, X., Guo, B.: "글로벌 일루미네이션을 위한 레디언스 회귀 함수." ACM Transactions on Graphics (2013).

39. Schénberger, J.L., Frahm, J.

40. Seitz, S.M., Dyer, C.R.: 복셀 색상화를 이용한 사실적인 장면 재구성. International Journal of Computer Vision (1999).

41. Sitzmann, V., Thies, J., Heide, F., Nießner, M., Wetzstein, G., Zollhöfer, M.: Deep-voxels: 지속적인 3차원 특징 임베딩 학습. In: CVPR (2019)

42. Sitzmann, V., Zollhoefer, M., Wetzstein, G.: 장면 표현 네트워크: 지속적인 3차원 구조를 인식하는 신경망 기반 장면 표현. NeurIPS (2019) 학회 발표 논문.

43. Srinivasan, P.P., Tucker, R., Barron, J.T., Ramamoorthi, R., Ng, R., Snavely, N.: 다중 평면 이미지를 활용한 시야 확장 기술의 한계 극복. In: CVPR (2019)
44. Stanley, K.O.: 구성 패턴 생성 네트워크: 발달 과정을 새롭게 추상화한 모델. 유전 프로그래밍 및 진화 가능한 기계 (2007).
45. Szeliski, R., Golland, P.: 투명도 및 매칭을 이용한 입체 매칭. ICCV (1998) 학회 발표.
46. Tulsiani, S., Zhou, T., Efros, A.A., Malik, J.: 차등 광선 일관성을 이용한 단일 뷰 재구성에서의 다중 뷰 지도 학습. CVPR (2017) 학회 논문.
47. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L., Polosukhin, I.: "Attention is all you need." NeurIPS (2017)에 발표.
48. Waechter, M., Moehrle, N., Goesele, M.: "색을 더하자!". 3차원 복원 모델의 대규모 텍스처링. In: ECCV (2014)
49. Wood, D.N., Azuma, D.I., Aldinger, K., Curless, B., Duchamp, T., Salesin, D.H., Stuetzle, W.: 3D 사진을 위한 표면 광장. SIGGRAPH (2000)에 발표.
50. Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: 심층 특징이 인지적 측정 기준으로 얼마나 효과적인가. CVPR (2018) 학회 발표.
51. Zhong, E.D., Bepler, T., Davis, J.H., Berger, B.: 동결 전자 현미경 이미지를 사용하여 3차원 단백질 구조의 연속적인 분포를 재구성하는 방법. In: ICLR (2020)
52. Zhou, T., Tucker, R., Flynn, J., Fyffe, G., Snavely, N.: 입체 확대 기술: 다중 평면 이미지를 이용한 시점 합성 학습. ACM Transactions on Graphics (SIGGRAPH) (2018)

추가 구현 세부 사항.

Network 아키텍처 (그림 7)는 저희가 개발한 간단한 완전 연결 신경망 구조를 자세히 보여줍니다. *ure*.

저희 방법은 카메라 광선에 따라 연속적인 5차원 좌표에서 뉴럴 방사 휘도 필드(neural radiance field) 표현을 참조하여 이미지를 생성합니다. 합성 이미지 실험에서는 장면의 크기를 조정하여 원점 중심의 한 변이 2인 정육면체 안에 포함되도록 하고, 이 경계 영역 내에서만 표현을 참조합니다. 실제 이미지 데이터셋에는 가장 가까운 지점부터 무한대까지 다양한 내용이 포함되어 있으므로, 이러한 지점들의 깊이 범위를 $[1, 1]$ 범위로 변환하기 위해 정규화된 장치 좌표를 사용합니다. 이를 통해 모든 광선의 시작점을 장면의 가장 가까운 평면에 이동시키고, 카메라의 투영 광선을 변환된 영역에서 평행한 광선으로 변환하며, 실제 깊이 대신 시차(역방향 깊이)를 사용하여 모든 좌표를 특정 범위 내로 제한합니다.

실제 장면 데이터를 사용할 때, 저희는 최적화 과정에서 출력 값(ReLU 함수를 통과하기 전)에 평균이 0이고 분산이 1인 가우시안 노이즈를 추가하여 네트워크를 정규화합니다. 이를 통해 새로운 시점을 렌더링할 때 시각적 성능이 약간 향상되는 것을 확인했습니다. 저희 모델은 TensorFlow를 사용하여 구현되었습니다.

렌더링 세부 사항: 테스트 시, 우리는 조잡한 네트워크를 통해 광선당 64개의 점을, 그리고 정밀 네트워크를 통해 광선당 $64 + 128 = 192$ 개의 점을 샘플링합니다. 이를 통해 광선당 총 256번의 네트워크 연산을 수행합니다. 우리의 사실적인 합성 데이터는...




그림 7: 우리의 튜리(Tully) 연결 네트워크 아키텍처 시각화. 입력 벡터는 녹색으로, 중간 은닉층은 파란색으로, 출력 벡터는 빨간색으로 표시됩니다. 각 블록 안에 있는 숫자는 해당 벡터의 차원을 나타냅니다. 모든 층은 표준 완전 연결 층이며, 검은색 화살표는 ReLU 활성화 함수를 사용하는 층을, 주황색 화살표는 활성화 함수가 없는 층을, 점선 검은색 화살표는 시그모이드 활성화 함수를 사용하는 층을 나타냅니다. "+" 기호는 벡터 연결을 의미합니다. 입력 위치($y(x)$)의 위치 인코딩은 8개의 완전 연결 ReLU 층을 거치며, 각 층은 256개의 채널을 가집니다. 우리는 DeepSDF [32] 아키텍처를 따르며, 이 입력값을 다섯 번째 층의 활성화 값에 연결하는 건너뛴 연결(skip connection)을 포함합니다. 추가적인 층은 부피 밀도 σ (ReLU 함수를 사용하여 항상 0 이상이 되도록 조정)와 256차원 특징 벡터를 출력합니다. 이 특징 벡터는 입력 시야 방향(d)의 위치 인코딩과 연결되고, 추가적인 완전 연결 ReLU 층(128개 채널)을 거칩니다. 마지막 층(시그모이드 활성화 함수 사용)은 방향 d 를 가진 광선에 의해 관찰되는 위치 x 에서의 방출되는 RGB 광도를 출력합니다.

데이터셋은 이미지당 64만 개의 광선을 필요로 하며, 실제 장면의 경우 이미지당 76만 개의 광선을 필요로 합니다. 결과적으로, 렌더링된 각 이미지에 대해 1억 5천만 개에서 2억 개의 네트워크 쿼리가 발생합니다. NVIDIA V100 GPU를 사용할 경우, 프레임당 약 30초가 소요됩니다.

추가적인 기본 방법 상세 설명.

뉴럴 볼륨(NV) | 24/ 저희는 저자들이 공개한 NV 코드를 사용합니다. 해당 코드는 다음 링크에서 확인할 수 있습니다: [https://github.com/facebookresearch/neuralvolumes]. 저희는 이 코드를 사용하여 시간 의존성이 없는 단일 장면에서 학습하는 방법을 따릅니다.

장면 표현 네트워크(SRN): 저희는 저자들이 GitHub 주소 https://github.com/vsitzmann/scene-representation-n에 공개한 SRN 코드를 사용하며, 그들이 제시한 단일 장면 학습 절차를 따릅니다.

로컬 라이트 필드 퓨전(LLFF) [25]: 저희는 저자들에 의해 공개된 LLFF 모델을 사용합니다. 해당 모델은 다음 링크(<https://github.com/Fyusion/LLFF>)에서 확인할 수 있습니다.

양적 비교: 저자들이 발표한 SRN(Super-Resolution Neural Network) 구현 방식은 상당한 양의 GPU 메모리를 필요로 하며, 4개의 NVIDIA V100 GPU를 사용하여 병렬 처리를 하더라도 이미지 해상도가 512 x 512 픽셀로 제한됩니다. 우리는 합성 데이터셋에서는 512 x 512 픽셀, 실제 데이터셋에서는 504 x 376 픽셀의 해상도로 SRN의 성능을 측정했으며, 이는 다른 방법들이 더 높은 해상도(각각 800 x 800 및 1008 x 752)에서 실행될 수 있다는 점과 비교됩니다.

NDC (국가 데이터 센터) 레이스페이스 도출.

"저희는 삼각면 렌더링 파이프라인에서 일반적으로 사용되는 정규화된 장치 좌표(NDC) 공간에서 "정면 촬영" 방식으로 실제 장면을 재구성합니다. 이 공간은 z축(카메라 축)을 시차에 비례하도록 변환하면서도 평행선을 유지하므로 편리합니다."

여기서는 카메라 공간에서 NDC(Normalized Device Coordinates, 정규화된 장치 좌표) 공간으로의 변환을 수행하는 변환식을 유도합니다. 동차 좌표를 사용하는 표준 3차원 투영 행렬은 다음과 같습니다.

$$M = \begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \quad (7)$$

여기서 n과 f는 각각 가까운 절단면과 먼 절단면을 나타내고, r과 t는 가까운 절단면에서 보이는 장면의 오른쪽과 위쪽 경계를 나타냅니다. (참고: 여기서는 카메라가 -z 방향을 바라보는 방식을 따릅니다.) 동차 좌표 (x, y, z, 1)을 투영하려면, 먼저 행렬 M과 곱한 다음 네 번째 좌표로 나눕니다.

$$\begin{pmatrix} \frac{n}{r} & 0 & 0 & 0 \\ 0 & \frac{n}{t} & 0 & 0 \\ 0 & 0 & \frac{-(f+n)}{f-n} & \frac{-2fn}{f-n} \\ 0 & 0 & -1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{n}{r}x \\ \frac{n}{t}y \\ \frac{-(f+n)}{f-n}z - \frac{2fn}{f-n} \\ -z \end{pmatrix} \quad (8)$$

$$\text{project} \rightarrow \begin{pmatrix} \frac{n}{r} \frac{x}{-z} \\ \frac{n}{t} \frac{y}{-z} \\ \frac{(f+n)}{f-n} - \frac{2fn}{f-n} \frac{1}{-z} \end{pmatrix} \quad (9)$$

현재 투영된 점은 정규화된 장치 좌표(NDC) 공간에 위치하며, 원래의 시야 영역이 [-1, 1]이라는 입방체 형태로 매핑되었습니다.

저희의 목표는 광선(ray)을 받아들여 NDC(Normalized Device Coordinates) 공간에서 광선의 시작점(o')과 방향(d')을 계산하는 것입니다. 이때, 모든 t 값에 대해, $\gamma(o + td) = o' + t'd'$ 이 되는 새로운 t' 값이 존재해야 합니다 (여기서 γ 은 위에서 언급한 행렬을 사용한 투영을 의미). 다시 말해, 원래 광선의 투영과 NDC 공간에서의 광선 추적은 동일한 점들을 나타내지만, 반드시 동일한 속도로 진행되는 것은 아닙니다.

다음 식에 의해 정의되는 원점을 다시 정의해 보겠습니다. (QzX/Z, Ay Y/2, az+0z/2). 새로운 원점 o'와 방향 d'은 다음 조건을 만족해야 합니다.

$$\begin{pmatrix} a_x \frac{o_x+td_x}{o_z+td_z} \\ a_y \frac{o_y+td_y}{o_z+td_z} \\ a_z + \frac{b_z}{o_z+td_z} \end{pmatrix} = \begin{pmatrix} o'_x + t'd'_x \\ o'_y + t'd'_y \\ o'_z + t'd'_z \end{pmatrix}. \tag{10}$$

자유도를 줄이기 위해, 우리는 t' = 0과 ϕ = 0이 동일한 지점으로 매핑되도록 결정합니다. 식 [L0]에 t = 0과 t' = 0을 대입하면, NDC(Normalized Device Coordinates) 공간의 원점을 직접적으로 구할 수 있습니다.

$$\mathbf{o}' = \begin{pmatrix} o'_x \\ o'_y \\ o'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x}{o_z} \\ a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z} \end{pmatrix} = \pi(\mathbf{o}). \tag{11}$$

이것은 원래 광선의 출발점과 정확히 일치하는 투영점 7(o)입니다. 이 값을 방정식 10에 대입하여 임의의 t 값에 대해 t'와 d'의 값을 결정할 수 있습니다.

$$\begin{pmatrix} t'd'_x \\ t'd'_y \\ t'd'_z \end{pmatrix} = \begin{pmatrix} a_x \frac{o_x+td_x}{o_z+td_z} - a_x \frac{o_x}{o_z} \\ a_y \frac{o_y+td_y}{o_z+td_z} - a_y \frac{o_y}{o_z} \\ a_z + \frac{b_z}{o_z+td_z} - a_z - \frac{b_z}{o_z} \end{pmatrix} \tag{12}$$

$$= \begin{pmatrix} a_x \frac{o_z(o_x+td_x)-o_x(o_z+td_z)}{(o_z+td_z)o_z} \\ a_y \frac{o_z(o_y+td_y)-o_y(o_z+td_z)}{(o_z+td_z)o_z} \\ b_z \frac{o_z-(o_z+td_z)}{(o_z+td_z)o_z} \end{pmatrix} \tag{13}$$

$$= \begin{pmatrix} a_x \frac{td_z}{o_z+td_z} \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \frac{td_z}{o_z+td_z} \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{td_z}{o_z+td_z} \frac{1}{o_z} \end{pmatrix} \tag{14}$$

F 변수 'ϕ'에만 의존하는 공통적인 표현을 분리하면 다음과 같은 결과를 얻을 수 있습니다.

$$t' = \frac{td_z}{o_z + td_z} = 1 - \frac{o_z}{o_z + td_z} \tag{15}$$

$$\mathbf{d}' = \begin{pmatrix} a_x \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ a_y \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -b_z \frac{1}{o_z} \end{pmatrix}. \tag{16}$$

참고로, 원하는 경우, 't'는 '0'이 0일 때 0이 됩니다. 또한, 't'가 무한대로 증가함에 따라 't' 역시 1보다 커지는 것을 확인할 수 있습니다. 이제 원래의 투영 행렬로 돌아가면, 우리의 상수 값은 다음과 같습니다.

$$a_x = -\frac{n}{r} \quad (17)$$

$$a_y = -\frac{n}{t} \quad (18)$$

$$a_z = \frac{f + n}{f - n} \quad (19)$$

$$b_z = \frac{2fn}{f - n} \quad (20)$$

표준 핀홀 카메라 모델을 사용하면, 매개변수 a 를 재정의할 수 있습니다.

$$a_x = -\frac{f_{cam}}{W/2} \quad (21)$$

$$a_y = -\frac{f_{cam}}{H/2} \quad (22)$$

여기서 W 와 H 는 이미지의 가로 및 세로 크기(픽셀 단위)를 나타내고, f_{cam} 은 카메라의 초점 거리를 나타냅니다.

저희가 실제 전방향 이미지를 캡처할 때, 멀리 있는 장면의 경계는 무한대로 가정합니다 (이는 NDC가 깊이의 역수를 나타내는 z 축을 사용하기 때문에 큰 부담이 되지 않습니다). 이러한 조건에서 z 상수 값은 다음과 같이 단순화됩니다.

$$a_z = 1 \quad (23)$$

$$b_z = 2n. \quad (24)$$

모든 것을 종합하여:

$$\mathbf{o}' = \begin{pmatrix} -\frac{f_{cam}}{W/2} \frac{o_x}{o_z} \\ -\frac{f_{cam}}{H/2} \frac{o_y}{o_z} \\ 1 + \frac{2n}{o_z} \end{pmatrix} \quad (25)$$

$$\mathbf{d}' = \begin{pmatrix} -\frac{f_{cam}}{W/2} \left(\frac{d_x}{d_z} - \frac{o_x}{o_z} \right) \\ -\frac{f_{cam}}{H/2} \left(\frac{d_y}{d_z} - \frac{o_y}{o_z} \right) \\ -2n \frac{1}{o_z} \end{pmatrix}. \quad (26)$$

구현 과정에서 마지막으로 언급할 부분은 다음과 같습니다. 우리는 광선의 근접 평면과의 교차점($z = -n$)에서 'o' 값을 조정합니다. 구체적으로, NDC 변환 전에 $o' = 0 + tnd$ 로 설정하며, 여기서 t 는 $-(n + o') / d$ 입니다. 이렇게 NDC 광선으로 변환한 후, 우리는 't' 값을 0부터 1까지 선형적으로 샘플링하여, 원래 공간에서 'n'부터 무한대까지의 시차를 선형적으로 샘플링할 수 있습니다.




그림 8: Deep Voxels 합성 데이터셋의 장면들을 대상으로 한 테스트 데이터셋의 다양한 시점에 대한 비교. 이 데이터셋의 객체들은 단순한 기하학적 구조를 가지고 있으며, 완벽하게 빛을 반사합니다. 입력 이미지의 수가 매우 많고(479개 시점), 렌더링된 객체의 구조가 단순하기 때문에, 저희 방법과 LLFF [28] 모두 이 데이터에 대해 거의 완벽한 성능을 보입니다. LLFF는 여전히 3차원 볼륨 데이터 간의 보간 과정에서 가끔씩 왜곡 현상을 나타냅니다 (각 객체에 대한 상단 삽입 그림 참조). SRN과 NV는 미세한 디테일을 렌더링할 수 있는 표현력을 가지고 있지 않습니다.

추가 결과:

각 장면별 분석 결과는 '레이블' 섹션의 3, 4, 5 부분에 제시된 주요 논문의 정량적 결과를 각 장면별 지표로 나누어 보여줍니다. 각 장면별 분석 결과는 논문에 제시된 전체적인 정량적 지표와 일관성을 유지하며, 저희 방법이 모든 기준 모델보다 정량적으로 우수한 성능을 보입니다. LLFF가 약간 더 나은 LPIPS 지표를 달성하는 것은 사실이지만, 독자분들께서는 저희 방법이 기준 모델보다 더 나은 다중 뷰 일관성을 보여주고, 더 적은 화질 저하 현상을 발생시킨다는 것을 보여주는 추가 영상을 꼭 시청해 주시기를 권장합니다.

	PSNR↑				SSIM↑				LPIPS↓			
	Chair	Pedestal	Cube	Vase	Chair	Pedestal	Cube	Vase	Chair	Pedestal	Cube	Vase
DeepVoxels [41]	33.45	32.35	28.42	27.99	0.99	0.97	0.97	0.96	—	—	—	—
SRN [42]	36.67	35.91	28.74	31.46	0.982	0.957	0.944	0.969	0.093	0.081	0.074	0.044
NV [24]	35.15	36.47	26.48	20.39	0.980	0.963	0.916	0.857	0.096	0.069	0.113	0.117
LLFF [28]	36.11	35.87	32.58	32.97	0.992	0.983	0.983	0.983	0.051	0.039	0.064	0.039
Ours	42.65	41.44	39.19	37.32	0.991	0.986	0.996	0.992	0.047	0.024	0.006	0.017

표 3: DeepVoxels 데이터셋을 사용한 장면별 정량적 결과. 이 데이터셋의 "장면"은 모두 단순한 기하학 구조를 가진 확산체이며, 3D 스캐너로 캡처된 텍스처 매핑 메시를 사용하여 렌더링되었습니다. DeepVoxels 방법의 성능 지표는 해당 논문에서 직접 가져왔으며, LPIPS 값은 보고되지 않고 SSIM 값은 소수점 둘째 자리까지만 보고됩니다.

	PSNR↑							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	26.96	17.18	20.73	26.81	20.85	18.09	26.85	20.60
NV [24]	28.33	22.58	24.79	30.71	26.08	24.22	27.78	23.93
LLFF [28]	28.72	21.13	21.79	31.41	24.54	20.72	27.48	23.22
Ours	33.00	25.01	30.13	36.18	32.54	29.62	32.91	28.65

	SSIM↑							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	0.910	0.766	0.849	0.923	0.809	0.808	0.947	0.757
NV [24]	0.916	0.873	0.910	0.944	0.880	0.888	0.946	0.784
LLFF [28]	0.948	0.890	0.896	0.965	0.911	0.890	0.964	0.823
Ours	0.967	0.925	0.964	0.974	0.961	0.949	0.980	0.856

	LPIPS↓							
	Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
SRN [42]	0.106	0.267	0.149	0.100	0.200	0.174	0.063	0.299
NV [24]	0.109	0.214	0.162	0.109	0.175	0.130	0.107	0.276
LLFF [28]	0.064	0.126	0.130	0.061	0.110	0.117	0.084	0.218
Ours	0.046	0.091	0.044	0.121	0.050	0.063	0.028	0.206

표 4: 저희가 제작한 사실적인 합성 데이터셋을 활용한 장면별 정량적 결과. 이 데이터셋의 "장면"은 복잡한 기하 구조와 람베르트 반사율이 아닌 재질을 가진 객체들로 구성되어 있으며, 블렌더의 사이클스 경로 추적 엔진을 사용하여 렌더링되었습니다.

PSNR↑								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	27.29	21.37	18.24	26.63	17.37	24.63	22.87	24.33
LLFF [28]	28.42	22.85	19.52	29.40	18.52	25.46	24.15	24.70
Ours	32.70	25.17	20.92	31.16	20.36	27.40	26.80	27.45

SSIM↑								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	0.883	0.611	0.520	0.641	0.449	0.738	0.761	0.742
LLFF [28]	0.932	0.753	0.697	0.872	0.588	0.844	0.857	0.840
Ours	0.948	0.792	0.690	0.881	0.641	0.827	0.880	0.828

LPIPS↓								
	Room	Fern	Leaves	Fortress	Orchids	Flower	T-Rex	Horns
SRN [42]	0.240	0.459	0.440	0.453	0.467	0.288	0.298	0.376
LLFF [28]	0.155	0.247	0.216	0.173	0.313	0.174	0.222	0.193
Ours	0.178	0.280	0.316	0.171	0.321	0.219	0.249	0.268

표 95: 실제 이미지 데이터셋을 사용한 장면별 정량적 결과. 이 데이터셋에 포함된 모든 장면은 전면 카메라를 장착한 휴대폰으로 촬영되었습니다.

		PSNR↑							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	28.44	23.11	25.17	32.24	26.38	24.69	28.16	25.12
2)	No Pos. Encoding	30.33	24.54	29.32	33.16	27.75	27.79	30.76	26.55
3)	No View Dependence	30.06	23.41	25.91	32.65	29.93	24.96	28.62	25.72
4)	No Hierarchical	31.32	24.55	29.25	35.24	31.42	29.22	31.74	27.73
5)	Far Fewer Images	30.92	22.62	24.39	32.77	27.97	26.55	30.47	26.57
6)	Fewer Images	32.19	23.70	27.45	34.91	31.53	28.54	32.33	27.67
7)	Fewer Frequencies	32.19	25.29	30.73	36.06	30.77	29.77	31.66	28.26
8)	More Frequencies	32.87	24.65	29.92	35.78	32.50	29.54	32.86	28.34
9)	Complete Model	33.00	25.01	30.13	36.18	32.54	29.62	32.91	28.65

		SSIM↑							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	0.919	0.896	0.926	0.955	0.882	0.905	0.955	0.810
2)	No Pos. Encoding	0.938	0.918	0.953	0.956	0.903	0.933	0.968	0.824
3)	No View Dependence	0.948	0.906	0.938	0.961	0.947	0.912	0.962	0.828
4)	No Hierarchical	0.951	0.914	0.956	0.969	0.951	0.944	0.973	0.844
5)	Far Fewer Images	0.956	0.895	0.922	0.966	0.930	0.925	0.972	0.832
6)	Fewer Images	0.963	0.911	0.948	0.971	0.957	0.941	0.979	0.847
7)	Fewer Frequencies	0.959	0.928	0.965	0.972	0.947	0.952	0.973	0.853
8)	More Frequencies	0.967	0.921	0.962	0.973	0.961	0.948	0.980	0.853
9)	Complete Model	0.967	0.925	0.964	0.974	0.961	0.949	0.980	0.856

		LPIPS↓							
		Chair	Drums	Ficus	Hotdog	Lego	Materials	Mic	Ship
1)	No PE, VD, H	0.095	0.168	0.084	0.104	0.178	0.111	0.084	0.261
2)	No Pos. Encoding	0.076	0.104	0.050	0.124	0.128	0.079	0.041	0.261
3)	No View Dependence	0.075	0.148	0.113	0.112	0.088	0.102	0.073	0.220
4)	No Hierarchical	0.065	0.177	0.056	0.130	0.072	0.080	0.039	0.249
5)	Far Fewer Images	0.058	0.173	0.082	0.123	0.081	0.079	0.035	0.229
6)	Fewer Images	0.051	0.166	0.057	0.121	0.055	0.068	0.029	0.223
7)	Fewer Frequencies	0.055	0.143	0.038	0.087	0.071	0.060	0.029	0.219
8)	More Frequencies	0.047	0.158	0.045	0.116	0.050	0.064	0.027	0.261
9)	Complete Model	0.046	0.091	0.044	0.121	0.050	0.063	0.028	0.206

표 6: 본 연구에서 실시한 분석을 통해 얻은, 장면별 정량적 결과. 여기에서 사용된 장면은 표 [4]에 나와 있는 장면과 동일합니다.