

6 저는 인간의 지능에 특별한 점이 없다고 생각합니다. 뇌에 존재하는 모든 뉴런(신경 세포)은 감각과 감정을 만들어내는 데 이진 방식으로 작동합니다.

윌리엄 헨리 게이츠 2세

1. 서론

대규모 언어 모델(BMR™* 20, Ope23, CND*22, ADF* 23, TLI" 23, TMS+* 23)의 빠른 성장은 다양한 작업에서 상당한 개선을 가져왔습니다. 그러나 대규모 언어 모델을 운영하는 데는 높은 추론 비용과 에너지 소비로 인해 비용이 많이 듭니다. 이러한 모델의 크기가 커짐에 따라 모델 매개변수에 접근하고 처리하는 데 필요한 메모리 대역폭이 주요 병목 현상이 되어 전체 추론 성능을 제한합니다. 또한 이러한 모델을 분산 시스템이나 다중 장치 플랫폼에 배포하는 경우 장치 간 통신 오버헤드가 추론 지연 시간과 에너지 소비에 상당한 영향을 미칠 수 있습니다. 모델 양자화(FAHA23, CCKS23, XLS* 23)는 대규모 모델의 메모리 사용량과 컴퓨팅 비용을 크게 줄이면서도 경쟁력 있는 성능을 유지할 수 있는 유망한 해결책으로 부상하고 있습니다.

대규모 언어 모델에 사용되는 대부분의 기존 양자화 방식은 훈련 후 방식입니다. 이러한 방식은 훈련 파이프라인을 변경하거나 모델을 재훈련하는 데 필요한 추가적인 노력이 없기 때문에 간단하고 적용하기 쉽습니다. 그러나 특히 정밀도가 낮아질 경우, 모델이 양자화된 표현에 최적화되지 않았기 때문에 정확도 손실이 더욱 커질 수 있습니다.

양자화된 심층 신경망의 또 다른 접근 방식은 양자화에 대한 인식을 가진 훈련입니다. 훈련 후 방식에 비해, 모델이 처음부터 정밀도 감소를 고려하도록 훈련되므로 일반적으로 더 나은 정확도를 제공합니다. 또한, 양자화 인식 훈련은 대규모 언어 모델에 필수적인 지속적인 훈련 또는 미세 조정 기능을 제공합니다. 양자화 인식 훈련의 주요 과제는 최적화, 즉 정밀도가 낮아질수록 모델이 수렴하기 어려워지는 것입니다.

본 연구에서는 1비트, 즉 이진화를 적용하여 대규모 언어 모델에 적용하는 것을 중심으로 다룹니다. 이진화된 신경망에 대한 이전 연구[RORF16, BT19]는 주로 합성 신경망에 초점을 맞추었습니다. 최근에는 이진화된 트랜스포머에 대한 연구가 진행되고 있습니다. 그러나 이러한 연구는 주로 기계 번역이나 BERT 사전 훈련에 초점을 맞추고 있으며, 이는 대규모 언어 모델과는 상당히 다릅니다. 예를 들어, 기계 번역은 인코더-디코더 구조를 사용하고, BERT 사전 훈련은 양방향 인코더를 사용하며, 대규모 언어 모델은 단방향 디코더를 사용합니다. 또한, 대규모 언어 모델은 일반적으로 훨씬 더 큰 모델 크기로 확장되는 반면, BERT와 기계 번역 모델은 그러한 광범위한 확장을 겪지 않습니다.

현재까지 저희가 알고 있는 바에 따르면, 이 연구는 1비트 대규모 언어 모델에 대한 양자화 인식 훈련을 처음으로 조사하는 연구입니다. 저희는 메모리와 연산 측면에서 효율적인 확장성을 목표로 하는 1비트 Transformer 아키텍처인 BitNet을 제안합니다. BitNet은 훈련 중에 고정밀도를 유지하면서 낮은 정밀도 이진 가중치와 양자화된 활성화를 사용합니다. 저희의 접근 방식은 대규모 언어 모델을 효율적으로 처리할 수 있도록 확장성과 안정성을 갖도록 설계되었습니다. BitNet 아키텍처의 구현은 Transformer 내의 선형 투영(예: PyTorch의 nn.Linear)만 교체하는 방식으로 간단합니다. 또한 BitNet은 PagedAttention [KLZ*23], FlashAttention [DFEt22, Dao23], 스펙 티브 디코딩 [LKM23]과 같은 다른 대규모 언어 모델 가속 방법에 보완적인 역할을 합니다.

우리는 BitNet을 다양한 언어 모델링 벤치마크에서 평가하고, 최신 양자화 방법 및 FP16 트랜스포머와 비교합니다. 실험 결과, BitNet은 perplexity와 다운스트림 작업 정확도 모두에서 경쟁력 있는 성능을 보입니다. 더 중요한 점은 BitNet이 기본 모델에 비해 메모리 사용량과 에너지 소비를 크게 줄일 수 있다는 것입니다. 또한, BitNet은 풀 정밀도 트랜스포머와 유사한 스케일링 법칙을 따르며, 이는 성능 및 효율 측면에서 훨씬 더 큰 언어 모델에도 효과적으로 적용될 수 있음을 시사합니다.




그림 2: (a) BitLinear의 계산 흐름 (b) 주의 및 FFN 레이어의 겹쳐진 구조를 가진 BitNet의 아키텍처, 여기서 행렬 곱셈은 BitLinear로 구현됨.

2 BitNet

如 2에서 볼 수 있듯이, BitNet은 Transformer와 동일한 구조를 사용하며, 자체 주의 및 순방향 신경망 블록을 씁습니다. 일반적인 Transformer와 달리, BitNet은 비나라이즈된 (즉, 1비트) 모델 가중치를 사용합니다 (Eq. 1). 실험에서는 다른 구성 요소는 고정밀도로 유지합니다 (예: 8비트). 그 이유는 다음과 같습니다. 첫째, 잔류 연결과 층 정규화는 대규모 언어 모델에 미미한 계산 비용만 추가합니다. 둘째, 모델이 커짐에 따라 QKV 변환의 계산 비용은 파라메트릭 프로젝션보다 훨씬 적습니다. 셋째, 언어 모델은 샘플링을 수행하기 위해 고정밀 확률을 사용해야 하므로 입력/출력 임베딩의 정밀도를 유지합니다.

2.1 BitLinear

우리는 먼저 시그누스 함수를 사용하여 가중치를 +1 또는 -1로 이분화합니다. [LOP™ 22]에 따라, 이분화 전에 가중치를 평균 0으로 조정하여 제한된 수치 범위 내에서 용량을 늘립니다. 이분화 후에는 실제 값과 이분화된 가중치 간의 12 오류를 줄이기 위해 스케일링 요소를 사용합니다. $W \in \mathbb{R}^{n \times m}$ 의 가중치를 이분화하는 것은 다음과 같이 표현할 수 있습니다:

$$\widetilde{W} = \text{Sign}(W - \alpha), \quad (1)$$

$$\text{Sign}(W_{ij}) = \begin{cases} +1, & \text{if } W_{ij} > 0, \\ -1, & \text{if } W_{ij} \leq 0, \end{cases} \quad (2)$$

$$\alpha = \frac{1}{nm} \sum_{ij} W_{ij} \quad (3)$$

또한 활성화 값을 b-비트 정밀도로 더욱 정량화합니다. [DLBZ22]에 따라, 활성화 값을 입력 행렬의 절대 최대값으로 곱하고, Q로 나누어 $[-Q_y, Q_o]$ 범위로 스케일링하는 absmax 양자화 방법을 사용합니다.

$$\tilde{x} = \text{Quant}(x) = \text{Clip}\left(x \times \frac{Q_b}{\gamma}, -Q_b + \epsilon, Q_b - \epsilon\right), \quad (4)$$

$$\text{Clip}(x, a, b) = \max(a, \min(b, x)), \quad \gamma = \|x\|_{\infty}, \quad (5)$$

여기 ϵ 는 작은 부동 소수점 숫자이며, 클리핑 연산을 수행할 때 오버플로우를 방지하는 데 사용됩니다.

비선형 함수(예: ReLU) 이전의 활성화 값은, 입력 값 중 최소값을 빼서 모든 값이 양수이도록 $[0, Q_p]$ 범위로 조정합니다.

$$\tilde{x} = \text{Quant}(x) = \text{Clip}((x - \eta) \times \frac{Q_b}{\gamma}, \epsilon, Q_b - \epsilon), \quad \eta = \min_{ij} x_{ij}. \quad (6)$$

본 연구에서는 활성화 값을 8비트로 양자화하고, 향후 연구에서는 더 낮은 정밀도를 사용합니다. 또한, 안정성과 효율성을 위해 학습 과정에서는 텐서별로 양자화를 수행하고, 추론 과정에서는 토큰별로 수행합니다.

위의 양자화 방정식들을 사용하여 행렬 곱셈은 다음과 같이 표현할 수 있습니다.

$$y = W\tilde{x} \quad (7)$$

우리는 W와 x에 있는 요소들이 서로 독립적이며 동일한 분포를 가지며, W와 z가 서로 독립적이라고 가정합니다. 그렇다면 출력값 y의 분산은 다음과 같이 추정됩니다:

$$\text{Var}(y) = n\text{Var}(\tilde{w}\tilde{x}) \quad (8)$$

$$= nE[\tilde{w}^2]E[\tilde{x}^2] \quad (9)$$

$$= n\beta^2 E[\tilde{x}^2] \approx E[\tilde{x}^2] \quad (10)$$

정밀 계산을 위해, 출력 변수 Var(y)의 분산은 1의 척도로 설정되며, Kaiming 초기화 또는 Xavier 초기화와 같은 표준 초기화 방법을 사용합니다. 이는 훈련 안정성에 큰 도움이 됩니다. 양자화를 통해 분산을 유지하기 위해, 활성화 양자화 전에 LayerNorm [BKH16] 함수를 도입합니다. 이렇게 하면 출력 y의 분산은 Var(y) ~ E[LN(Z)] = 1로 추정되며, 이는 정밀 계산과 동일한 크기를 가집니다. 트랜스포머의 맥락에서, SubLN [WMH * 22]와 동일한 구현을 사용합니다. SubLN 및 위에 언급된 양자화 방법과 함께, BitLinear를 사용할 수 있습니다.

$$y = \tilde{W}\tilde{x} = \tilde{W} \text{Quant}(\text{LN}(x)) \times \frac{\beta\gamma}{Q_b} \quad (11)$$

$$\text{LN}(x) = \frac{x - E(x)}{\sqrt{\text{Var}(x) + \epsilon}}, \quad \beta = \frac{1}{nm} \|W\|_1 \quad (12)$$

그림 2는 BitLinear의 계산 흐름을 보여줍니다. SubLN 연산 후, 활성화 값은 absmax 함수를 사용하여 양자화됩니다. 1비트 가중치와 양자화된 활성화 값 사이의 행렬 곱셈이 수행됩니다. 마지막으로, 출력 활성화 값을 {8,-y}를 사용하여 원래 정밀도로 되돌립니다.

그룹 양자화 및 정규화를 이용한 모델 병렬화는 대규모 언어 모델을 확장하는 데 필수적인 기술입니다[SPP* 19]. 이 기술은 여러 장치에서 행렬 곱셈을 분할합니다. 기존의 모델 병렬화 방식의 전제 조건은 텐서가 분할 차원을 따라 독립적이어야 한다는 것입니다. 그러나 a, 3, y, 77과 같은 모든 파라미터는 전체 텐서에서 계산되므로, 이 전제 조건이 깨집니다. 하나의 해결책은 각 파라미터에 대해 하나의 전체 감소 연산을 도입하는 것입니다. 그러나 각 파라미터에 대한 통신은 작더라도 모델이 깊어짐에 따라 동기화량이 증가하여 순방향 통과 속도를 크게 늦춥니다. 또한, SubLN에서도 평균과 분산을 분할 차원을 따라 추정해야 하는 문제가 있습니다.

이를 위해, 우리는 모델 병렬 처리를 더욱 효율적으로 만드는 간단한 방법을 제안합니다. 우리는 가중치와 활성화 값을 그룹으로 나누고, 각 그룹의 파라미터를 독립적으로 추정합니다. 이렇게 하면 추가적인 통신 없이 각 파라미터를 로컬에서 계산할 수 있습니다. 이러한 접근 방식은 "그룹 양자화"라고 불리며, 다음과 같이 정의됩니다:

체계(W)가 R"*""의 행렬인 경우, 행렬을 분할 차원을 따라 G개의 그룹으로 나눕니다. 각 그룹의 크기는 & x m입니다. 그런 다음 각 그룹에 대해 독립적으로 매개변수를 추정합니다:

$$\alpha_g = \frac{G}{nm} \sum_{ij} W_{ij}^{(g)}, \quad \beta_g = \frac{G}{nm} \|W^{(g)}\|_1, \quad (13)$$

Models	Size	WBits	7nm Energy (J)		45nm Energy (J)	
			MUL	ADD	MUL	ADD
Transformer	6.7B	32	4.41	1.28	12.46	3.03
BitNet		16	1.14	0.54	3.70	1.35
BitNet		1	0.02	0.04	0.08	0.13
Transformer	13B	32	8.58	2.49	24.23	5.89
BitNet		16	2.23	1.05	7.20	2.62
BitNet		1	0.04	0.06	0.12	0.24
Transformer	30B	32	20.09	5.83	56.73	13.80
BitNet		16	5.21	2.45	16.87	6.13
BitNet		1	0.06	0.14	0.20	0.53

표 1: BitNet과 Transformer 모델의 크기가 다른 경우 에너지 소비량 비교 결과. 입력 길이를 512로 설정하여 결과가 보고되었습니다.

여기서 W^g 는 가중치 행렬의 g 번째 그룹을 나타냅니다. 마찬가지로, 활성화 함수에 대해서도, 입력 행렬 $\ll \epsilon R^{*}$ 을 G 개의 그룹으로 나누고 각 그룹에 대한 파라미터를 계산할 수 있습니다:

$$\gamma_g = \|x^{(g)}\|_\infty, \quad \eta_g = \min_{ij} x_{ij}^{(g)} \tag{14}$$

LN의 경우, 각 그룹에 대해 평균과 분산을 독립적으로 계산하기 위해 그룹 정규화 기법 [WH20]을 적용할 수 있습니다.

$$\text{LN}(x^{(g)}) = \frac{x^{(g)} - E(x^{(g)})}{\sqrt{\text{Var}(x^{(g)}) + \epsilon}} \tag{15}$$

이 방법을 통해, 그룹 양자화 및 정규화를 사용하여 모델 병렬 처리를 효율적으로 구현할 수 있습니다. 이는 추가적인 통신 없이 대규모 언어 모델에도 적용 가능합니다.

2.2. 모델 훈련

직렬 추정 방법...저희의 1-비트 모델을 훈련하기 위해, 역전파 과정에서 기울기를 추정하기 위해 직렬 추정 방법(STE)[BLC13]을 사용합니다. 이 방법은 역전파 과정에서 비연속 함수, 예를 들어 Sign(Eq. 2) 및 Clip(Eq. 5) 함수와 같은 함수에 영향을 받지 않고 기울기가 네트워크를 통과하도록 합니다. 이를 통해 저희의 양자화된 모델을 훈련할 수 있습니다.

혼합 정밀도 훈련... 가중치와 활성화 값은 낮은 정밀도로 양자화되지만, 기울기와 옵티마이저 상태는 높은 정밀도로 저장하여 훈련의 안정성과 정확성을 보장합니다. 이전 연구 [LSL* 21]에 따르면, 학습 가능한 매개변수에 대해 높은 정밀도로 잠재된 가중치를 유지하여 매개변수 업데이트를 누적합니다. 잠재된 가중치는 순방향 통과 과정에서 즉석에서 이진화되며 추론 과정에서는 사용되지 않습니다.

높은 학습률... 최적화 과정에서 중요한 문제는 잠재 변수의 가중치를 조금씩 업데이트해도 1비트 가중치에 큰 영향을 미치지 않는다는 것입니다. 이는 1비트 가중치를 기반으로 추정한 편향된 경사 및 업데이트를 초래합니다. 특히 훈련 초반에는 모델이 가능한 한 빨리 수렴해야 하는데, 이러한 문제가 더욱 심각합니다. 이러한 문제를 해결하기 위해, 우리는 다양한 방법을 탐구한 결과, 최적화 속도를 높이는 가장 간단하고 효과적인 방법은 학습률을 높이는 것이라고 결론 내렸습니다. 실험 결과, BitNet은 높은 학습률을 통해 수렴 속도를 높이는 반면, FP16 Transformer는 동일한 학습률을 사용하더라도 훈련 초반에 수렴하지 않는다는 것을 확인했습니다. 자세한 내용은 3장에 있습니다.

2.3 계산 효율성

우리는 BitNet의 계산 효율성을 산술 연산 에너지 및 메모리 사용량 측면에서 평가합니다. 특히, 대규모 언어 모델의 비용에 가장 큰 영향을 미치는 행렬 곱셈 계산에 중점을 두고 있습니다.

산술 연산에 따른 에너지 소비량: [Hor14, ZZL22]에 제시된 에너지 모델에 따르면, 다음과 같이 다양한 산술 연산에 따른 에너지 소비량을 추정할 수 있습니다.

Bits	ADD Energy $\hat{E}_{add}$ (pJ)		MUL Energy $\hat{E}_{mul}$ (pJ)	
	45nm	7nm	45nm	7nm
FP32	0.9	0.38	3.7	1.31
FP16	0.4	0.16	1.1	0.34
INT8	0.03	0.007	0.2	0.07

표 2: 45nm 및 7nm 공정 노드에서 다양한 비트 표현 방식에 따른 ADD 및 MUL 에너지 소비 [Hor14, ZZL22]

일반적인 트랜스포머 모델에서 $m \times n$ 크기의 행렬 곱셈과 $n \times p$ 크기의 행렬 곱셈을 수행할 때, 에너지 소비는 다음과 같이 계산할 수 있습니다:

$$E_{add} = m \times (n - 1) \times p \times \hat{E}_{add} \quad (16)$$

$$E_{mul} = m \times n \times p \times \hat{E}_{mul} \quad (17)$$

비트넷의 경우, 행렬 곱셈의 에너지 소비는 가중치가 1비트이기 때문에 덧셈 연산에 크게 기인합니다. 곱셈 연산은 주로 3과 a라는 스케일러를 사용하여 출력 값을 조정하는 데 사용되므로, 곱셈 연산에 소요되는 에너지는 다음과 같이 계산할 수 있습니다:

$$E_{mul} = (m \times p + m \times n) \times \hat{E}_{mul} \quad (18)$$

이는 트랜스포머에 비해 훨씬 작습니다. W1A8 BitNet의 전력 효율은 32비트/32비트와 16비트/16비트 정밀도의 트랜스포머와 비교했을 때 표 1에 나와 있습니다. 표 1에서 볼 수 있듯이, BitNet은 특히 행렬 곱 연산에 대한 상당한 전력 절감 효과를 제공합니다.

FP16 트랜스포머와의 비교

3.1 설정

저희는 다양한 규모의 BitNet을 사용하여 여러 개의 자기 회귀 언어 모델을 훈련합니다. 모델은 125M에서 30B까지의 규모로 훈련되며, 훈련 데이터는 Pile, Common Crawl, RealNews, CC-Stories 데이터 세트를 포함한 영어 기반의 데이터 세트를 사용합니다. 데이터 전처리를 위해 SentencePiece 토큰라이저를 사용하며, 어휘 크기는 16K입니다. BitNet 외에도 동일한 데이터 세트와 설정을 사용하여 트랜스포머 기반 모델도 훈련합니다. 자세한 내용은 부록에서 확인할 수 있습니다.

3.2 추론에 최적화된 스케일링 법칙

뉴럴 언어 모델은 기본적인 트랜스포머 아키텍처를 사용하여 예측 가능한 방식으로 확장될 수 있음이 입증되었습니다 [KMHTM~ 20]. 손실은 학습에 사용되는 계산량과 함께 지수적으로 증가합니다. 이를 통해, 우리는 대규모 언어 모델의 성능을 작은 모델에서 예측하고, 또한 최적의 계산 예산을 할당할 수 있습니다.

이진화된 트랜스포머의 스케일링 법칙을 연구하기 위해, 먼저 BitNet과 FP16 트랜스포머의 기본 모델을 파라미터 수에 따라 스케일링 곡선을 그립니다. 학습 토큰 수를 고정하고 모델 크기를 변경합니다. 그림 3은 BitNet의 손실 스케일링이 FP16 트랜스포머와 유사하며, 이는 지수 법칙을 따르는 것을 보여줍니다. 그런 다음, 불변 손실 항을 사용하여 스케일링 법칙을 조정합니다:

$$L(N) = aN^b + c \quad (19)$$




그림 3: BitNet 및 FP16 트랜스포머의 스케일링 곡선

손실을 정확하게 예측할 수 있는지 평가하기 위해, 파워 함수에 맞는 파라미터를 갖는 125M에서 6.7B 모델을 선택하고, 이를 사용하여 13B와 30B 모델의 손실을 예측했습니다. 결과적으로, 선택된 파워 함수에 맞는 모델이 BitNet의 손실을 높은 정확도로 예측했습니다. 또한, 모델 크기가 커짐에 따라 BitNet과 FP16 Transformer 간의 차이가 줄어드는 것을 확인할 수 있었습니다.

위의 파워 법은 BitNet의 스케일링 추세를 측정하지만, 실제 계산과 손실 사이의 관계를 제대로 모델링하지 못합니다. 이전 연구 [KMH*20, HKK*20, HBM*22]는 FLOPs를 계산하여 계산량을 추정합니다. 그러나 이는 정수 계산에 의해 지배되는 1비트 모델에는 적용되지 않습니다. 또한, 이 방법은 주로 추론에 초점을 맞추고 훈련에는 적용되지 않습니다. 신경 언어 모델의 스케일링 효율성을 더 잘 이해하기 위해, 추론 최적 스케일링 법칙을 소개합니다. 이는 에너지 소비에 대한 손실을 예측합니다. 모델의 사용량에 따라 스케일링되는 추론 에너지 비용에 초점을 맞추는 반면, 훈련 비용은 단 한 번만 발생합니다. 2.3절과 같이 에너지 소비를 추정합니다. 그림 3은 7nm 공정 노드에서 추론 에너지 비용에 따른 스케일링 곡선을 보여줍니다. 이는 BitNet이 훨씬 더 높은 스케일링 효율성을 갖는다는 것을 입증합니다. 고정된 계산 예산 하에서, BitNet은 FP16 모델과 비교하여 훨씬 더 나은 손실을 달성합니다. 또한, 동일한 성능을 얻기 위해 FP16 모델보다 훨씬 적은 추론 비용이 필요합니다.

3.3. 파생 작업 결과

손실 외에도, 비트넷의 확장성에 대한 우려도 있습니다. 신경 언어 모델의 특성상 손실 예측보다 능력 예측은 더욱 어렵습니다. 해석 가능한 지표를 사용하여 능력을 평가하기 위해, 우리는 Hellaswag [ZHB* 19], Winogrande [SBBC20], Winograd [LDM12], Storycloze [MCH* 16]를 포함한 네 가지 하위 작업에 대해 0-샷 및 4-샷 결과를 테스트합니다. 그림 4는 다양한 스케일의 BitNet과 FP16 Transformer의 평균 결과를 보여줍니다. 0-샷 및 4-샷 성능 모두에서, 계산 예산이 증가함에 따라 하위 작업에서의 성능도 스케일링될 수 있습니다.

3.4 안정성 테스트

로우 비트 트랜스포머를 훈련하는 주요 과제는 최적화 안정성에 있습니다. 따라서, 다양한 학습률을 가진 여러 모델을 훈련하여 BitNet과 FP16 기반 모델 모두의 안정성 테스트를 수행합니다. 그림 5a는 안정성 테스트 결과의 예시를 보여줍니다. 이 그림은 BitNet이 큰 학습률에서도 수렴할 수 있지만, FP16 트랜스포머는 그렇지 못하며, BitNet의 우수한 훈련 안정성을 보여줍니다. 이러한 최적화의 이점을 통해 더 큰 학습률을 사용할 수 있습니다. 그림 5b는 BitNet이 학습률 증가로부터 혜택을 받을 수 있으며, PPL 측면에서 더 나은 수렴을 달성할 수 있음을 보여줍니다.




그림 4: BitNet과 FP16 Transformer의 제로 샷 (왼쪽) 및 소량 샘플 (오른쪽) 성능 비교.




그림 5: 동일 학습률을 사용한 FP16 트랜스포머보다 BitNet이 더 안정적입니다 (왼쪽). 안정적인 학습 능력 덕분에 BitNet은 더 높은 학습률을 사용할 수 있으며, 이는 더 나은 수렴으로 이어집니다 (오른쪽).

4. 후처리 양자화와의 비교

4.1 설치

우리는 3.1절에 설명된 동일한 설정으로 BitNet을 훈련합니다. 우리는 BitNet을 Absmax [DLBZ22], SmoothQuant [XLS* 23], GPTQ [FAHA23], QuIP [CCKS23] 등 최신 양자화 방법에 따라 비교합니다. 이러한 방법들은 FP16 트랜스포머 모델을 사용하여 훈련 후 양자화를 수행하며, BitNet과 동일한 훈련 설정과 데이터를 사용합니다. 이 중 Absmax와 SmoothQuant는 가중치와 활성화 모두를 양자화하는 반면, GPTQ와 QuIP는 가중치만 양자화합니다. 우리는 다양한 양자화 수준에 이러한 방법을 적용합니다. 가중치만 양자화하는 경우 (즉, GPTQ 및 QuIP)에서는 W4A16 및 W2A16을 사용합니다. 가중치와 활성화 모두 양자화하는 경우 (즉, Absmax 및 SmoothQuant)에서는 FP16 트랜스포머를 W8A8, W4A4, W1A8로 양자화하는 데 사용합니다. 우리의 BitNet 구현은 기본 설정보다 낮은 또는 동일한 비트 수의 8비트 가중치 활성화를 사용합니다 (W1A8).

4.2 결과

표 3는 제안된 방법인 BitNet의 제로 샷 성능에 대한 다양한 기준 방법과의 상세한 비교 분석을 Winogrande, Winograd, Storycloze, Hellaswag이라는 네 가지 벤치마크 데이터셋에 대해 제시합니다. 모든 모델은 공정한 비교를 위해 6.7B의 모델 크기를 가지고 있습니다.




그림 6: BitNet에 대한 제로 샷 (왼쪽) 및 Few-shot (오른쪽) 결과와 후 학습 양자화된 모델을 사용하여 수행된 다운스트림 작업 결과.

WBits	Methods	PTQ	PPL↓	WG↑	WGe↑	HS↑	SC↑	Avg↑
16	Random	✗	-	50.0	50.0	25.0	50.0	43.8
	Transformer	✗	15.19	66.7	54.3	42.9	67.4	57.8
8	Absmax	✓	21.43	60.4	52.0	38.3	62.7	53.4
	SmoothQuant	✓	15.67	65.3	53.1	40.9	67.6	56.7
4	GPTQ	✓	16.05	57.2	51.2	39.9	63.4	52.9
	Absmax	✓	4.8e4	55.8	50.9	25.0	53.1	46.2
	SmoothQuant	✓	1.6e6	53.7	48.3	24.8	53.6	45.1
2	GPTQ	✓	1032	51.6	50.1	25.8	53.4	45.2
	QuIP	✓	70.43	56.1	51.2	30.3	58.4	49.0
1	Absmax	✓	3.5e23	49.8	50.0	24.8	53.6	44.6
	SmoothQuant	✓	3.3e21	50.5	49.5	24.6	53.1	44.4
1	BitNet	✗	17.07	66.3	51.4	38.9	66.9	55.9

3. 비트넷 및 기본 모델(PTQ: 학습 후 양자화, WGe: V 'ande, WG: Winograd, SC: Storycloze, HS: Hellaswag 데이터셋)에 대한 제로샷 결과

이 방법들은 16부터 1까지의 다양한 비트 수준에서 평가됩니다. 또한, 특정 작업에 대한 0샷 정확도 외에도, 검증 세트에 대한 언어 모델의 복잡도를 포함하여 각 방법의 성능에 대한 포괄적인 이해를 제공합니다.

결과는 BitNet이 특히 낮은 비트 수준에서 기본 접근 방식과 비교하여 경쟁 수준의 성능을 달성하는 데 효과적임을 보여줍니다. BitNet의 0-샷 성능은 8-비트 모델과 유사하며, 추론 비용은 훨씬 낮습니다. 4-비트 모델의 경우, 가중치만 사용하는 양자화 방법이 가중치와 활성화 값을 모두 사용하는 양자화 방법보다 우수합니다. 이는 활성화 값을 양자화하는 것이 더 어렵기 때문입니다. 1-비트 모델인 BitNet은 가중치와 활성화 값을 모두 사용하는 방법과 가중치만 사용하는 방법 모두보다 훨씬 더 나은 결과를 달성합니다. 낮은 비트 모델의 경우, BitNet은 모든 기본 모델에 대해 일관되게 더 높은 점수를 기록합니다. 이는 양자화에 대한 인지 훈련 방식이, 훈련 후 양자화 방식보다 더 유리하다는 것을 입증합니다. 그림 6은 1.3B에서 6.7B까지 모델 크기를 확장하면서, BitNet과 기본 모델의 0-샷 정확도 및 몇-샷 정확도를 요약합니다. 이는 다양한 규모에서 장점이 일관되게 나타난다는 것을 보여줍니다.

Methods	PPL↓	HS↑	WGe↑	WG↑	SC↑	Avg↑
<i>Zero-Shot Learning</i>						
BitNet	20.34	33.2	52.1	60.7	63.2	52.3
Elastic + Pre-LN	24.05	29.6	52.9	56.8	61.3	50.2
Absmax + Pre-LN	22.11	31.6	50.0	61.8	61.6	51.3
Absmax + BMT	22.98	31.2	52.1	60.4	62.7	51.6
<i>Few-Shot Learning</i>						
BitNet	20.34	33.5	50.4	62.1	63.8	52.5
Elastic + Pre-LN	24.05	29.9	51.7	57.5	61.1	50.1
Absmax + Pre-LN	22.11	31.4	51.9	63.9	61.6	52.2
Absmax + BMT	22.98	31.3	51.5	57.5	62.6	50.7

표 4: BitNet의 저자거(WGe: Winogrande, WG: Winograd, SC: Storycloze, HS: HellaSwag, 메모리넷) Elastic는 [LOP* 22]에서 제시된 활성화 양자화 방법이며, BMT는 [ZGC* 23]에서 제시된 아키텍처 및 온비트 모델의 학습 안정성을 향상하기 위한 것임이다.

5. 절제 연구

표 4에서는 저희가 사용한 방법과 여러 대안 방법과의 비교 연구 결과를 제시합니다. 저희는 활성화 량 정규화 방법을 사용했을 때의 효과를 분석하고, 모델 훈련의 안정성을 확보하기 위한 기술을 평가합니다. BitNet은 absmax를 사용하여 활성화 량을 정규화하고, SubLN을 사용하여 훈련 안정성을 확보합니다. absmax를 사용한 또 다른 정규화 방법은 탄성 함수 [LOP* 22]로, 학습 가능한 매개변수를 사용하여 동적으로 스케일을 조정합니다. 저희 실험 결과, absmax가 탄성 함수보다 더 나은 성능을 보인다는 것을 확인했습니다. 또한, absmax는 BitNet에서 더 안정적인 훈련을 가능하게 하여 더 큰 학습률을 사용하도록 합니다. 저희는 SubLN을 Pre-LN과 BMT 아키텍처 [ZGC* 23]와 비교합니다. Pre-LN은 GPT의 기본 아키텍처이며, BMT는 이진 모델의 안정성을 향상시키는 것으로 입증되었습니다. 저희 실험 결과, SubLN이 Pre-LN과 BMT 모두보다 우수한 성능을 보인다는 것을 확인했습니다. 따라서, 저희는 BitNet에서 absmax와 SubLN을 구현으로 선택했습니다.

6. 결론 및 향후 연구

저희는 대규모 언어 모델을 위한 새로운 1비트 Transformer 아키텍트인 BitNet을 소개합니다. 저희의 접근 방식은 확장성과 안정성을 갖도록 설계되었으며, 대규모 언어 모델을 효율적으로 처리할 수 있습니다. 실험 결과, BitNet은 perplexity 및 다운스트림 작업 성능 측면에서 경쟁력 있는 성능을 달성하는 동시에, 기존 모델에 비해 메모리 사용량과 에너지 소비를 크게 줄이는 것으로 나타났습니다. 또한, BitNet은 풀 정밀도 Transformer와 유사한 스케일링 법칙을 따르므로, 성능 및 효율 측면에서 더 큰 언어 모델에도 효과적으로 적용될 수 있습니다. 향후, 저희는 모델 크기와 훈련 단계를 확장하는 BitNet을 개발하는 데 관심을 가지고 있습니다. 또한, BitNet을 RetNet [SDH* 23]과 같은 다른 아키텍처에도 적용하여 대규모 언어 모델을 훈련하는 데 관심을 가지고 있습니다.

참고 문헌

[ADF* 23] 로한 아닐, 앤드류 M. 대이, 오르한 피랫, 멜빈 존슨, 드미트리 레피킨, 알렉산드레 파소스, 시마크 샤케리, 에마누엘 타로파, 페이 그레이, 즈핑 첸, 에릭 추, 등. PaL.M 2 기술 보고서… CoRR, abs/2305.10403, 2023.

[BKH16] 레이 지미 바, 제이미 라이언 키로스, 그리고 조지 에. 힌튼. 층 정규화… CoRR, 2016.

[BLC13] 요슈아 벤지오, 니콜라스 룬랜드, 그리고 에인 셴 C. 코르빌. 조건부 계산을 위한 확률적 뉴런을 통한 기울기 추정 또는 전파. CoRR, abs/1308.3432, 2013.

[BMR* 20] 톰 B. 브라운, 벤자민 맨, 니크 라이더, 메랄리 수비아, 제레드 캡런, 프라풀라 다리왈, 아르빈 nil라칸탄, 프라나브 삼, 기리쉬 사스트리, 앤마 엑셀, 산디니 아가르왈, 에리얼 허버트-보스, 그레첸 크루거, 등. 언어 모델은 소량의 데이터만으로 학습이 가능한 모델입니다. "Advances in Neural Information Processing Systems" 33, 2020.

[B19] 아드리안 블라트와 조르지오스 [지미로폴루]: ANOR-Net++: 개선된 이진 신경망... BMVC 2019, 2019.

[CCKS23] 제리 치, 야오휘 차이, 블로디미르 쿨레쇼프, 크리스토퍼 데 사..QuIP: 대규모 언어 모델의 2비트 양자화, 보장된 성능..CoRR, abs/2307.13304, 2023.

[CND® 22] 아양카샤 chowdhery, 샤란 나랑, 제이크 데블린, 마르틴 보스마, 가우라 미쉬라, 애덤 로버츠, 폴 바햄, 흥원 첵, 찰스 Sutton, 세바스찬 게르만, 파커 슈, 켄센 쉬, 사샤 트스바첵코, 조슈아 메인즈, 아비шек 라오, 파커 바인즈, 이 태, 노암 샤지르, 등. PaLM: 패스웨이를 통한 언어 모델의 확장... CoRR, abs/2204.02311, 2022.

[Dao23] "Dao..FlashAttention-2: 향상된 병렬 처리 및 작업 분할을 통해 더 빠른 어텐션 구현... CoRR, abs/2307.08691, 2023"

[DFE™ 22] 트리 다오, 다니엘 Y. 푸, 스테파노 에르몬, 아트리 루드라, 크리스토퍼 리. FlashAttention: I/O를 고려한 빠르고 메모리 효율적인 정확한 어텐션. NeurIPS, 2022.

[DLBZ22] 짐 뎀터스, 마이크 루이스, 유네스 벨카다, luk Zettlemoyer. LLM.int8(): 대규모 트랜스포머를 위한 8비트 행렬 곱셈. CoRR, 2022.

[FAHA23] 엘리야스 프란타, 살레 아쉬브스, 토르스 뢰플러, 단 알리스타... OPTQ: 생성형 사전 훈련된 트랜스포머를 위한 정확한 양자화... 2023년 제11회 국제 학습 표현 컨퍼런스

{HBM*™ 22} 조던 호프먼, 세바스찬 보르가우드, 아서 멘쉬, 엘레나 부차츠카야, 트레버 카이, 엘리자 루서포드, 디에고 데 라스 카사스, 리사 앤 헨드릭스, 요한스 웰블, 에이단 클락, 톰 헨니건, 에릭 놀랜드, 케이트 밀리칸, 조지 반 덴 드리스체, 보그단 다모크, 오렐리아 가이, 사이먼 오신데로, 케렌 시모야, 에릭 엘센, 잭 윌레이, 오리오 비냐스, 그리고 로랑 시프..계산 효율성을 극대화한 대규모 언어 모델 훈련..CoRR, abs/2203.15556, 2022.

[HKK* 20] 톰 헨니건, 제러드 캡lan, 모르 카츠, 마크 첸, 크리스토퍼 헤스, 제이콥 잭슨, 히우우 준, 톰 B. 브라운, 프라풀라 다리왈, 스콧 그레이, 크리스 헬라시, 벤자민 맨, 알렉 래드포드, 아디타 람세, 닉 라이더, 다니엘 M. 지글러, 존 술만, 다리오 아마데이, 그리고 샘 맥캔들리스. 자기 회귀 생성 모델에 대한 스케일링 법칙... CoRR, abs/2010.14701, 2020.

[호롤4] 마크 호로비츠, "컴퓨팅 분야의 에너지 문제 (그리고 그에 대한 해결책)"... 2014년 IEEE 국제 고체 상태 회로 컨퍼런스 (ISSCC), 샌프란시스코, 캘리포니아, USA, 2014년 2월 9일~13일, 10~14페이지, 2014.

[KLZ™ 23] 우수크 권, 주한 리, 시원 Zhuang, 잉 성, 리민 정, 코디 하오 유, 조셉 E. 곤잘레스, 하오 장, 그리고 아이온 스토이카. 페이지 기반의 주의 메커니즘을 활용한 대규모 언어 모델 서비스에 적합한 효율적인 메모리 관리. CoRR, 2023.

[KMH™ 20] 제러드 캡lan, 샘 맥캔들리, 톰 헨니건, 톰 B. 브라운, 벤자민 체스, 류원 찰드, 스콧 그레이, 알렉 래드포드, Jeffrey Wu, 그리고 다리오 아마데이. 신경망 언어 모델의 확장 법칙... CoRR, abs/2001.08361, 2020.

[LLDM12] 헥터 레베스크, 에른스트 데이비스, 그리고 레오라 모르겐스텐. "원그라드 스키마 챌린지"... 제13회 지식 표현 및 추론 원칙 국제 회의... CiteSeer, 2012.

[LKM23] 야니 레비아탄, 마탄 칼만, 요시 마티아스. 트랜스포머를 이용한 빠른 추론을 통한 추론... 2023년 7월 23일부터 29일까지, 하와이 호놀룰루, 미국에서 개최되는 국제 머신러닝 학회 (ICML 2023) 발표.

[LOP* 22] 즈충 류, 바라스 오구즈, 아시쉬 파푸, 린 시아오, 스콧 야, 멩 리, 라구라마난 크리슈나모르티, 야샤르 메드하. Bit: 견고하게 이진화된 다중 증류 트랜스포머. NeurIPS, 2022.

[LSL*21] 제충 리우, 지양 선, 시차 리, 코엔 헬웨겐, 동 흥, 강팅 씸. 'LSL' 방법과 훈련 전략이 BNNS 최적화에 어떻게 기여하는가? 2021년 7월 18일부터 24일까지 개최된 제38회 국제 머신러닝 학회(ICML 2021), 온라인 행사, 머신러닝 연구 학회(Proceedings of Machine Learning Research) 139권, 6936-6946페이지. PMLR, 2021.

[MCH™ 16] 나스린 모스타파자데, 나탄넬 챔버스, 시아둥 헤, 데비 파리크, 드루 바트라, 루시 반더웨인, 푸쉬밋 콜리, 제임스 F. 앨런. 보편적인 상식 기반 이야기의 심층적인 이해를 위한 코퍼스 및 평가 프레임워크. CoRR, abs/1604.01696, 2016.

{Ope23| OpenAI..GP 1-4 기술 보고서..CoRR, abs/2303.08774, 2023년}

[RORF16] 모하메드 라스테가리, 비센테 오르도네스, 조셉 레드몬, 그리고 알리 파라디. XNOR-Net: 이진 컨볼루션 신경망을 이용한 ImageNet 분류. 컴퓨터 비전 - ECCV 2016 - 14회 유럽 학회, 암스테르담, 네덜란드, 2016년 10월 11일-14일, Proceedings, Part IV, Lecture Notes in Computer Science, 2016.

[SBBC20] 사쿠치 케이스케, 로난 르 브르, 찬드라 바가바툴, 그리고 예진 초이. 대규모 Winograd 세마 기반의 적대적 챌린지: Wino-Grande. "34회 인공지능 학회(AAI)"에서, 8732-8740페이지, 2020년.

[SDH™23] 유타오 썬, 리동, 샤오한 흥, 슈밍 마, 유칭 알타, 지룽 쑤, 지양용 왕, 푸루 웨이. "Retentive 네트워크: 대규모 언어 모델을 위한 트랜스포머의 후속 기술, 2023."

LSPP™ 19] 모하마드 쇼이비, 모스타파 파트와리, 랄 폴, 패트릭 르그레슬리, 제러드 캐스퍼, 브라이언 카탄자로. Megatron-LM: 모델 병렬 방식을 사용하여 수십억 개의 매개변수를 갖는 언어 모델 훈련. CoRR, abs/1909.08053, 2019.

[ELI"23] 호고 루브론, 티바트 라브릴, 고티에 이자카드, 샤비에 마르티네, 마리-안 르샤우, 팀오티에 락스크로, 바티스트 로지에, 나만 고얄, 에릭 햄브로, 파 아자르, 오렐리엔 로드리게스, 아르망 주린, 에두아르 그라브, 그리고 윌리엄 램플..LLaMA: 개방적이고 효율적인 기반 언어 모델..CoRR, abs/2302.13971, 2023.

[IMS*23] 호고 루브론, 루이스 마틴, 케빈 스톤, 피터 알베르트, 아마드 알마헤리1, 야스민 바바이, 니콜라이 바슬리코프, 수미 바트라, 프라즈왈 바르가바, 슈루 Bhosle, 댄 비켈, 루카스 블레셔, 크리스티안 칸톤 페레, 모야 첸, Guillem Cucurull, 데이비드 에시오부, 주데 폰데라스, 제레미 푸, 등. Llama 2: 오픈 기반 및 미세 조정된 챗 모델... CoRR, abs/2307.09288, 2023.

[WH20] 유신 우와 카밍 헤... 그룹 정규화../nt.. J. Comput. Vis., 128(3): 42-755, 2020.

[WMH* 22] 홍유 왕, 슈밍 마, 샤오한 황, 리동, 웬휘 왕, 즈리앙 팡, 유우, 페일 바자, 사크삼 싱할, 알론 베나임, 바룬 파트라, 주니 류, 비슈라 차우드하, 샤오 송, 그리고 푸루 웨이.. 기반 트랜스포머.. CoRR, 2022.

[XLS*™23] 광수안 X1ao, 지린, 미셸 세즈네크, 하오 우, 줄렌 demeouth, 송한. SmoothQuant: 대규모 언어 모델을 위한 정확하고 효율적인 후 학습 정량화 기술. 2023년 7월 23일부터 29일까지, 2023년 하와이 호놀룰루, 미국, ICML 2023 국제 머신러닝 학회

[ZGC* 23] 아이치 장, 안쿠쉬 가르, 류안 차오, 루카쉬 레브, 베로즈 고르바니, 지루 장, 오르한 피라트... 정형화된 신경망 기계 번역... CoRR, 2023.

[ZHB* 19] 로언 젤러스, 아리 홀츠만, 요타난 비스크, 알리 파라디, 예진 최. HellaSwag: 기계가 정말로 문장을 완성할 수 있을까요? In Proceedings of the 57th Conference of the Association for Computational Linguistics, 4791-4800페이지, 2019.

[ZZL22] | 야치 장, 지루 장, 루카슈 레브. "PokeBNN: 경량화된 정확성을 위한 이진적 접근 방식" IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스, 12465-12475 페이지 IEEE, 2022.

하이퍼파라미터

Params	# Hidden	# Layers	# Heads	Learning Rate
125M	768	12	12	2.4e-3
350M	1024	24	16	1.2e-3
760M	1536	24	16	1e-3
1.3B	2048	24	32	8e-4
2.7B	2560	32	32	6.4e-4
6.7B	4096	32	32	4.8e-4
13B	5120	40	40	4e-4
30B	7168	48	56	4e-4

표 5: 스케일링 실험에서 BitNet 모델 구성

Hyperparameters	Value
Training updates	40K
Tokens per sample	256K
Adam β	(0.9, 0.98)
Learning rate schedule	Polynomial decay
Warmup updates	750
Gradient clipping	$\times$
Dropout	$\times$
Attention dropout	$\times$
Weight decay	0.01

표 6: 스케일링 실험에서 BitNet 및 FP16 트랜스포머의 하이퍼파라미터. 13B 및 30B 모델의 경우, 훈련 안정성을 위해 가중치 감쇠를 0.05로 설정했습니다.

Hyperparameters	Value
Peak learning rate	1e-3
Tokens per sample	128K
Adam β	(0.9, 0.98)
Learning rate schedule	Polynomial decay
Warmup updates	750
Gradient clipping	$\times$
Dropout	$\times$
Attention dropout	$\times$
Weight decay	0.01

표 7: BitNet 및 FP16 트랜스포머의 안정성 테스트를 위한 하이퍼파라미터

Hyperparameters	Elastic	Absmax
Peak learning rate	1e-4	8e-4
Training updates		40K
Tokens per sample		256K
Adam β		(0.9, 0.98)
Learning rate schedule	Polynomial decay	
Warmup updates		750
Gradient clipping		$\times$
Dropout		$\times$
Attention dropout		$\times$
Weight decay		0.01

표 8: BitNet의 제거 실험을 위한 하이퍼파라미터