




-TO
T
PO
LI ['
TO'
S9]
TAS
SrIT
OLe
z:At
xie

Abstract

Figure 1 is a line graph showing the relationship between Training WBits (Y-axis) and Inference WBits (X-axis). The Y-axis ranges from 1 to 16, and the X-axis ranges from 16 to 1. A dashed blue line labeled "Training from Scratch" represents the identity line (y=x). BitNet is marked with a red star at (1, 1). Other points include FP8 at (8, 8), FP16/BF16 at (16, 16), and SmoothQuant, GPTQ, and QulP at (4, 16). The region below the dashed line is labeled "Post-Training Quantization".



“평등한 기여도. 주제저자.

6 I don't think there's anything unique about human intelligence. All the neurons in the brain 9 9
that make up perceptions and emotions operate in a binary fashion.

윌리엄 헨리 게이츠 2세

1 Introduction

대형 언어 모델의 급속한 성장[BMR™* 20, Ope23, CND*22, ADF* 23, TLI" 23, TMS+* 23]은 다양한 과제의 상당한 개선을 이끌어냈다. 다만, 고비용 추론 비용과 에너지 소비로 인해 대규모 언어 모델을 호스팅하는 데 비용이 많이 든다. 이 모델들의 사이즈가 커짐에 따라 모델 파라미터들을 액세스하고 프로세싱하기 위해 요구되는 메모리 대역폭이 주요한 병목이 되어 전체적인 추론 성능을 제한한다. 더욱이, 분산 시스템 또는 다중 디바이스 플랫폼 상에 이러한 모델을 전개할 때, 디바이스 간 통신 오버헤드는 추론 지연 및 에너지 소비에 상당한 영향을 미칠 수 있다. 모델 양자화 [FAHA23, CCKS23, XLS* 23]는 경쟁 성능을 유지하면서도 대규모 모델의 메모리 풋프린트 및 계산 비용을 크게 줄일 수 있어 유망한 해결책으로 부상했다.

대규모 언어 모델에 대한 기존의 대부분의 양자화 접근법은 사후 훈련이다. 이들은 트레이닝 파이프라인에 어떠한 변경도 필요하지 않으며 모델을 재훈련하는 것도 필요하지 않기 때문에 간단하고 적용하기 쉽다. 그러나, 특히 정밀도가 더 낮아질 때, 모델은 트레이닝 동안 양자화된 표현에 대해 최적화되지 않기 때문에 보다 더 큰 정확도의 손실을 초래할 것이다.

양자화 깊은 신경망들(1s)의 양자화의 다른 가닥은 양자화-지각 학습이다. 훈련 후와 비교하여, 일반적으로, 모델이 초기부터 감소된 정밀도를 고려하도록 훈련되기 때문에 더 나은 정확도를 초래한다. 더욱이, 그것은 대형 언어 모델에 필수적인, 모델이 지속-훈련하거나 미세 조정을 하도록 한다. 양자화 인식 트레이닝의 문제는 주로 최적화에 있으며, 즉, 정밀도가 더 낮아질수록 모델이 수렴하기 더 어렵게 된다. 게다가, 양자화 인식 학습이 신경 언어 모델의 스케일링 법칙을 따르는지 여부는 알려져 있지 않다.

이 작업에서는, 양자화(즉, 1비트)의 경우에 초점을 맞추며, 이는 양자화의 극한 경우이며, 대규모 언어 모델에 적용된다. 이진화 신경망에 대한 이전 연구 [RORF16, BT19]는 대부분 컨볼루션 신경망을 중심으로 이루어졌다. 최근 이진화된 변환기들에 대한 연구가 일부 이루어지고 있다. 하지만 이들 연구는 기계번역이나 BERT 사전 학습에 초점이 맞춰져 있어 대규모 언어모델과는 사뭇 다른 특징을 가지고 있다. 예를 들어, 기계 번역은 인코더-디코더 아키텍처를 사용하고, BERT의 사전 훈련은 양방향 인코더를 사용하며, 대형 언어 모델은 단방향 디코더를 사용한다. 또, 대형 언어 모델은 통상적으로 상당히 더 큰 모델 크기로 스케일링되는 반면, BERT 및 기계 번역 모델은 그러한 광범위한 스케일링을 거치지 않는다.

우리가 아는 한, 이 작업은 1비트 대규모 언어 모델에 대한 양자화 인지 트레이닝을 조사하는 첫 번째이다. 우리는 메모리와 연산 측면 모두에서 효율적으로 스케일링할 수 있는 대형 언어 모델을 위한 1비트 트랜스포머 아키텍처인 비트넷을 제안한다. BitNet은 낮은 정밀도의 이진 가중치와 양자화된 활성화를 사용하는 반면, 훈련 동안의 최적화기 상태 및 경사도에 대해 높은 정밀도를 유지한다. 우리의 접근법은 대형 언어 모델을 효율적으로 처리할 수 있는 능력을 갖추고 확장 가능하고 안정적이도록 설계되었다. BitNet 아키텍처의 구현은 상당히 단순하며, 트랜스포머 내의 선형 프로젝션(즉, PyTorch의 nn.Linear)의 교체만을 필요로 한다. 더욱이, PagedAttention[KLZ*23], FlashAttention[DFEt22, Dao23], 및 사변적 디코딩[LKM23]과 같은 대형 언어 모델에 대한 다른 가속화 방법을 보완한다.

우리는 현재 최고 수준의 양자화 방법 및 FP16 트랜스포머와 비교하여 언어 모델링 벤치마크의 범위에서 BitNet을 평가한다. 실험 결과는 비트넷이 복잡도와 다운스트림 작업 정확도 모두에서 경쟁적인 성능을 달성한다는 것을 보여준다. 더 중요한 것은, BitNet이 베이스라인들에 비해 메모리 풋프린트 및 에너지 소비를 현저하게 감소시킨다는 것이다. 또한, 우리는 BitNet가 플-정밀성 트랜스포머들과 유사한 스케일링 법칙을 따른다는 것을 보여주며, 이는 성능과 효율 측면에서 잠재적인 이점을 갖는 더 큰 언어 모델들에 효과적으로 스케일링될 수 있음을 나타낸다.




그림 2: (a) BitLinear의 연산 흐름을 보여준다. (b) 비트네트의 아키텍처는 행렬 곱셈이 비트리니어로 구현되는 어텐션과 FFN의 스택으로 구성된다.

2 BitNet

BitNet는 그림 2와 같이 Transformer와 동일한 레이아웃을 사용하고 있으며, 셀프-어텐션과 피드-포워드 네트워크의 블록을 쌓는다. 비탄니언 트랜스포머와 비교했을 때, 비트넷은 비트리니어를 이용하여 (Eq. 1) 이진화된 (즉, 1비트) 모델 가중치를 채용하는 기존의 행렬 곱셈 대신에, 이다. 우리는 다른 성분들을 우리의 실험에서 고정밀, 예를 들어 8비트로 둔다. 그 이유를 다음과 같이 요약하였다. 첫 번째로, 잔여 연결과 계층 정규화는 큰 언어 모델에 미미한 연산 비용을 기여한다. 둘째로, QKV 변환의 계산 비용은 모델이 커짐에 따라 파라미터 프로젝트보다 훨씬 작다. 셋째, 언어 모델은 샘플링을 수행하기 위해 고정밀도 확률을 사용해야 하기 때문에 입력/출력 임베딩의 정밀도를 보존한다.

2.1 BitLinear

우리는 가중치를 부호 함수로 +1이나 -1로 이진화한다. [LOP(22)] 에 이어, 우리는 제한된 수치 범위 내에서 용량을 증가시키기 위해 이진화하기 전에 가중치를 0-평균으로 중앙 집중화한다. 스케일링 팩터는 실수 값과 이진화된 가중치 간의 오차를 줄이기 위해 이진화 후에 사용된다. 가중치 $W \in \mathbb{R}^{n \times m}$ 의 이진화는 다음과 같이 공식화될 수 있다.

$$\widetilde{W} = \text{Sign}(W - \alpha), \quad (1)$$

$$\text{Sign}(W_{ij}) = \begin{cases} +1, & \text{if } W_{ij} > 0, \\ -1, & \text{if } W_{ij} \leq 0, \end{cases} \quad (2)$$

$$\alpha = \frac{1}{nm} \sum_{ij} W_{ij} \quad (3)$$

우리는 활성화들을 b-비트 정밀도로 양자화한다. DLBZ22에 이어, 우리는 Q와 곱하여 활성화를 $[-Q_y, Q_o]$ ($Q_y=2^{b-1}$) 범위로 스케일링하고 입력 행렬의 절대 최대값으로 나눈 absmax 양자화를 사용한다.

$$\tilde{x} = \text{Quant}(x) = \text{Clip}\left(x \times \frac{Q_b}{\gamma}, -Q_b + \epsilon, Q_b - \epsilon\right), \quad (4)$$

$$\text{Clip}(x, a, b) = \max(a, \min(b, x)), \quad \gamma = \|x\|_{\infty}, \quad (5)$$

여기서 ϵ 는 클리핑 수행 시 오버플로우를 방지하는 소수점 숫자이다.

비선형 함수(예: ReLU) 이전의 활성화들은 모든 값들이 비음수일 수 있도록 입력들의 최솟값을 뺀 때, 그들을 범위 $[0, Q_p]$ 으로 스케일링한다.

$$\tilde{x} = \text{Quant}(x) = \text{Clip}((x - \eta) \times \frac{Q_b}{\gamma}, \epsilon, Q_b - \epsilon), \quad \eta = \min_{ij} x_{ij}. \quad (6)$$

본 연구에서는 활성화를 8비트로 양자화하고 향후 연구에서 보다 낮은 정밀도를 남긴다. 더구나요. 정량화는 안정성과 효율성 모두를 위해 훈련 시 텐서당, 추론 시 토큰당 수행된다.

위 양자화 방정식으로 행렬 곱셈은 다음과 같이 쓸 수 있다.

$$y = W\tilde{x} \quad (7)$$

우리는 W와 x에 속한 원소들이 서로 독립적이며 동일한 분포를 가지고 있으며, W와 z는 서로 독립적이라고 가정한다. 그렇다면 출력값 y의 분산은 다음과 같이 추정된다.

$$\text{Var}(y) = n\text{Var}(\tilde{w}\tilde{x}) \quad (8)$$

$$= nE[\tilde{w}^2]E[\tilde{x}^2] \quad (9)$$

$$= n\beta^2 E[\tilde{x}^2] \approx E[\tilde{x}^2] \quad (10)$$

완전-정밀 계산을 위해, 표준 초기화 방법(예: Kaiming 초기화 또는 Xavier 초기화)으로 1의 스케일에서 출력 Var(y) 1s의 분산은 학습 안정성에 큰 이점을 갖는다. 양자화 후 분산을 보존하기 위해, 우리는 활성화 양자화 이전에 LayerNorm [BKH16] 함수를 도입한다. 이렇게 하면 산출치 y의 분산은 Var(y) ~ E[LN(Z)?]로 추정된다. = 1로 완전정밀도 대응인 Var(y)와 크기가 동일하다. 트랜스포머들의 맥락에서는 SubLN[WMH*22]과 정확한 구현을 갖는다. 위의 SubLN 및 양자화 방법으로 우리는 BitLinear을 가지게 되는데, 이것은 다음과 같이 정의된다.

$$y = \tilde{W}\tilde{x} = \tilde{W} \text{Quant}(\text{LN}(x)) \times \frac{\beta\gamma}{Q_b} \quad (11)$$

$$\text{LN}(x) = \frac{x - E(x)}{\sqrt{\text{Var}(x) + \epsilon}}, \quad \beta = \frac{1}{nm} \|W\|_1 \quad (12)$$

그림 2는 비트리니어의 계산 흐름을 보여준다. SubLN 연산 후, 활성화들은 absmax 함수로 양자화된다. 매트릭스 곱셈은 1-비트 가중치들과 양자화된 활성화들 사이에서 수행된다. 출력 활성화들은 원래의 정밀도로 디퀀터화되도록 {8,-y}로 재스케일링된다.

그룹 양자화 및 정규화와의 모델 병렬화 대형 언어 모델을 스케일업하기 위한 중요한 기술은 다중 장치에서 행렬 곱셈을 분할하는 모델 병렬화[SPP* 19]이다. 기존 모델 병렬 접근법에 대한 전제 조건은 텐서가 분할 차원을 따라 독립적이라는 것이다. 하지만, 매개변수 a, 3, y, 77은 모두 전체 텐서로부터 계산되므로, 독립적인 전제조건을 깨뜨린다. 하나의 해결책은 각 파라미터에 대한 하나의 전체-축소 연산을 도입하는 것이다. 그러나 파라미터 별 커뮤니케이션은 작음에도 불구하고 모델이 깊어질수록 동기화의 양이 커지고, 이는 포워드 패스를 현저하게 느리게 한다. 또한 SubLN에서도 분할 차원에 걸쳐 평균과 분산을 추정해야 하는 문제가 존재한다.

이를 위해, 우리는 모델의 병렬성을 보다 효율적으로 만드는 간단한 접근법을 제안한다. 우리는 가중치와 활성화를 그룹으로 나누고 그룹별 매개변수를 독립적으로 추정한다. 이 방식으로, 파라미터들은 추가의 통신을 필요로 하지 않고 로컬적으로 계산될 수 있다. 그룹 양자화라고 불리는 이 접근법은 다음과 같이 공식화된다.

가중치 행렬 $W \in \mathbb{R}^{n \times m}$ 에 대해, 분할 차원을 따라 G개의 그룹으로 나누고, 각 그룹은 $\frac{n}{G} \times m$ 의 크기를 가지며, 각 그룹에 대한 파라미터를 독립적으로 추정한다.

$$\alpha_g = \frac{G}{nm} \sum_{ij} W_{ij}^{(g)}, \quad \beta_g = \frac{G}{nm} \|W^{(g)}\|_1, \quad (13)$$

Models	Size	WBits	7nm Energy (J)		45nm Energy (J)	
			MUL	ADD	MUL	ADD
Transformer	6.7B	32	4.41	1.28	12.46	3.03
BitNet		16	1.14	0.54	3.70	1.35
BitNet		1	0.02	0.04	0.08	0.13
Transformer	13B	32	8.58	2.49	24.23	5.89
BitNet		16	2.23	1.05	7.20	2.62
BitNet		1	0.04	0.06	0.12	0.24
Transformer	30B	32	20.09	5.83	56.73	13.80
BitNet		16	5.21	2.45	16.87	6.13
BitNet		1	0.06	0.14	0.20	0.53

표 1: BitNet과 변압기의 에너지 소비는 상이한 모델 크기를 변화시킨다. 입력 길이는 512로 결과를 보고한다.

여기서 W^g 는 가중치 행렬의 g 번째 그룹을 나타낸다. 유사하게, 활성화에 대해, 우리는 입력 행렬 $\ll \epsilon R^*$ 으로부터 G 개의 그룹으로 나누어 각 그룹에 대한 매개변수를 계산할 수 있다.

$$\gamma_g = \|x^{(g)}\|_\infty, \quad \eta_g = \min_{ij} x_{ij}^{(g)} \quad (14)$$

LN의 경우, 각 그룹에 대해 평균과 분산을 독립적으로 계산하기 위해 그룹 정규화 기술 [WH20]을 적용할 수 있다.

$$\text{LN}(x^{(g)}) = \frac{x^{(g)} - E(x^{(g)})}{\sqrt{\text{Var}(x^{(g)}) + \epsilon}} \quad (15)$$

이러한 방식으로, 우리는 추가적인 통신을 필요로 하지 않으며 대형 언어 모델들로 스케일링할 수 있는 Group Quantization과 Normalization으로 모델 병렬화를 효율적으로 구현할 수 있다.

2.2. Model Training

스트레이트-스루 추정량을 사용합니다. 우리의 1-비트 모델을 훈련시키기 위해, 우리는 역전파 동안의 기울기를 근사화하기 위해 직진 통과 추정기 (STE)[BLC13]를 채용한다. 이 방법은 Sign(Eq. 2. 2. 3)과 같은 미분할 수 없는 함수들을 우회한다. 2)와 클립(Eq. 5) 백워드 패스 동안, 함수들을 수행한다. STE는 비미분 함수의 영향을 받지 않고 그레디언트가 네트워크를 통해 흐르도록 허용하여 우리의 양자화된 모델을 훈련할 수 있게 한다.

혼합된 정밀도 훈련. 가중치들 및 활성화들은 낮은 정밀도로 양자화되면서, 그레디언트들 및 최적화기 상태들은 훈련 안정성 및 정확도를 보장하기 위해 높은 정밀도로 저장된다. 이전 작업 [LSL* 21]에 이어, 우리는 파라미터 업데이트를 누적하기 위해 학습 가능한 파라미터에 대한 고정밀도 형식의 잠재 가중치를 유지한다. 잠재 가중치는 포워드 패스 동안에 일회적으로 이진화되며, 추론 프로세스에 절대 사용되지 않는다.

학습 속도가 빨라졌다. 최적화에 대한 한 가지 과제는 잠재 가중치들에 대한 작은 업데이트가 종종 1-비트 가중치들에 아무런 차이가 없는 경우라는 것이다. 이것은 1비트 가중치들에 기초하여 추정되는 편향된 기울기 및 업데이트를 초래한다. 모델들이 최대한 빨리 수렴해야 할 훈련 초기에는 이 문제가 더욱 심각하다. 이 문제를 해결하기 위해 우리는 다양한 방법을 탐색하며, 최적화의 속도를 높이는 것이 최단 시간에 최적화하는 가장 간단하고 좋은 방법이라고 결론지었다. 우리의 실험은 BitNet이 수렴 측면에서 큰 학습 속도에 의해 혜택을 받는 반면 FP16 Transformer은 동일한 학습 속도로 훈련의 초기에 발산한다는 것을 보여준다. 세부적인 내용은 3절에서 자세히 살펴볼 수 있다.

2.3 Computational Efficiency

우리는 BitNet의 계산 효율성을 연산 연산 에너지와 메모리 푸트프린트 두 가지 측면에서 추정한다. 우리는 주로 대형 언어 모델의 비용에 가장 큰 기여를 하는 행렬 곱셈에 대한 계산에 초점을 맞추고 있다.

연산을 통해 에너지를 얻습니다. [Hor14, ZZL22]의 에너지 모델에 따르면, 상이한 연산을 위한 에너지 소비는 다음과 같이 추정될 수 있다.

Bits	ADD Energy $\hat{E}_{add}$ (pJ)		MUL Energy $\hat{E}_{mul}$ (pJ)	
	45nm	7nm	45nm	7nm
FP32	0.9	0.38	3.7	1.31
FP16	0.4	0.16	1.1	0.34
INT8	0.03	0.007	0.2	0.07

표 2: 45nm 및 7nm 공정 노드에서의 상이한 비트 표현에 대한 ADD 및 MUL 에너지 소비량 [Hor14, ZZL22]

바닐라 트랜스포머에서는 $m \times n$, $n \times p$ 의 차원을 가진 행렬 곱셈을 위해 에너지 소비량은 다음과 같이 계산할 수 있다.

$$E_{add} = m \times (n - 1) \times p \times \hat{E}_{add} \quad (16)$$

$$E_{mul} = m \times n \times p \times \hat{E}_{mul} \quad (17)$$

비트넷의 경우, 웨이트가 1비트이므로 행렬 곱셈의 에너지 소비는 덧셈 연산에 의해 지배된다. 곱셈 연산들은 스케일러 3과 a를 사용하여 출력을 스케일링하기 위해만 적용되므로 곱셈에 대한 에너지 소비는 다음과 같이 계산될 수 있다.

$$E_{mul} = (m \times p + m \times n) \times \hat{E}_{mul} \quad (18)$$

이는 변환기에서 보다 현저하게 작다. W1A8 BitNet의 전형(32-32) 및 반형(16-16) 변환기 대비 에너지 절감을 표 1에 나타내었다. 알 수 있듯이, BitNet는 특히 행렬 곱셈 에너지 소비의 주요 구성 요소인 곱셈 연산에 상당한 에너지 절감을 제공한다.

3 Comparison with FP16 Transformers

3.1 Setup

우리는 125M부터 30B까지 다양한 스케일의 비트넷으로 일련의 자기회귀 언어 모델을 훈련한다. 모델들은 영어 언어 코퍼스, Pile 데이터세트, Common Crawl 스냅샷, RealNews, CC-Stories 데이터 세트로 구성된다. Sentencpiece tokenizer를 사용하여 데이터를 전처리하고 어휘 크기는 16K이다. 비트넷 외에도 공정한 비교를 위해 동일한 데이터세트와 설정으로 변형기 베이스라인을 훈련한다. 보다 자세한 내용은 부록에서 확인할 수 있다.

3.2 Inference-Optimal Scaling Law

신경 언어 모델은 베이컨Transformer 아키텍처로 예측 가능하게 스케일링하는 것이 입증되었다. 손실은 트레이닝에 사용된 계산량에 따라 파워 로와 같이 규모가 커진다. 이것은 우리가 연산 예산의 최적 할당을 결정하는 것은 물론, 작은 모델로부터의 큰 언어 모델의 성능을 예측할 수 있도록 해준다.

이진화된 트랜스포머의 스케일링 법칙을 연구하기 위해, 우리는 먼저 파라미터 카운트에 대한 BitNet 및 FP16 트랜스포머 베이스라인의 스케일링 곡선을 그리는 것으로 시작한다. 우리는 훈련 토큰의 수를 고정하고 모델의 크기를 달리한다. 그림 3은 BitNet의 손실 스케일링이 FP16 Transformer와 유사하며, 이는 파워-law를 따른다는 것을 보여준다. 그런 다음 우리는 축소 법칙을 감소할 수 없는 손실 항과 함께 맞춘다.

$$L(N) = aN^b + c \quad (19)$$




그림 3: BitNet와 FP16 Transformer의 스케일링 곡선이다.

스케일링 법칙이 손실을 정확하게 예측할 수 있는지 평가하기 위해 125M에서 6.7B의 모델을 선택하여 파워로의 매개변수에 맞게 하며 13B와 30B의 손실을 예측하는 법칙을 사용한다. 피팅된 스케일링 법칙이 BitNet의 손실을 높은 정확도로 예측했다는 것을 보여준다. 또한 모델 크기가 커질수록 비트넷과 FP16 트랜스포머 사이의 격차가 더 작아진다.


위의 파워-로법은 비트넷의 스케일링 경향을 측정하지만 손실과 실제 컴퓨팅 사이의 관계를 제대로 모델링하지는 못한다. 이전 작업 [KMH*20, HKK*20, HBM*22]은 FLOPs 계산에 의해 컴퓨팅을 추정한다. 단, 비용이 정수 계산에 의해 지배되는 1비트 모델에는 적용되지 않는다. 더욱이, 그것은 주로 추론보다는 훈련 계산을 측정한다. 신경 언어 모델의 스케일링 효율성을 더 잘 이해하기 위해, 우리는 추론-최적 스케일링 법칙을 도입한다. 이것은 에너지 소비에 대한 손실을 예측한다. 우리는 추론 에너지 비용에 집중하는데, 이는 모델의 사용에 따라 스케일링되는 반면, 훈련 비용은 단 한 번이다. 우리는 2.3절에서와 같이 에너지 소비량을 추정한다. 그림 3은 7nm 공정 노드에서 추론 에너지 비용에 대한 스케일링 곡선을 나타낸다. 비트넷이 훨씬 높은 스케일링 효율을 가졌다는 것을 증명한다. 고정된 계산 예산을 가지고, 비트넷은 훨씬 더 우수한 손실을 달성한다. 한편, FP16 모델과 동일한 성능을 얻기 위해 추론 비용이 훨씬 적다.

3.3. Results on Downstream Tasks


손실과 함께 비트넷의 규모화에 따른 역량도 우려된다. 손실에 비해 신경 언어 모델의 부상성으로 인해 용량 예측이 더 어렵다. 해석 가능한 측정치로 능력을 평가하기 위해, 0-샷과 4-샷 결과를 헬라스왑 [ZHB*19], 위노그란드 [SBBC20], 위노그란드 [LDM12], 스토리클로즈 [MCH*16]를 포함한 네 가지 하류 작업에 대해 모두 테스트한다. Fig. 4는 다양한 스케일을 가진 BitNet와 FP16 Transformer의 평균 결과를 보고하였다. 손실 스케일링 커브와 유사하게, 하류 작업들에 대한 성능은 계산 예산이 커질수록 스케일링될 수 있다. 게다가, 역량의 스케일링 효율은 FP16 변환 기반보다 훨씬 더 높으며, 제로샷 및 페우샷 성능 모두에서 그렇다.

3.4 Stability Test

저비트 트랜스포머를 훈련시키는 데 있어 주요 과제는 최적화에서의 안정성이다. 따라서, 우리는 피크 학습 속도가 달라지는 일련의 모델을 훈련시킴으로써 비트넷과 FP16 베이스라인 모두에 대한 안정성 테스트를 수행한다. 그림 5a는 안정성 테스트의 결과를 보여준다. BitNet는 큰 학습률로 수렴할 수 있는 반면 FP16 Transformer은 그렇지 못하므로 BitNet의 더 나은 훈련 안정성을 보여준다. 최적화에서의 이러한 장점은 더 큰 학습율을 갖는 트레이닝을 가능하게 한다. 그림 5b는 BitNet가 학습률의 증가로 인해 PPL 측면에서 더 나은 수렴을 달성할 수 있다는 것을 보여준다.




(a)




(b)

그림 4: 추론 비용에 대한 BitNet와 FP16 Transformer의 제로 샷(왼쪽)과 소샷(오른쪽)의 성능이다.



(a)



(b)

그림 5: 비트넷은 FP16 Transformer와 동일 학습율을 갖는 것보다 안정적이다. 훈련 안정성은 비트넷에게 더 큰 학습 속도를 가능하게 하여 (오른쪽) 더 나은 수렴을 유도한다.

4 Comparison with Post-training Quantization

4.1 Setup

우리는 3.1절에서 설명한 바와 같은 설정으로 BitNet을 훈련시킨다. 우리는 Absmax [DLBZ22], SmoothQuant [XLS* 23], GPTQ [FAHA23], QuIP [CCKS23]를 포함하여 최신 양자화 방법들과 BitNet을 비교한다. 이러한 방법은 FP16 Transformer 모델에 대한 훈련 후 양자화이며, 이는 BitNet와 동일한 훈련 설정 및 데이터를 따르는 것이다. 이 중 Absmax 및 SmoothQuant는 가중치 및 활성화 모두를 양자화하는 반면, GPTQ 및 QuIP는 가중치의 정밀도를 줄일 뿐이다. 우리는 다양한 양자화 수준에 대해 그 방법을 적용한다. 가중치만의 양자화(즉, GPTQ 및 QuIP)에 대해 W4A16과 W2A16을 실험한다. 가중치-활성화 양자화(즉 Absmax 및 SmoothQuant)에 대해, 우리는 FP16 트랜스포머를 W8A8, W4A4 및 W1A8으로 양자화하기 위해 이를 사용한다. 비트넷을 구현하는 것은 베이스라인보다 낮거나 같은 비트를 갖는 이진 가중치 8비트 활성화(W1A8)이다.

4.2 Results

표 3은 Winogrande, Winograd, Storycloze 및 Hellaswag와 같은 4개의 벤치마크 데이터세트에 대한 다양한 베이스라인 접근법에 대한 제한된 방법, BitNet의 제로 샷 성능에 대한 상세 비교 분석을 제시한다. 모든 모델은 공정한 비교를 위해 6.7B의 모델 크기를 가지고 있다.




그림 6: BitNet과 후트레이닝 양자선의 다운스트림 작업에 대한 제로 샷 (왼쪽) 및 소수 샷 (오른쪽) 결과이다.

WBits	Methods	PTQ	PPL↓	WG↑	WGe↑	HS↑	SC↑	Avg↑
16	Random	✗	-	50.0	50.0	25.0	50.0	43.8
	Transformer	✗	15.19	66.7	54.3	42.9	67.4	57.8
8	Absmax	✓	21.43	60.4	52.0	38.3	62.7	53.4
	SmoothQuant	✓	15.67	65.3	53.1	40.9	67.6	56.7
4	GPTQ	✓	16.05	57.2	51.2	39.9	63.4	52.9
	Absmax	✓	4.8e4	55.8	50.9	25.0	53.1	46.2
	SmoothQuant	✓	1.6e6	53.7	48.3	24.8	53.6	45.1
2	GPTQ	✓	1032	51.6	50.1	25.8	53.4	45.2
	QuIP	✓	70.43	56.1	51.2	30.3	58.4	49.0
1	Absmax	✓	3.5e23	49.8	50.0	24.8	53.6	44.6
	SmoothQuant	✓	3.3e21	50.5	49.5	24.6	53.1	44.4
1	BitNet	✗	17.07	66.3	51.4	38.9	66.9	55.9

BitNet 및 베이스라인(PTQ: 포스트 트레이닝 양자화, WGe: V &e;., WG: Winograd, SC: Storycloze, HS: Hellaswag 데이터 세트)에 대한 제로 샷 결과를 나타낸다.

방법들은 16부터 1까지의 범위에 걸쳐서 여러 가중치 비트 레벨들에 걸쳐 평가된다. 다운스트림 태스크의 제로 샷 정확도 이외에도, 평가 메트릭에는 각 방법의 성능에 대한 포괄적인 이해를 제공하는 검증 세트의 언어 모델 곤란도가 포함된다.

결과는 특히 낮은 비트 레벨들에 대해, 베이스라인 접근법들에 비해 경쟁적 성능 레벨들을 달성하는 데 비트넷의 효과를 입증한다. BitNet의 0-샷 점수는 8-비트 모델과 비교할 수 있는 반면, 추론 비용은 훨씬 낮다. 4 비트 모델들에 대해, 가중치-온리 양자화 방법들은 주로 활성화가 더 양자화되기 어려워서, 가중치-및-활성화 양자화기들보다 더 우수하다. BitNet은 1-비트 모델로서 가중치-활성화 양자화 방법 및 가중치-만의 방법 모두보다 훨씬 나은 결과를 달성한다. 하위 비트 모델의 경우, BitNet은 모든 베이스라인에 대해 일관성 있게 우수한 점수를 보였다. 이는 포스트-훈련 양자화 방법들에 대한 양자화 인지 트레이닝 접근법들의 이점들을 증명한다. 그림 6은 모델 크기를 1.3B에서 6.7B로 확대하면서 우리 방법과 베이스라인의 제로 샷 정확도와 소 샷 정확도를 모두 요약한다. 그 장점이 다양한 척도에 걸쳐서 일관적으로 나타남을 입증한다.

Methods	PPL↓	HS↑	WGe↑	WG↑	SC↑	Avg↑
<i>Zero-Shot Learning</i>						
BitNet	20.34	33.2	52.1	60.7	63.2	52.3
Elastic + Pre-LN	24.05	29.6	52.9	56.8	61.3	50.2
Absmax + Pre-LN	22.11	31.6	50.0	61.8	61.6	51.3
Absmax + BMT	22.98	31.2	52.1	60.4	62.7	51.6
<i>Few-Shot Learning</i>						
BitNet	20.34	33.5	50.4	62.1	63.8	52.5
Elastic + Pre-LN	24.05	29.9	51.7	57.5	61.1	50.1
Absmax + Pre-LN	22.11	31.4	51.9	63.9	61.6	52.2
Absmax + BMT	22.98	31.3	51.5	57.5	62.6	50.7

표 4: 비트넷(BitNet)의 성능. WGe: Winograd Schema; WG: Word Grouping; SC: Simple Commonsense; HS: HellaSwag; PPL: Perplexity. BitNet은 다른 방법들보다 낮은 PPL과 높은 HS, WG, SC, HS를 달성하며, 이는 모델의 학습을 안정화하고, 더 나은 성능을 달성하는 데 도움이 된다. BitNet은 1-비트 변환기 아키텍처의 아키텍처이다.

5 Ablation Studies

표 4에서 우리는 여러 대안적 접근법과 비교하여 제거 연구를 제시한다. 우리는 모델 훈련을 안정화하는 기술뿐만 아니라 활성화 양자화 접근법에서 선택의 영향을 절제한다. BitNet은 absmax를 구현하여 활성화를 양자화하고 SubLN을 사용하여 학습 안정성을 구현하였다. 한 양자화 대안은 학습 가능한 파라미터로 스케일을 동적으로 조정하는 탄성 함수 [LOP* 22]이다. 우리의 실험에서, 우리는 absmax가 탄성 함수보다 더 좋은 성능을 갖는다는 것을 발견한다. 또한, absmax 함수는 더 안정적인 훈련을 이끌어 BitNet에 대한 더 큰 학습 속도를 가능하게 한다. 우리는 또한 SubLN을 Pre-LN 및 BMT 아키텍처 [ZGC* 23]와 비교한다. Pre-LN은 GPT에 대한 기본 아키텍처인 반면 BMT는 이진화된 모델의 안정성을 개선하는 것으로 밝혀졌다. 우리의 실험은 SubLN이 Pre-LN과 BMT 둘 다를 능가한다는 것을 보여준다. 따라서, 우리는 BitNet에서 구현으로 Absmax와 SubLN을 선택한다.

6 Conclusion and Future Work

우리는 대형 언어 모델을 위한 새로운 1-비트 변환기 아키텍처인 BitNet을 제시한다. 우리의 접근법은 대규모 언어 모델을 효율적으로 처리할 수 있는 능력을 가지고, 확장 가능하고 안정적이도록 설계되었다. 실험 결과는 BitNet가 퍼플리시티와 다운스트림 작업 성능 모두에서 경쟁적 성능을 달성하는 한편, 기저선에 비해 메모리 발자국과 에너지 소비를 현저하게 감소시킨다는 것을 입증한다. 더욱이, 비트넷은 풀-정밀 트랜스포머와 유사한 스케일링 법칙을 따른다는 점을 보여주고, 성능과 효율 측면에서 잠재적인 이점을 가진 더 큰 언어 모델까지 효과적으로 스케일링할 수 있음을 나타낸다. 향후 모델 크기 및 훈련 단계의 측면에서 비트넷을 확대하기를 원한다. 우리는 또한 대규모 언어 모델을 학습하기 위한 다른 아키텍처(예를 들어, RetNet[SDH* 23])에서 BitNet을 적용하는 것에 관심을 가지고 있다.

References

[ADF* 23] 노한 아닐, 앤드류 M. 다이, 오르한 피라트, 멜빈 존슨, 드미트리 레피히닌, 알렉산드르 파소스, 시야막 샤케리, 에마누엘 타로파, 페이지 베일리, 지펑 천, 에릭 추 등. PaL.M 2 기술 보고서. CoRR, abs/2305.10403, 2023.

[BKH16] Lei Jimmy Ba, Jamie Ryan Kiros, Geoffrey E. Hinton. 계층 정규화요. CoRR, 2016.

[Yoshua Bengio, Nicholas Léonard, Aaron C. Courville] 조건부 계산을 위해 확률적 뉴런을 통해 경사를 추정하거나 전파한다. CoRR, abs/1308.3432, 2013.

[BMR* 20]Tom B. 브라운, 벤저민 맨, 닉 라이더, 멜라니 서비아, 제라드 카플란, 프랭올라 다리왈, 아르빈딜라칸탄, 프라나브 샤얀, 지리쉬 사스트리, 암다나 애스켈, 산디니 아가르왈, 에릴 헤르베르트-보스, 그레첸 크루게르 등이 이에 참여했다. 언어 모델은 퍼스트샷 학습자로서, 작은 샷을 통해 학습하는 학습자이다. Neural Information Processing Systems 33, 2020. Advances in Neural Information Processing Systems에 포함되었다.

아드리안 볼라트, 게오르기오스 지미로풀로스. ANOR-Net++: 개선된 이진 신경망을 사용한다. BMVC 2019에서, 2019.

[CCKS23] 제리 치, 야오후이 카이, 블로디미르 쿨레쇼프, 크리스토퍼 데 사. QuIP : 보증을 갖는 대규모 언어 모델의 2비트 양자화이다. CoRR, abs/2307.13304, 2023.

[[CND® 22]Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, Parker Schuh, Kensen Shi, Sasha Tsvyashchenko, Joshua Maynez, Abhishek Rao, Parker Barnes, Yi Tay, Noam Shazeer, 등. PaLM: 경로를 이용한 언어 모델링 스케일링을 한다. CoRR, abs/2204.02311, 2022.

[도23] ‘도에서. FlashAttention-2 : 병렬성 및 작업 분할을 더 잘 하는 더 빠른 어텐션이다. CoRR, abs/2307.08691, 2023.

[DFE™ 22] Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, Christopher Re. FlashAttention: 빠르고 메모리 효율적인 정확한 주의력이다. NeurIPS, 2022.

[DLBZ22] 팀 데트머스, 마이크 루이스, 유네스 벨카다, 루크 제틀메이어. LLM.int8(): 스케일의 변환자들에 대한 8비트 행렬 곱셈이다. CoRR, 2022.

[FAHA23] Elias Frantar, Saleh Ashkboos, Torsten Hoefler, Dan Alistarh. OPTQ: 생성적 사전 훈련된 변환기에 대한 정확한 양자화이다. 2023년 제11차 국제 학습 표현에 관한 학술대회에서 연구 결과를 발표하였다.

HBM*™ 22] 조던 호프만, 세바스티안 보르가우드, 아서 멩시, 엘레나 부차츠카야, 트레버 카이, 엘리자 러더퍼드, 디에고 데 라스 카사스, 리사 앤 헨드릭스, 요한네스 웰블, 에이든 클라크, 톰 헨니건, 에릭 놀랜드, 카티 밀리컨, 조지언 댄드레시, 보그단 다모크, 아우렐리아 귀 컴퓨팅 최적의 대규모 언어 모델을 훈련한다. CoRR, abs/2203.15556, 2022.

[HKK* 20] 톰 헤니건, 제라드 카플란, 모르 카츠, 마크 첸, 크리스토퍼 헤스, 제이콥 잭슨, 허우 준, 톰 비. 브라운, 프라풀라 다리왈, 스콧 그레이, 크리스 홀레이시, 베니마먼, 알렉 라드포드, 아디티야 라메쉬, 닉 라이더, 다니엘 M. 지글러, 존 쉰만, 다리오 아모데이, 샘 맥캔드리스 등이다. 자기 회귀 생성 모델링을 위한 스케일링 법칙을 제시한다. CoRR, abs/2010.14701, 2020.

{호르리4] 마크 호로위츠. 1.1 컴퓨팅의 에너지 문제 (그리고 그것에 대해 우리가 할 수 있는 일) 2014년 2월 9일~13일 미국 샌프란시스코, CA에서 열린 20/4 IEEE International Conference on Solid-State Circuits Conference, ISSCC 2014, 기술논문 디지스트, USA, 10-14쪽.

[KLZ™ 23]권우석, 리췌, 장시위안, 쉰영, 정리민, 코디 하오유, 조셉 E. 골론지, 하오 장, 이온 스토이카. 페이지화된 주의(pagedattention)로 서비스하는 대규모 언어 모델에 대한 효율적인 메모리 관리를 한다. 코아르, 2023.

[KMH™ 20] 제라드 카플란, 샘 맥캔드리스, 톰 헤니건, 톰 B. 브라운, 벤자민 체스, 레온 차일드, 스콧 그레이, 앨릭 라드포드, 제프리 우, 다리오 아모데이 등이다. 신경 언어 모델의 스케일링 법칙들. CoRR, abs/2001.08361, 2020.

LLDM12] 헥터 르베스케, 에른스트 데이비스, 레오라 모르겐슈터. 원오그라드 스키마는 과제입니다. 제13차 지식표현 및 추론원리 국제회의에서 말한다. 시티시어, 2012.

[LKM23] 야니브 레비아탄, 마탄 칼만, 요시 마티아스. 투기적 디코딩을 통해 변환기로부터의 빠른 추론을 한다. 2023년 7월 23일부터 29일까지 미국 하와이 호놀룰루에서 열린 International Conference on Machine Learning, ICML 2023에서 발표했다.

[LOP* 22] 루이 제춘, 바르라스 오구즈, 아시시 파푸, 린 샤오, 스콧 이히, 멩리, 라구르만 크리스나모르티, 야샤르 메드라드. Bit: 강건한 이진화 다중 증류 변환기. 2022년 NeurIPS에서요.

{[LSL*21] 리이쭈룬, 쯔장셴, 리시차오, 킬헬보이겐, 동황, 쯡 GANG팅. 아담과 훈련 전략이 BNN 최적화에 어떻게 도움을 주는지 알아보자. 머신 러닝 연구 프로시딩의 139권, 2021년 7월 18일부터 24일까지의 ICML 2021, Virtual Event, 제38차 국제 머신 러닝 회의의 프로시딩에서, 머신 러닝 연구에 관한 논문이 발표되었다. PMLR, 2021.

[MCH™ 16] 나스린 모스타파자데, 나타나엘 챔버스, 샤오둥 헤, 데비 파리크, 드루브 바트라, 루시 반데르웬데, 푸쉬미트 코일리, 제임스 F. 앨런. 상식 이야기의 더 깊은 이해를 위한 코퍼스와 평가 프레임워크. CoRR, abs/1604.01696, 2016.

{Ope23 | OpenAI. GP 1-4 기술 보고서. CoRR, abs/2303.08774, 2023.

모하마드 라스트게가리, 비센테 오르도네스, 조셉 레드먼, 알리 파르하디. XNOR-Net: 이진 컨볼루션 신경망을 사용한 이미지넷 분류이다. Computer Vision - ECCV 2016 - 14th European Conference, Amsterdam, The Netherlands, 2016년 10월 11-14일, 프로시딩스, Part IV, Computer Science Lectures Notes, 2016.

SBBC20 사카구치 게이스케, 르 브라르 론, 칸드라 바가바투라, 최예진. Wino- Grande: 스케일에서 적대적인 위노- 그란데 도전이다. 인공 지능에 관한 제 24차 AAAI 컨퍼런스, 2020, 8732-8740쪽에서 말한다.

SDH™23 울토토 쏜, 리둥, 샤오헌 황, 마쩌밍, 유키엽 알타, 짜옌 쑤, 장원왕, 푸루 웨이. 보유 네트워크: 대규모 언어 모델에 대한 변환기(Transformer)의 후속작, 2023.

LSPP™ 19] Mohammad Shoeybi, Mostofa Patwary, Raul Pur, Patrick LeGresley, Jared Casper, 그리고 Bryan Catanzaro. 메가트론-LM: 모델 병렬화를 이용하여 다수 억 파라미터 언어 모델을 학습한다. CoRR, abs/1909.08053, 2019.

"ELI"23 후고 루베르, 티보 르브릴, 고티에 이자카르, 자비에르 마르네트, 마리 앙르 라슈, 티모티 레크로이, 바스트레 로지예르, 나만 고얀, 에릭 햄브로, 파이살 아즈하르, 오렐랑 로드리게스, 아르만 주원, 에두아르 그라브, 기엠 루엥프는 이날 열린 '제10회 유네스코 세계기후변 LLaMA: 개방적이고 효율적인 기반이 되는 언어 모델이다. CoRR, abs/2302.13971, 2023.

[IMS*23] Hugo louvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi1, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajwal Bhargava, Shruti Bhosale, Dan Bikel, Lukas Blecher, Cristian Canton Ferrer, Moya Chen, Guillem Cucurull, David Esiobu, Jude Fernandes, Jeremy Fu 등. Llama 2: 개방형 기반이자 미세 조정된 대화 모델들. CoRR, abs/2307.09288, 2023.

[WH20] 위신 우와 카이밍 허. 그룹 정규화. 그런데 나도 지금 잘 안되는데. J. Comput. Vis., 128(3):/42-755, 2020.

WMH*22] 홍위 왕, 마슈밍, 황샤오한, 리둥, 왕원휘, 평쯔랑, 우위, 파야알 바자, 사크샘 싱할, 알론 벤하임, 바른 파트라, 준이우, 비쉬라브 차우드하리, 샤오송, 푸루웨이. 상당히 기초가 되는 변압기. CoRR, 2022.

[XLS*™23] Guangxuan X1ao, Ji Lin, Mickaél Seznec, Hao Wu, Julien Demouth, 그리고 Song Han. SmoothsQuant: 대규모 언어 모델을 위한 정확하고 효율적인 후단계 양자화이다. 2023년 미국 하와이 호놀룰루에서 23~29일 개최되는 ICML 2023 국제 머신 러닝 콘퍼런스에서 발표한다.

[ZGC* 23] Yichi Zhang, Ankush Garg, Yuan Cao, Lukasz Lew, Behrooz Ghorbani, Zhiru Zhang, Orhan Firat. 이산화된 신경기계번역을 합니다. 코 는 2023년으로 제정되었고, 2019년부터는 2023년까지로 확대되었다.

[ZHB*19] 로웬 셀러스, 아리 홀츠만, 요나탄 비스크, 알리 파하디, 여진 최. 헬라스와그: 기계가 정말로 당신의 말을 끝낼 수 있을까? 2019년 연산언어학협회 제57차 학술대회 논문집, 4791~4800쪽에 실렸다.

ZZL22]] Yichi Zhang, Zhiru Zhang, Lukasz Lew. 포크BNN: 경량화된 정확성을 이룩하기 위한 이진 추격이다. 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스에서 12465-12475쪽에 나온다. IEEE, 2022.

A Hyperparameters

Params	# Hidden	# Layers	# Heads	Learning Rate
125M	768	12	12	2.4e-3
350M	1024	24	16	1.2e-3
760M	1536	24	16	1e-3
1.3B	2048	24	32	8e-4
2.7B	2560	32	32	6.4e-4
6.7B	4096	32	32	4.8e-4
13B	5120	40	40	4e-4
30B	7168	48	56	4e-4

표 5: 스케일링 실험에서 비트넷에 대한 모델 구성을 보여준다.

Hyperparameters	Value
Training updates	40K
Tokens per sample	256K
Adam β	(0.9, 0.98)
Learning rate schedule	Polynomial decay
Warmup updates	750
Gradient clipping	$\times$
Dropout	$\times$
Attention dropout	$\times$
Weight decay	0.01

표 6: 스케일링 실험에서 BitNet 및 FP16 Transformer에 대한 하이퍼 파라미터이다. 13B와 30B 모델의 경우, 우리는 훈련 안정성을 위해 가중치 퇴화량을 0.05로 설정하였다.

Hyperparameters	Value
Peak learning rate	1e-3
Tokens per sample	128K
Adam β	(0.9, 0.98)
Learning rate schedule	Polynomial decay
Warmup updates	750
Gradient clipping	$\times$
Dropout	$\times$
Attention dropout	$\times$
Weight decay	0.01

표 7: BitNet와 FP16 Transformer의 안정성 테스트를 위한 하이퍼 파라미터를 나타낸다.

Hyperparameters	Elastic	Absmax
Peak learning rate	1e-4	8e-4
Training updates		40K
Tokens per sample		256K
Adam β		(0.9, 0.98)
Learning rate schedule	Polynomial decay	
Warmup updates		750
Gradient clipping		$\times$
Dropout		$\times$
Attention dropout		$\times$
Weight decay		0.01

표 8: BitNet의 절단에 대한 하이퍼 파라미터다.